CURS 3

VECTORI ALEATORI BIDIMENSIONALI

REGRESIE. ESTIMĂRI LINIARE ȘI NELINIARE

În multe aplicații practice ale teoriei probabilităților și statisticii matematice nu este suficient să măsurăm și cuantificăm o singură mărime (reprezentată printr-o variabilă aleatoare) ci avem nevoie de două sau mai multe astfel de mărimi (variabile aleatoare). În plus, aceste mărimi nu sunt, de cele mai multe ori, independente – în sensul efectelor și variațiilor comune care compun fenomenul studiat. Pentru a putea studia aceste fenomene în complexitatea lor, se folosesc vectori aleatori, compuși din două sau mai multe variabile aleatoare.

În acest capitol ne vom ocupa de **vectori aleatori bidimensionali** (formați din două variabile aleatoare). Acești vectori se notează $U=(X,Y)$, unde componentele sunt variabile aleatoare (discrete sau continue). Legătura dintre aceste două variabile aleatoare este pusă în evidență prin *funcția lor comună de repartiție*.

În continuare vom renunța la precizarea "*bidimensionali*" și ne vom referi simplu la "*vectori aleatori*", subînțelegând că sunt bidimensionali. Toate rezultatele prezentate pentru vectori aleatori bidimensionali se pot generaliza cu ușurință pentru cazul multidimensional.

FUNCȚIA DE REPARTIȚIE

Ca și variabila aleatoare simplă, vectorul aleator bidimensional este o *funcţie reală* care depinde de rezultatul unui anumit experiment.

- Fie $\{\Omega,K,P\}$ spaţiu de probabilitate. Funcţia $U:\Omega\to\mathbb{R}^2$, $U=(X,Y)$ se numeşte **vector aleator** dacă:

$$\text{pentru } (\forall)(a_1,a_2)\in\mathbb{R}^2,\ \{\omega\in\Omega \mid X(\omega)<a_1, Y(\omega)<a_2\}\in K$$

Observaţie: Mulţimea valorilor vectorului aleator, $U(\Omega)$, este o submulţime a mulţimii $\mathbb{R}^2$ ($U(\Omega)\subseteq\mathbb{R}^2$).

Prin vectorii aleatori bidimensionali, unui fenomen supus unor circumstanţe aleatoare i se asociază o pereche de numere reale, deci se stabileşte o corespondenţă între spaţiul de selecţie Ω, convenabil ales, şi $\mathbb{R}^2$.

În practică este dificil să găsim valorile acestor corespondenţe, dar este posibil să determinăm „cât de des" sunt luate aceste perechi de valori (cu ce probabilitate). Astfel, prin analogie cu cazul variabilelor aleatoare, putem defini *funcţia de repartiţie a vectorului aleator* U.

- Fie $\{\Omega,K,P\}$ spaţiu de probabilitate şi $U:\Omega\to\mathbb{R}^2$ un vector aleator. Funcţia $F_U:\mathbb{R}^2\to[0,1]$ definită prin:

$$F_U(x,y)=P\left(\{\omega\in\Omega \mid X(\omega)<x, Y(\omega)<y\}\right), \text{ cu } (x,y)\in\mathbb{R}^2$$

se numeşte ***funcţia de repartiţie*** *(sau de* ***distribuţie****) a vectorului aleator* U.
Prescurtat, se scrie $F_U(x,y)=P(X<x, Y<y)$.

Proprietăți:

1) Funcţie mărginită $0\le F_U(x,y)\le 1$, deoarece:

$$F_U(x,-\infty)=F_U(-\infty,y)=0 \text{ şi respectiv } F_U(+\infty,+\infty)=1;$$

2) F_X este *continuă la stânga* în fiecare argument;

3) Este nedescrescătoare în raport cu fiecare argument:

$$x_1<x_2 \Rightarrow F_U(x_1,y)\le F_U(x_2,y),\ \forall y\in\mathbb{R}$$
$$y_1<y_2 \Rightarrow F_U(x,y_1)\le F_U(x,y_2),\ \forall x\in\mathbb{R}$$

4) Pentru orice $a<b$ şi $c<d$, avem:

$$P(a\le X<b, c\le Y<d)=F_U(b,d)-F_U(a,d)-F_U(b,c)+F_U(a,c)\ge 0.$$

Funcția de repartiție precum și funcția de probabilitate (respectiv densitatea de repartiție) vor fi particularizate în continuare pentru cazul discret și continuu.

1. VECTORI ALEATORI – cazul discret

Dacă vectorul aleator (X,Y) ia un număr finit de valori, atunci se numește **discret** și se poate reprezenta printr-un tablou de repartiție bidimensional de forma:

$X\setminus Y$	y_1	y_2	.....	y_n	
x_1	p_{11}	p_{12}		p_{1n}	$p_1=\sum_{j=1}^{n}p_{1j}$
x_2	p_{21}	p_{22}		p_{2n}	$p_2=\sum_{j=1}^{n}p_{2j}$
.	.	.		.	.
.	.	.		.	.
.	.	.		.	.
x_m	p_{m1}	p_{m2}	.....	p_{mn}	$p_m=\sum_{j=1}^{n}p_{mj}$
	$q_1=\sum_{i=1}^{m}p_{i1}$	$q_2=\sum_{i=1}^{m}p_{i2}$	.....	$q_n=\sum_{i=1}^{m}p_{in}$	1

- Elementele p_{ij} ale tabloului reprezintă probabilitatea realizării *simultane* a evenimentelor $(X=x_i)$ și $(Y=y_j)$ (numită **repartiția comună**), adică:

$$p_{ij}=P\left[(X=x_i)\cap(Y=y_j)\right]=P\left[X=x_i,Y=y_j\right], \text{ cu } i=\overline{1,m} \text{ și } j=\overline{1,n}.$$

<u>Observații</u>:

- Dacă variabilele aleatoare X și Y sunt *independente*, atunci $p_{ij}=p_i\cdot q_j$;
- Din faptul că evenimentele $(X=x_i,Y=y_j)$ formează un sistem complet de evenimente, avem: $\sum_{i=1}^{m}\sum_{j=1}^{n}p_{ij}=1$.

1.1. Funcţia de repartiţie şi funcţia de probabilitate

Fie vectorul aleator discret $U=(X,Y)$, reprezentat prin tabloul său de repartiţie (similar cu cel prezentat mai sus).

- **Funcția de probabilitate** (*en. probability mass function*) a vectorului aleator discret U este *funcția care atașează fiecărei perechi de valori a vectorului probabilitatea cu care această valoare este luată*:

$$f\left(x_i, y_j\right) = p_{ij} = P\left(X = x_i, Y = y_j\right), \text{ cu } i = \overline{1,m} \text{ și } j = \overline{1,n}$$

În mod evident, $f\left(x_i, y_j\right) \geq 0$ pentru orice $i = \overline{1,m}$ și $j = \overline{1,n}$ și $\sum_{i=1}^{m}\sum_{j=1}^{n} f\left(x_i, y_j\right) = 1$.

- **Funcția de repartiție** a vectorului aleator discret U este:

$$F_U(x,y) = P\left(X < x, Y < y\right) = \sum_{l=1}^{j-1}\sum_{k=1}^{i-1} p_{kl},$$

cu $x_{i-1} \leq x < x_i$ și $y_{j-1} \leq y < y_j$, $i = \overline{1,m}$ și $j = \overline{1,n}$.

1.2. Repartiții marginale și condiționate

- **Repartițiile marginale** (sau *legile de probabilitate marginală, en. marginal distribution*) sunt repartițiile variabilelor aleatoare ce compun vectorul aleator $U = \left(X, Y\right)$:

$$X: \begin{pmatrix} x_1 & x_2 & \ldots & x_m \\ p_1 & p_2 & \ldots & p_m \end{pmatrix} = \begin{pmatrix} x_i \\ p_i \end{pmatrix}, \text{ cu } i = \overline{1,m} \text{ și respectiv:}$$

$$Y: \begin{pmatrix} y_1 & y_2 & \ldots & y_n \\ q_1 & q_2 & \ldots & q_n \end{pmatrix} = \begin{pmatrix} y_j \\ q_j \end{pmatrix}, \text{ cu } j = \overline{1,n}$$

Probabilitățile $p_i = P\left(X = x_i\right)$ și respectiv $q_j = P\left(Y = y_j\right)$ se numesc *probabilități marginale* și se calculează prin însumarea pe linii (respectiv pe coloane) a probabilităților $p_{ij} = P\left(X = x_i, Y = y_j\right)$ din tabloul de repartiție al vectorului discret $U = \left(X, Y\right)$.

Observație: Dacă se cunoaște tabloul de repartiție al unui vector aleator $U = \left(X, Y\right)$, se poate calcula **produsul variabilelor marginale**, indiferent dacă acestea sunt independente sau nu:

$$X \cdot Y = \begin{pmatrix} x_i \cdot y_j \\ p_{ij} \end{pmatrix}_{\substack{i=\overline{1,m} \\ j=\overline{1,n}}}$$

Evident, odată cunoscută repartiția variabilei produs, calcularea **mediei produsului variabilelor marginale** X și Y, $M\left[XY\right]$ nu mai comportă nicio dificultate:

$$M[XY] = \sum_{i=1}^{m}\sum_{j=1}^{n} x_i y_j p_{ij}.$$

Cu ajutorul tabloului de repartiție al vectorului discret $U = \left(X, Y\right)$ se pot defini **repartițiile condiționate** ale variabilelor aleatoare X și Y:

- *Variabila aleatoare* $\left\{X \middle| Y = y_j\right\}$ se numește **repartiția condiționată a variabilei aleatoare** X **de către evenimentul** $\left\{Y = y_j\right\}$ *și are tabloul:*

$$\left\{X \middle| Y = y_j\right\} = \begin{pmatrix} x_1 & x_2 & \ldots & x_i & \ldots & x_m \\ \dfrac{p_{1j}}{q_j} & \dfrac{p_{2j}}{q_j} & \ldots & \dfrac{p_{ij}}{q_j} & \ldots & \dfrac{p_{mj}}{q_j} \end{pmatrix} = \begin{pmatrix} x_i \\ \dfrac{p_{ij}}{q_j} \end{pmatrix}, \text{ cu } i = \overline{1,m} \text{ și } j \text{ fixat}$$

Valorile $\frac{p_{ij}}{q_j}=\frac{P\left(X=x_i,Y=y_j\right)}{P\left(Y=y_j\right)}=P\left(X=x_i\middle|Y=y_j\right)$ sunt probabilitățile condiționate corespunzătoare, pentru $i=\overline{1,m}$ și j fixat.

- *Variabila aleatoare* $\left\{Y\middle|X=x_i\right\}$ se numește **repartiția condiționată a variabilei aleatoare** Y **de către evenimentul** $\left\{X=x_i\right\}$ *și are tabloul:*

$$\left\{Y\middle|X=x_i\right\}=\begin{pmatrix} y_1 & y_2 & \dots & y_j & \dots & y_n \\ \frac{p_{i1}}{p_i} & \frac{p_{i2}}{p_i} & \dots & \frac{p_{ij}}{p_i} & \dots & \frac{p_{in}}{p_i} \end{pmatrix}=\begin{pmatrix} y_j \\ \frac{p_{ij}}{p_i} \end{pmatrix}$$, cu $j=\overline{1,n}$ și i fixat

Valorile $\frac{p_{ij}}{p_i}=\frac{P\left(Y=y_j,X=x_i\right)}{P\left(X=x_i\right)}=P\left(Y=y_j\middle|X=x_i\right)$ sunt probabilitățile condiționate corespunzătoare, pentru $j=\overline{1,n}$ și i fixat.

1.3. Medii marginale și medii condiționate

- **Mediile marginale** sunt mediile variabilelor aleatoare care compun vectorul discret:

$$M\left[X\right]=\sum_{i=1}^{m}x_i\cdot p_i \text{ și respectiv } M\left[Y\right]=\sum_{j=1}^{n}y_j\cdot q_j;$$

- **Mediile condiționate** sunt mediile variabilelor aleatoare caracterizate de repartițiile condiționate, $\left\{X\middle|Y=y_j\right\}$ și $\left\{Y\middle|X=x_i\right\}$:

$$M\left[X\middle|Y=y_j\right]=\sum_{i=1}^{m}x_i\cdot P\left(X=x_i\middle|Y=y_j\right)=\sum_{i=1}^{m}x_i\cdot\frac{p_{ij}}{q_j} \text{ cu } i=\overline{1,m} \text{ și } j \text{ fixat și}$$

$$M\left[Y\middle|X=x_i\right]=\sum_{j=1}^{n}y_j\cdot P\left(Y=y_j\middle|X=x_i\right)=\sum_{j=1}^{n}y_j\cdot\frac{p_{ij}}{p_i}, \text{ cu } j=\overline{1,n} \text{ și } i \text{ fixat}$$

În plus se mai pot defini și *mediile condiționate "globale"*, ca variabile aleatoare:

- **Media lui** X **condiționată de** Y este o *variabilă aleatoare* cu repartiția:

$$M\left[X\middle|Y\right]=\begin{pmatrix} M\left[X\middle|Y=y_j\right] \\ q_j \end{pmatrix}$$

- **Media lui** Y **condiționată de** X este o *variabilă aleatoare* cu repartiția:

$$M\left[Y\middle|X\right]=\begin{pmatrix} M\left[Y\middle|X=x_i\right] \\ p_i \end{pmatrix}$$

Observații:

1) $M\left(M\left[Y\middle|X\right]\right)=M\left[Y\right]$ și respectiv $M\left(M\left[X\middle|Y\right]\right)=M\left[X\right]$;

2) $M\left(X\cdot M\left[Y\middle|X\right]\right)=M\left[XY\right]$.

2. VECTORI ALEATORI – cazul continuu

2.1. Funcţia de repartiţie şi densitatea de repartiție

▪ Fie $\{\Omega, K, P\}$ câmp de probabilitate. Considerăm o clasă de vectori aleatori $U=(X,Y)$ pentru care există o funcţie $f:\mathbb{R}^2\to[0,+\infty)$ cu un număr finit de puncte de discontinuitate de prima speţă (deci integrabilă), ce satisface relaţia:

$$P(X<x,\,Y<y)\overset{def}{=}F_U(x,y)=\int_{-\infty}^{x}\int_{-\infty}^{y}f(u,v)\,du\,dv$$

unde $F_U(x,y)$ este **funcţia de repartiţie** a vectorului aleator U. Atunci funcţia f se numeşte **densitate de repartiție** a vectorului aleator U.

Proprietăţi ale densității de repartiție:

1) Funcţie pozitivă: $f(x,y)\geq 0$, pentru $\forall(x,y)\in\mathbb{R}^2$;

2) $\int_{-\infty}^{\infty}\int_{-\infty}^{\infty}f(x,y)\,dx\,dy=1$;

<u>Observații</u>:

- Dacă f este continuă, atunci există $\dfrac{\partial^2 F}{\partial x\partial y}$ și avem: $\dfrac{\partial^2 F}{\partial x\partial y}=f(x,y)$.
- Pentru orice $a<b$ și $c<d$, avem: $P(a\leq X<b,\,c\leq Y<d)=\int_a^b\int_c^d f(x,y)\,dx\,dy$.
- Pentru un domeniu oarecare $D\subset\mathbb{R}^2$ avem: $P((X,Y)\in D)=\iint_D f(x,y)\,dx\,dy$.

2.2. Densități și funcții de repartiție marginale și condiționate

Considerăm un vector aleator bidimensional $U=(X,Y)$, cu densitatea de repartiție $f(x,y)$ (cunoscută).

▪ **Densitățile de repartiție marginale** sunt densitățile de repartiție ale variabilelor aleatoare componente ale vectorului aleator și se calculează cu ajutorul densității de repartiție a acestuia:

$$f_X(x)=\int_{-\infty}^{\infty}f(x,y)\,dy \quad \text{și respectiv:} \quad f_Y(y)=\int_{-\infty}^{\infty}f(x,y)\,dx$$

Dacă variabilele aleatoare X și Y sunt *<u>independente</u>*, atunci $\boxed{f(x,y)=f_X(x)\cdot f_Y(y)}$.

Această relație este cunoscută și sub denumirea de "*Teorema multiplicării legilor de repartiție*" și reprezintă *<u>condiția necesară și suficientă de independență</u>* a două variabile aleatoare.

Acest criteriu de verificare a independenței se poate aplica doar dacă se cunoaște densitatea de repartiție comună $f(x,y)$.

▪ **Funcțiile de repartiție marginale** sunt funcțiile de repartiție ale variabilelor aleatoare marginale X și Y. Acestea se pot calcula în două moduri:

1. Folosind densitatea de repartiție comună $f(x,y)$:

$$F_X(x) = P(X < x) = F(x, \infty) = \int_{-\infty}^{x} \int_{-\infty}^{\infty} f(u,v)\,du\,dv$$ și respectiv:

$$F_Y(y) = P(Y < y) = F(+\infty, y) = \int_{-\infty}^{\infty} \int_{-\infty}^{y} f(u,v)\,du\,dv$$

2. Folosind densitățile de repartiție marginale (dacă au fost calculate în prealabil):

$F_X(x) = \int_{-\infty}^{x} f_X(u)\,du$ și respectiv: $F_Y(y) = \int_{-\infty}^{y} f_Y(v)\,dv$

Dacă variabilele aleatoare X și Y sunt ***independente***, atunci $F(x,y) = F_X(x) \cdot F_Y(y)$.

- **Densități de repartiție condiționate**: sunt densitățile de repartiție ale variabilelor aleatoare condiționate $(X \mid Y = y)$ și $(Y \mid X = x)$:

$$f(X \mid Y = y) = f(x \mid y) = \frac{f(x,y)}{f_Y(y)}$$ și respectiv: $$f(Y \mid X = x) = f(y \mid x) = \frac{f(x,y)}{f_X(x)}.$$

- **Funcții de repartiție condiționate:**

$$F(X \mid Y = y) = \frac{\int_{-\infty}^{x} f(u,y)\,du}{f_Y(y)}$$ și respectiv: $$F(Y \mid X = x) = \frac{\int_{-\infty}^{y} f(x,v)\,dv}{f_X(x)}$$

- Cu ajutorul densităților de repartiție condiționate se pot calcula probabilități condiționate de forma:

$$P(Y < b \mid X = x) = \int_{-\infty}^{b} f(y|x)\,dy$$ și respectiv $$P(X < a \mid Y = y) = \int_{-\infty}^{a} f(x|y)\,dx$$

2.3. Medii marginale și medii condiționate

- **Mediile marginale** sunt mediile variabilelor aleatoare care compun vectorul discret:

$$M[X] = \int_{-\infty}^{\infty} x \cdot f_X(x)\,dx$$ și respectiv $$M[Y] = \int_{-\infty}^{\infty} y \cdot f_Y(y)\,dy$$

Observație: Cu ajutorul densității de repartiție a vectorului aleator, $f(x,y)$ se poate calcula **media produsului variabilelor marginale** X și Y:

$$M[XY] = \iint_{\mathbb{R}^2} xy\,f(x,y)\,dxdy.$$

Dacă variabilele aleatoare X și Y sunt ***independente***, atunci $M[XY] = M[X] \cdot M[Y]$.

- **Mediile condiționate** sunt mediile variabilelor aleatoare $(X \mid Y = y)$ și $(Y \mid X = x)$, care au densitățile de repartiție $f(x|y)$ și respectiv $f(y|x)$:

$M[X|Y = y] = \int_{-\infty}^{\infty} x \cdot f(x|y)\,dx$ = *"Media variabilei X condiționată de $Y = y$"* și

$M[Y|X = x] = \int_{-\infty}^{\infty} y \cdot f(y|x)\,dy$ = *"Media variabilei Y condiționată de $X = x$"*

Observație: Mediile condiționate ale variabilelor aleatoare continue pot fi privite ca numere sau ca funcții! De exemplu, să presupunem că am calculat $M\left[X\middle|Y=y\right]=\frac{1-y}{2}$, pentru $y\in\left[0,1\right]$. Pentru orice valoare concretă, fixată, a lui y în intervalul $\left[0,1\right]$, $M\left[X\middle|Y=y\right]$ este un număr. Dacă $y\in\left[0,1\right]$, fără a se specifica o valoare particulară pentru y, atunci $M\left[X\middle|Y=y\right]$ este o funcție în y.

- **Media lui X condiționată de Y** este o *variabilă aleatoare* cu densitatea de repartiție $f_Y\left(y\right)$ și care ia valorile $M\left[X\middle|Y=y\right]$. Se notează $M\left[X\middle|Y\right]$.
- **Media lui Y condiționată de X** este o *variabilă aleatoare* cu densitatea de repartiție $f_X\left(x\right)$ și care ia valorile $M\left[Y\middle|X=x\right]$. Se notează $M\left[Y\middle|X\right]$.

Mediile variabilelor aleatoare $M\left[X\middle|Y\right]$ și $M\left[Y\middle|X\right]$ sunt:

$$M\left[M\left[X\middle|Y\right]\right]=\int_{-\infty}^{\infty}M\left[X\middle|Y=y\right]\cdot f_Y\left(y\right)dy \text{ și respectiv:}$$

$$M\left[M\left[Y\middle|X\right]\right]=\int_{-\infty}^{\infty}M\left[Y\middle|X=x\right]\cdot f_X\left(x\right)dx$$

Observație: Ca și în cazul discret, variabila aleatoare $M\left[Y\middle|X\right]$ (și în mod analog $M\left[X\middle|Y\right]$) are proprietățile:

1) $M\left(M\left[Y\middle|X\right]\right)=M\left[Y\right]$ și respectiv $M\left(M\left[X\middle|Y\right]\right)=M\left[X\right]$;

2) $M\left(X\cdot M\left[Y\middle|X\right]\right)=M\left[XY\right]$.

3. REGRESIE. ESTIMĂRI LINIARE ȘI NELINIARE

3.1. FUNCȚII DE REGRESIE

Termenul de "regresie" provine din studiile efectuate, în domeniul eredității, de statisticianul englez Francis Galton (1822 – 1911).

Regresia ne arată (în formă analitică) cum o variabilă este dependentă de altă variabilă (sau de alte variabile) și nu implică cauzalitate – dacă există cauzalitate, aceasta trebuie justificată pe baza unei teorii existente în domeniul de aplicabilitate (legi ale fizicii, biologiei, economiei, etc).

Analiza de regresie estimează valoarea medie a unei variabile, cunoscând valorile fixate ale altei variabile (sau altor variabile).

Considerăm un vector aleator bidimensional $U=\left(X,Y\right)$, discret sau continuu, cu tabloul de repartiție cunoscut, respectiv cu densitatea de repartiție $f\left(x,y\right)$ cunoscută.

- *Funcția de regresie a variabilei aleatoare X în raport cu Y* este variabila aleatoare $M\left[X\middle|Y\right]$ cu mulțimea valorilor $M\left[X\middle|Y=y\right]$, pentru $\forall x\in\mathbb{R}$. Se notează $R_X\left(y\right)$.

▪ *Funcția de regresie a variabilei aleatoare* Y *în raport cu* X este variabila aleatoare $M\left[Y\middle|X\right]$ cu mulțimea valorilor $M\left[Y\middle|X=x\right]$, pentru $\forall y\in\mathbb{R}$. Se notează $R_Y\left(x\right)$.

Observație: Se obișnuiește ca în loc de ”funcție de regresie” să se folosească termenul de ”regresie”. Indiferent de termenul folosit, este obligatoriu să se specifice care variabilă este condiționată și care condiționează. În statistică se folosesc termenii de ”variabilă dependentă” pentru variabila condiționată și ”variabilă independentă” pentru cea care condiționează. *Termenul de ”independent” nu se referă la independența variabilelor în sens probabilistic.*

3.1.1. Regresie liniară

Considerăm un vector aleator bidimensional $U=\left(X,Y\right)$, discret sau continuu, cu tabloul de repartiție cunoscut, respectiv cu densitatea de repartiție $f\left(x,y\right)$ cunoscută.

Dacă funcția de regresie este funcție liniară:

$$R_X\left(y\right)=M\left[X\middle|Y\right]=aY+b \text{ , cu } a,b\in\mathbb{R} \text{ sau}$$

$$R_Y\left(x\right)=M\left[Y\middle|X\right]=aX+b \text{ , cu } a,b\in\mathbb{R}$$

spunem că **regresia este liniară** (dependența dintre cele două variabile este liniară).

3.1.2. Dreapta de regresie

Fie X și Y două variabile aleatoare (discrete sau continue) cu dispersii nenule și fie $\rho\left[X,Y\right]=\dfrac{Cov\left[X,Y\right]}{\sigma_X\cdot\sigma_Y}$ coeficientul de corelație al acestor variabile. Dacă corelația este ”puternică” (modulul coeficientului de corelație este apropiat de 1), atunci valorile luate de vectorul aleator $U=\left(X,Y\right)$ tind să fie situate pe dreapta de ecuație:

$$y-M\left[Y\right]=\frac{\operatorname{cov}\left[X,Y\right]}{D^2\left[X\right]}\left(x-M\left[X\right]\right)$$

numită **dreaptă de regresie** a lui Y în raport cu X.

Observație: Similar se poate defini și dreapta de regresie a lui X în raport cu Y:

$$x-M\left[X\right]=\frac{\operatorname{cov}\left[X,Y\right]}{D^2\left[Y\right]}\left(y-M\left[Y\right]\right)$$

Alegerea uneia dintre ecuații se face în funcție de situația particulară de aplicare – în funcție de logica teoretică a dependenței dintre mărimile reprezentate de cele două variabile aleatoare.

▪ Semnul coeficientului de corelație coincide cu semnul covarianței (dispersiile sunt întotdeauna pozitive) și cu panta dreptei de regresie (ne vom referi în continuare la dreapta de regresie a lui Y în raport cu X). Astfel, avem:

- Dacă $\rho\left[X,Y\right]>0$, la o creștere a valorilor variabilei X, valorile lui Y au tendința să crească;
- Dacă $\rho\left[X,Y\right]<0$, la o creștere a valorilor variabilei X, valorile lui Y au tendința să scadă;
- Dacă $\rho\left[X,Y\right]=0$, variabilele X și Y sunt necorelate.

Revenim asupra unui aspect foarte important, precizat în Cursul 5+6 (la proprietățile coeficientului de corelație), și anume legătura dintre independența a două variabile aleatoare și valoarea coeficientului de corelație:

- Dacă X şi Y sunt variabile aleatoare *independente*, atunci $\rho[X,Y]=0$.
- Dacă $\rho[X,Y]=0$, NU rezultă că X şi Y sunt variabile aleatoare *independente*.

3.2. ESTIMĂRI LINIARE ȘI NELINIARE

Estimările liniare și neliniare ale unei variabile aleatoare Y cu ajutorul altei variabile aleatoare X presupun determinarea unei funcții de forma $\hat{Y}=\varphi(X)$ care minimizează media pătratului erorii $\varepsilon=Y-\varphi(X)$:

$$M\left[\left(Y-\varphi(X)\right)^2\right]=\min$$

Această tehnică este cunoscută sub numele de "*Metoda celor mai mici pătrate*". În continuare sunt prezentate câteva rezultate importante obținute pe baza acestei metode, fără a insista asupra metodei în sine:

1. *Estimări liniare și omogene, de forma:* $\hat{Y}=aX$, $a\in\mathbb{R}$
2. *Estimări liniare și neomogene, de forma:* $\hat{Y}=aX+b$, $a,b\in\mathbb{R}$
3. *Estimări neliniare, de forma* $\hat{Y}=\varphi(X)$, *unde* φ *nu este funcție liniară.*

Fie X și Y două variabile aleatoare (discrete sau continue) care au momente inițiale de ordin 1 și 2, nenule. Alegem să estimăm variabila Y în funcție de variabila X.

- Variabilele aleatoare X și Y se numesc **ortogonale** dacă $M[XY]=0$.
- Numim **proiecție ortogonală a lui** X **pe** Y variabila aleatoare:

$$Y_0=\frac{M[XY]}{M[X^2]}X$$

cu proprietatea că variabilele aleatoare X și $Y-Y_0$ sunt ortogonale.

Pe baza metodei celor mai mici pătrate, putem afirma că:

1. Cea mai bună estimare liniară omogenă a lui Y în funcție de X este *proiecția ortogonală* a lui Y pe X:

$$\hat{Y}=\frac{M[XY]}{M[X^2]}X;$$

- **Cea mai bună estimare liniară neomogenă** a lui Y în funcție de X are proprietatea că perechea $\left(X,\hat{Y}\right)$ este situată pe *dreapta de regresie*:

$$\hat{Y}-M[Y]=\frac{\operatorname{cov}[X,Y]}{D^2[X]}\left(X-M[X]\right)$$

- **Cea mai bună estimare neliniară** a lui Y în funcție de X este *media lui* Y *condiționată de* X, $M[Y|X]$.

Observații:

- Termenul de ”cea mai bună estimare...” face referire la îndeplinirea condiției de minim din Metoda celor mai mici pătrate.
- Similar se poate defini cea mai bună estimare liniară sau neliniară a lui X în funcție de Y. Alegerea variabilei de estimat se face în funcție de situația particulară de aplicare – în funcție de logica teoretică a dependenței dintre mărimile reprezentate de cele două variabile aleatoare.