CURS 4 PROBABILITĂȚI

OPERAȚII CU VARIABILE ALEATOARE CONTINUE

ȘIRURI DE V.A. TEOREMA LIMITĂ CENTRALĂ. LEGEA NUMERELOR MARI

1. OPERAȚII CU VARIABILE ALEATOARE CONTINUE

Cu ajutorul repartiției comune a două variabile aleatoare (componente ale unui vector aleator) se pot defini densitățile de repartiție ale *sumei, diferenței, produsului și câtului* acestor variabile.

1.1. Transformări de variabile aleatoare

Pentru a defini operațiile cu variabile aleatoare continue, se folosesc **transformări de variabile aleatoare**. Vom exemplifica această tehnică pentru cazul bidimensional, generalizarea la cazul multidimensional fiind imediată.

Considerăm câmpul de probabilitate $\{\Omega, K, P\}$ și două variabile aleatoare X și Y, definite pe acest câmp. Considerăm o transformare inversabilă între două domenii $\Delta, D \subset \mathbb{R}^2$, deci o funcție vectorială de două variabile $\varphi(\varphi_1, \varphi_2)$:

$$\begin{cases} x = \varphi_1(u,v) \\ y = \varphi_2(u,v) \end{cases}, \ (x,y) \in D \text{ și } (u,v) \in \Delta$$

Funcția $\varphi(\varphi_1, \varphi_2)$ satisface condițiile:

1) φ_1, φ_2 sunt funcții reale, de clasă $C^1(\Delta)$;

2) Jacobianul transformării $J(u,v) = \begin{vmatrix} \frac{\partial \varphi_1}{\partial u} & \frac{\partial \varphi_1}{\partial v} \\ \frac{\partial \varphi_2}{\partial u} & \frac{\partial \varphi_2}{\partial v} \end{vmatrix} \neq 0$ pe Δ;

În aceste condiții, compunerea dintre (X,Y) și inversa transformării este tot o variabilă aleatoare notată (U,V). Dacă densitatea de repartiție comună a variabilelor X și Y este $f_{X,Y}(x,y)$, atunci, folosind formula schimbării de variabilă în integrala dublă:

$$\iint_D f(x,y)\,dxdy = \iint_\Delta f\left(\varphi_1(u,v), \varphi_2(u,v)\right) \cdot \left|J(u,v)\right| du\,dv$$

obținem densitatea de repartiție pentru variabila aleatoare (U,V):

$$\boxed{f_{U,V}(u,v) = f_{X,Y}\left(\varphi_1(u,v), \varphi_2(u,v)\right) \cdot \left|J(u,v)\right|}$$

Observație: Dacă avem o singură variabilă aleatoare X cu densitatea de repartiție $f_X(x)$ și avem nevoie să facem o schimbare de variabilă (de exemplu, pentru a ușura anumite calcule) de forma:

$$x = \varphi(y), \text{ cu } \varphi \text{ de clasă } C^1(D),\ D \subset \mathbb{R},$$

atunci densitatea de repartiție a inversei transformării (care este o variabilă aleatoare pe care o notăm cu Y) este:

$$\boxed{f_Y(y) = f_X\left(\varphi(y)\right) \cdot \left|\frac{d\varphi}{dy}\right|}$$

Exemplu: *Se consideră variabila aleatoare X cu densitatea de repartiție $f_X(x)$. Să se determine densitatea de repartiție a variabilei aleatoare $Y = aX + b$, $a \neq 0$ și $a, b \in \mathbb{R}$.*

Rezolvare: Considerăm transformarea $x = \frac{y-b}{a}$, adică $\varphi(y) = \frac{y-b}{a}$, care este o funcție de clasă $C^1(D)$, $D \subset \mathbb{R}$. Calculăm $\left|\frac{d\varphi}{dy}\right| = \frac{1}{|a|}$ *și obținem:*

$$f_Y(y) = f_X\left(\varphi(y)\right) \cdot \left|\frac{d\varphi}{dy}\right| = f_X\left(\frac{y-b}{a}\right) \cdot \frac{1}{|a|},$$

deci variabila aleatoare $Y = aX + b$ *are densitatea de repartiție :*

$$f_Y(y) = f_X\left(\frac{y-b}{a}\right) \cdot \frac{1}{|a|}.$$

Acest rezultat se poate folosi, fără demonstrație, în numeroase aplicații care presupun transformări liniare ale unor variabile aleatoare.

1.2. Densitatea de repartiție a sumei, diferenței, produsului și câtului

Considerăm un vector aleator (X, Y), cu densitatea de repartiție $f(x, y)$ cunoscută.

- **Densitatea de repartiție a sumei** variabilelor aleatoare X și Y, notată $Z = X + Y$:

Considerăm transformarea $\begin{cases} u = x + y \\ v = x \end{cases}$, care admite inversa $\begin{cases} x = v \\ y = u - v \end{cases}$, cu jacobianul $J = -1$. Atunci $f(x, y) = f(v, u - v) \cdot |J| = f(v, u - v)$. Densitatea de repartiție a variabilei aleatoare $Z = X + Y$ este repartiția marginală în raport cu $u = x + y$, adică:

$$\boxed{f_Z(u) = \int_{-\infty}^{\infty} f(v, u - v)\, dv}$$

Dacă X și Y sunt v.a. *indepedente,* cu densitățile de repartiție $f_X(x)$ și respectiv $f_Y(y)$, atunci: $\boxed{f_Z(u) = \int_{-\infty}^{\infty} f_X(v) \cdot f_Y(u - v)\, dv}$ (produs de convoluție).

- **Densitatea de repartiție a diferenței** variabilelor X și Y, notată $T = X - Y$

Considerăm transformarea $\begin{cases} u = x - y \\ v = x \end{cases}$, care admite inversa $\begin{cases} x = v \\ y = v - u \end{cases}$, cu jacobianul $J = 1$. Atunci $f(x, y) = f(v, v - u) \cdot |J| = f(v, v - u)$. Densitatea de repartiție a variabilei aleatoare $T = X - Y$ este repartiția marginală în raport cu $u = x - y$, adică:

$$\boxed{f_T(u) = \int_{-\infty}^{\infty} f(v, v - u)\, dv}$$

Dacă X și Y sunt v.a. *indepedente,* cu densitățile de repartiție $f_X(x)$ și respectiv $f_Y(y)$, atunci: $\boxed{f_T(u) = \int_{-\infty}^{\infty} f_X(v) \cdot f_Y(v - u)\, dv}$ (produs de convoluție).

- **Densitatea de repartiție a câtului** variabilelor X și Y ,notată $W=\frac{X}{Y}$

Considerăm transformarea $\begin{cases} u=\frac{x}{y} \\ v=y \end{cases}$, care admite inversa $\begin{cases} x=uv \\ y=v \end{cases}$, cu jacobianul $J=v$. Atunci $f(x,y)=f(uv,v)\cdot|v|$. Densitatea de repartiție a variabilei aleatoare $W=\frac{X}{Y}$ este repartiția marginală în raport cu $u=\frac{x}{y}$, adică: $\boxed{f_W(u)=\int_{-\infty}^{\infty} f(uv,v)\cdot|v|dv}$

Dacă X și Y sunt v.a. *indepedente,* cu densitățile de repartiție $f_X(x)$ și respectiv $f_Y(y)$, atunci:

$$\boxed{f_W(u)=\int_{-\infty}^{\infty} f_X(uv)\cdot f_Y(v)\cdot|v|\,dv}$$

Observație: Fie X o variabilă aleatoare de *tip discret*, cu repartiția: $\begin{pmatrix} x_i \\ p_i \end{pmatrix}$, $i\in\mathbb{N}$ și Y o variabilă aleatoare de *tip continuu*, cu densitatea de probabilitate $f(x)$. Densitatea de probabilitate a sumei $Z=X+Y$ este:

$$\boxed{f_Z(x)=\sum_{i=0}^{\infty} p_i\cdot f_Y(x-x_i)}$$

2. ȘIRURI DE V.A. TEOREMA LIMITĂ CENTRALĂ. LEGEA NUMERELOR MARI

2.1. ȘIRURI DE VARIABILE ALEATOARE. INEGALITATEA LUI CEBÂȘEV

Fie (Ω,K,P) un câmp de probabilitate, $(X_n)_{n\in\mathbb{N}^*}:\Omega\to\mathbb{R}$ un șir de variabile aleatoare și $X:\Omega\to\mathbb{R}$ o variabilă aleatoare. Deoarece variabilele aleatoare sunt funcții definite pe spațiul de selecție (cu proprietăți suplimentare), putem vorbi despre convergența punctuală a unui șir de variabile aleatoare $(X_n)_{n\in\mathbb{N}^*}$ către variabila aleatoare X, înțelegând prin aceasta că șirul numeric de variabile aleatoare $\{X_n(\omega)\}_{n\in\mathbb{N}^*}$, cu $\omega\in\Omega$, converge către $X(\omega)$.

2.1.1. Convergența în probabilitate

Șirul $(X_n)_{n\in\mathbb{N}^*}\xrightarrow{prob}X$ dacă pentru $\forall\varepsilon>0$, $\lim\limits_{n\to\infty}P(|X_n-X|<\varepsilon)=1$.

Formă echivalentă: $\lim\limits_{n\to\infty}P(|X_n-X|\geq\varepsilon)=0$

Observație:

Dacă $(X_n)\xrightarrow{prob}X$ și $(Y_n)\xrightarrow{prob}Y$, atunci : $(aX_n+bY_n)\xrightarrow{prob}aX+bY$, unde $a,b\in\mathbb{R}$ ct.

2.1.2. Convergența în repartiție

Convergența în repartiție mai este numită și convergența *slabă* (*en. weak*).

Șirul $(X_n)_{n\in\mathbb{N}^*}\xrightarrow{rep}X$ dacă în orice punct x de continuitate al funcției de repartiție F_X avem:

$$\lim_{n\to\infty}F_{X_n}(x)=F_X(x)$$

2.1.3. <u>Convergența aproape sigură</u>

Convergența aproape sigură mai este numită și convergența *tare* (*en. strong*).

Șirul $(X_n)_{n\in\mathbb{N}^*} \xrightarrow{a.s.} X$ dacă mulțimea evenimentelor în care $\{X_n(\omega)\}_{n\in\mathbb{N}^*}$ converge punctual la $X(\omega)$ formează un eveniment de probabilitate 1: $P\left(\omega \,\middle|\, \lim_{n\to\infty} X_n(\omega) = X(\omega)\right) = 1$.

2.1.4. <u>Convergența în medie</u>

Șirul $(X_n)_{n\in\mathbb{N}^*} \xrightarrow{r} X$ (converge în medie de ordinul r) dacă există momente absolute $M\left[|X_n|^r\right]$ și $M\left[|X|^r\right]$ și avem: $\lim_{n\to\infty} M\left[|X_n - X|^r\right] = 0$.

<u>Observație</u>: Dacă $r = 2$, convergența în medie de ordinul 2 se numește *convergență în medie pătratică*.

Legătura dintre tipurile de convergență poate fi schematizată astfel:

$$\begin{matrix}(X_n)_{n\in\mathbb{N}^*} \xrightarrow{a.s.} X \\ (X_n)_{n\in\mathbb{N}^*} \xrightarrow{r} X\end{matrix} \Rightarrow (X_n)_{n\in\mathbb{N}^*} \xrightarrow{prob} X \Rightarrow (X_n)_{n\in\mathbb{N}^*} \xrightarrow{rep} X$$

<u>Observație</u>: Conceptele de convergență aproape sigură și convergență în medie de ordin r nu pot fi comparate între ele, deoarece niciunul nu-l implică pe celălalt.

INEGALITATEA LUI CEBÂȘEV

Fiind dată o variabilă aleatoare, valorile ei pot avea un grad diferit de grupare / împrăștiere în jurul mediei. Inegalitatea lui Cebâșev dă o margine inferioară pentru probabilitatea ca abaterea absolută de la medie a unei variabile aleatoare cu dispersia cunoscută să fie mai mică decât un prag dat ε (evident, dacă media există).

<u>Enunț</u>: Fie X o variabilă aleatoare care admite medie şi dispersie finite (notate m și σ^2). Atunci, pentru orice $\varepsilon > 0$, are loc inegalitatea:

$$\boxed{P\left(\left\{|X - m| < \varepsilon\right\}\right) \geq 1 - \frac{\sigma^2}{\varepsilon^2}}$$

<u>Observații</u>:

1. Inegalitatea lui Cebâșev se poate exprima sub forma:"*Abaterea de la medie este puțin probabilă*".

2. Există şi o formă „complementară" pentru inegalitatea lui Cebâşev, şi anume:

$$P\left(\left\{|X - m| \geq \varepsilon\right\}\right) \leq \frac{\sigma^2}{\varepsilon^2}.$$

TEOREMA „ CELOR 3 SIGMA"

Ca o consecință directă a inegalității lui Cebâșev, pentru variabile aleatoare care au medie și dispersie finită, se poate formula următorul rezultat, cunoscut sub numele de "Teorema celor 3 sigma".

<u>Enunț</u>: Cu o probabilitate cuprinsă între $\frac{8}{9}$ şi 1, orice variabilă aleatoare ia valori cuprinse între $(m - 3\sigma, m + 3\sigma)$ (unde m este media valorilor variabilei şi σ este abaterea medie pătratică):

$$\boxed{P\left(m - 3\sigma < X < m + 3\sigma\right) \geq \frac{8}{9}}$$

2.2. TEOREMA LIMITĂ CENTRALĂ

Teorema Limită Centrală este un rezultat particular dintr-o problematică mai largă, și anume a studiului repartiției limită a sumelor de variabile aleatoare independente.

Acest rezultat teoretic este foarte important pentru fundamentarea aplicațiilor din statistica matematică.

Problema limită centrală constă în stabilirea condițiilor în care funcția de repartiție a unui șir de variabile aleatoare independente, cu dispersii finite și normate (cu media 0 și dispersia 1) converge către funcția de repartiție normală standard (funcția lui Laplace). Așadar, este vorba despre o convergență în repartiție.

Enunț (Liapunov): Fie $\left(X_n\right)_{n\in\mathbb{N}^*}$ un șir de variabile aleatoare independente, identic repartizate, cu media m și dispersia σ^2 (finită). Atunci, pentru $\forall x\in\mathbb{R}$:

$$\lim_{n\to\infty} P\left(\frac{\sum_{k=1}^{n} X_k - n\cdot m}{\sigma\sqrt{n}} < x\right) = \phi(x)$$

(Șirul $Y_n = \dfrac{\sum_{k=1}^{n} X_k - n\cdot m}{\sigma\sqrt{n}}$ converge în repartiție către o variabilă normală standard, unde

$\phi(x) = \dfrac{1}{\sqrt{2\pi}}\int_{-\infty}^{x} e^{-\frac{t^2}{2}}dt$ este funcția lui Laplace).

Observație: Dacă șirul $\left(X_n\right)_{n\in\mathbb{N}^*}$ converge în repartiție către X rezultă, din definiția acestui tip de convergență, că $P\left(X_n < x\right)\to P\left(X < x\right)$, în orice punct de continuitate al funcției de repartiție $F_X\left(x\right)$. De aici rezultă că pentru $a<b$ puncte de continuitate pentru $F_X\left(x\right)$, avem: $P\left(a\le X_n < b\right)\to P\left(a\le X < b\right)$. Astfel, Teorema Limită Centrală se poate scrie, pentru $a<b$:

$$\lim_{n\to\infty} P\left(a < \frac{\sum_{k=1}^{n} X_k - n\cdot m}{\sigma\sqrt{n}} < b\right) = \phi\left(b\right) - \phi\left(a\right)$$

sau, echivalent:

$$\lim_{n\to\infty} P\left(a < \sum_{k=1}^{n} X_k < b\right) = \phi\left(\frac{b-n\cdot m}{\sigma\sqrt{n}}\right) - \phi\left(\frac{a-n\cdot m}{\sigma\sqrt{n}}\right)$$

și se folosesc valorile tabelate ale funcției lui Laplace (repartiția normală standard, Tabelul A).

Teorema Moivre-Laplace

Reprezintă varianta particulară a Teoremei Limită Centrală, pentru un șir de variabile aleatoare independente, *repartizate Bernoulli*: $X = \begin{pmatrix} 1 & 0 \\ p & q \end{pmatrix}$, cu $p+q=1$, media $m=p$ și dispersia $\sigma^2 = pq$. În acest caz, forma Teoremei Limită Centrală este:

$$\lim_{n\to\infty} P\left(\left|\frac{\sum_{k=1}^{n} X_k - n\cdot p}{\sqrt{npq}}\right| < x\right) = \phi(x)$$

și reluând argumentația din observația de mai sus, avem formele echivalente:

$$\lim_{n\to\infty} P\left(a < \frac{\sum_{k=1}^{n} X_k - n\cdot p}{\sqrt{npq}} < b \right) = \phi(b) - \phi(a)$$

și $\lim_{n\to\infty} P\left(a < \sum_{k=1}^{n} X_k < b \right) = \phi\left(\frac{b - n\cdot p}{\sqrt{npq}} \right) - \phi\left(\frac{a - n\cdot p}{\sqrt{npq}} \right)$.

2.3. LEGEA NUMERELOR MARI (forma slabă)

Legătura dintre frecvența de apariție a unor evenimente și probabilitate, în contextul repetării unui experiment de un număr mare de ori, constituie elementul de bază al aplicațiilor practice ale teoriei probabilităților și statisticii inferențiale. Diversele rezultate privind această problemă fundamentală sunt cunoscute sub numele de variante ale Legii Numerelor Mari (en. Law of Large Numbers).

Aceste rezultate stabilesc diverse condiții privind existența unui șir de numere reale $(a_n)_{n\in\mathbb{N}^*}$ *și convergența unui șir de variabile aleatoare* $Y_n = \varphi_n(X_n)_{n\in\mathbb{N}^*}$ *către* $(a_n)_{n\in\mathbb{N}^*}$*. În mod frecvent, se consideră* $\varphi_n(X_n)_{n\in\mathbb{N}^*} = \frac{1}{n}\sum_{k=1}^{n} X_k$.

- Dacă există $(a_n)_{n\in\mathbb{N}^*}$ șir de numere reale astfel încât pentru $\forall \varepsilon > 0$ să avem: $P(|Y_n - a_n| < \varepsilon) = 1$

sau, pentru $\varphi_n(X_n)_{n\in\mathbb{N}^*} = \frac{1}{n}\sum_{k=1}^{n} X_k$: $\boxed{\frac{1}{n}\sum_{k=1}^{n} X_k - a_n \xrightarrow[n\to\infty]{prob.} 0}$, spunem că șirul $(X_n)_{n\in\mathbb{N}^*}$ satisface **legea slabă a numerelor mari** cu funcțiile $(\varphi_n)_{n\in\mathbb{N}^*}$.

- Dacă convergența are loc *aproape sigur (a.s.)*, spunem că șirul $(X_n)_{n\in\mathbb{N}^*}$ satisface **legea tare a numerelor mari**.

În continuare vom prezenta câteva rezultate teoretice în varianta slabă.

Forma generală:

Fie $(X_n)_{n\in\mathbb{N}^*}$ un șir de variabile aleatoare independente, *identic repartizate* (au aceeași medie m și aceeași dispersie σ^2, finite). Atunci, pentru $\forall \varepsilon > 0$ și $\forall \delta > 0$, există un număr natural $n_0(\varepsilon, \delta)$ astfel încât pentru $\forall n > n_0$ avem:

$$P\left(\left| \frac{1}{n}\sum_{k=0}^{n} X_k - m \right| \geq \varepsilon \right) < \delta \text{ sau, echivalent: } P\left(\left| \frac{1}{n}\sum_{k=0}^{n} X_k - m \right| < \varepsilon \right) > 1 - \delta .$$

Observație: Acest rezultat fundamentează teoretic procesul uzual de aproximare a mediei caracteristicii studiate a unei populații statistice prin media aritmetică a valorilor observate. Într-adevăr, dacă $X_1, X_2, ..., X_n$ sunt privite ca valori potențiale ale unei variabile aleatoare X obținute printr-un șir de probe independente, atunci teorema arată că *media aritmetică a acestora converge în probabilitate la media teoretică*.

Legea slabă a numerelor mari în forma Cebâșev

Fie $(X_n)_{n\in\mathbb{N}^*}$ un șir de variabile aleatoare independente, cu *dispersii finite*, *uniform mărginite* (există o constantă reală c astfel încât $\sigma^2(X_k) \leq c$ pentru $k = \overline{1,n}$). Atunci, pentru $\forall \varepsilon > 0$ avem:

$$\lim_{n\to\infty} P\left(\left|\frac{1}{n}\sum_{k=1}^{n} X_k - \frac{1}{n}\sum_{k=1}^{n} M\left[X_k\right]\right| < \varepsilon\right) = 1$$

Sau, într-o formulare echivalentă:

$$\lim_{n\to\infty} P\left(\left|\frac{1}{n}\sum_{k=1}^{n} X_k - \frac{1}{n}\sum_{k=1}^{n} M\left[X_k\right]\right| \geq \varepsilon\right) = 0$$

Legea slabă a numerelor mari în forma Bernoulli

Fie k numărul de apariții ale evenimentului A în n probe *independente* (ceea ce este echivalent cu a spune că frecvența relativă de apariție a evenimentului A este $\frac{k}{n}$) și $P(A) = p$. Atunci, pentru $\forall \varepsilon > 0$ avem:

$$\lim_{n\to\infty} P\left(\left|\frac{k}{n} - p\right| \leq \varepsilon\right) = 1$$

sau, echivalent: $\lim_{n\to\infty} P\left(\left|\frac{k}{n} - p\right| > \varepsilon\right) = 0$.

Observație: Această formă a Legii Numerelor Mari constituie justificarea teoretică a definiției în sens statisitic a probabilității (cu ajutorul frecvențelor relative). Enunțul poate fi reținut sub forma: "*frecvența relativă tinde în probabilitate la probabilitatea teoretică*".

- În legea slabă a numerelor mari în forma Bernoulli avem n variabile aleatoare identic repartizate Bernoulli: $X = \begin{pmatrix} 1 & 0 \\ p & q \end{pmatrix}$, cu $p + q = 1$. Media variabilei X este $M\left[X\right] = p$ iar dispersia este $D^2\left[X\right] = pq$. Se poate demonstra cu ușurință că $pq \leq \frac{1}{4}$, deci avem dispersii uniform mărginite și deci Teorema lui Bernoulli este o particularizare a legii slabe a numerelor mari în forma Cebâșev.

- În sensul enunțului general al Legii Numerelor Mari, pentru variabile Bernoulli avem:

$P\left(\left|\frac{k}{n} - p\right| \geq \varepsilon\right) < \delta$, și deoarece $\sigma^2 = pq \leq \frac{1}{4}$, alegem $\boxed{n_0(\varepsilon, \delta) > \frac{1}{4\delta\varepsilon^2}}$.

Cu ajutorul acestei relații *putem determina volumul unei selecții bernoulliene care să permită aplicarea Legii Numerelor Mari* .