CURS 5

STATISTICA INFERENȚIALĂ

1. POPULAȚIE STATISTICĂ, SELECȚIE, ESTIMATORI

Statistica este definită ca fiind știința care se ocupă cu culegerea, înregistrarea, gruparea, analiza și interpretarea datelor referitoare la un anumit fenomen precum și cu formularea unor previziuni privind comportarea viitoare a acestuia.

Statistica matematică este o ramură a matematicii care, folosind elemente și rezultate ale teoriei probabilităților, elaborează noțiunile și metodele specifice studiului statistic.

***Statistica inferențială** este acea ramură a statisticii matematice care se ocupă cu estimarea parametrilor și testarea ipotezelor statistice, pe baza unui set de date observate.*

În continuare vor fi prezentate noțiunile de bază și anumite aspecte teoretice fundamentale ale statisticii inferențiale.

1.1. DEFINIȚII, NOTAȚII

- Prin **populație statistică** (populație) se înțelege orice mulțime care formează obiectul unei analize statistice. Elementele unei populații statistice se numesc **indivizi sau unități statistice**.

- O trăsătură comună a tuturor indivizilor din populația statistică care ne interesează se numește **caracteristică**. Caracteristicile pot fi *cantitative* (înălțime, greutate, nota obținută la un examen, abscisa unui punct în plan, etc) sau *calitative* (culoarea ochilor, genul, apartenența etnică, etc). Caracteristicilor calitative li se asociază *coduri numerice* pentru a putea fi prelucrate statistic.

În continuare ne vom ocupa doar de caracteristici cantitative.

- Fie spațiul de probabilitate (Ω, K, P), unde Ω reprezintă populația statistică. Atunci caracteristica unei populații poate fi definită ca o *variabilă aleatoare* $X : \Omega \to \mathbb{R}$, discretă sau continuă (pentru caracteristici cantitative) și doar discretă (pentru caracteristici calitative).

- **Parametrii** sunt măsuri descriptive numerice ale caracteristicilor populației. Deoarece nu avem acces la întreaga populație, parametrii sunt necunoscuți și urmează a fi estimați pe baza datelor de selecție.
Parametrii caracteristicilor de interes pot fi: *parametri care descriu tendința centrală* (medie, momente), *parametri care descriu gradul de împrăștiere al datelor* (dispersie, abatere standard, coeficient de variație), *parametri de poziție* (cuantile), *parametri ce descriu forma* (aplatizarea sau asimetria), etc.

În majoritatea situațiilor practice, necesitatea de a obține informații relevante despre caracteristici ale unor populații mari (sau infinite) este dublată de imposibilitatea examinării fiecărui individ în parte. În aceste situații se alege o sub-populație (o submulțime a lui Ω) cu un număr finit și relativ mic de elemente și se înregistrează caracteristica dorită pentru această sub-populație (în continuare va fi numită "selecție"). Se pune problema: cât de bine este aproximată (estimată) caracterstica reală a populației de către caracteristica măsurată în sub-populație ?

Răspunsul la această întrebare depinde de modul în care este făcută selecția, de volumul acesteia și de teoria statistică folosită pentru inferență.

- *Există numeroase tehnici de selecție – numite tehnici de eșantionare – și care asigură reprezentativitatea selecției la nivelul populației, adică reproducerea într-o manieră cât mai fidelă a valorilor caracteristicilor populației.*
- *Un volum al selecției mai mare (de minim 30 de date observate) asigură o mai bună inferență decât un volum mai mic.*

1.2. SELECȚII, STATISTICI

- O mulțime de n observații independente asupra unei caracteristici X a unei populații statistice Ω, care au valorile $x_1, x_2, ..., x_n$ se numește **selecție** de volum n. Fiecărei date observate x_i i se poate asocia o variabilă aleatoare X_i, astfel încât x_i devine o posibilă valoare a variabilei X_i.
- Variabilele aleatoare $X_1, X_2, ..., X_n$ se numesc **variabile aleatoare de selecție** și pot fi interpretate ca fiind un set de observații independente asupra variabilei X (caracteristica populației). Toate aceste variabile de selecție sunt identic repartizate, repartiția comună fiind repartiția variabilei X.

În concluzie, X_i este o observație a variabilei X iar x_i este valoarea corespunzătoare observată.

- Se numește **statistică** (sau **funcție de selecție**) o funcție de variabilele aleatoare de selecție, adică o variabilă aleatoare de forma:

$$S_n(X) = u(X_1, X_2, ..., X_n)$$

unde u este o funcție (măsurabilă) $u : \mathbb{R}^n \to \mathbb{R}$.

Alte notații uzuale pentru statistici: $S(X, n)$, $S(X_1, X_2, ..., X_n)$

- Repartiția unei statistici se mai numește și **repartiția (distribuția) de selecție** iar valoarea numerică $S_n(x) = u(x_1, x_2, ..., x_n)$ se numește **valoarea funcției de selecție** pentru un set dat de observații $x_1, x_2, ..., x_n$.
- Repartiția unei statistici poate fi *exactă* (repartiția care se poate determina pentru orice volum al selecției) sau *asimptotică* (repartiția limită a lui $S_n(X)$, pentru $n \to \infty$).

Observații:

1. Dacă se lucrează cu selecții de volum redus ($n < 30$), atunci repartiția exactă trebuie să fie cunoscută apriori, dacă urmează a se lua decizii prin inferență; Utilizarea repartiției asimptotice conduce la obținerea unor rezultate inferențiale bune doar dacă volumul de selecție este mare (cel puțin $n \geq 30$).

2. Teoria probabilităților oferă posibilitatea determinării atât a repartiției exacte cât și a repartiției asimptotice a unei statistici $S_n(X)$, iar cu ajutorul acesteia putem trage concluzii despre populația din care a provenit eșantionul observat (inferența statistică).

Unde se folosesc statisticile?

- *În probleme de estimare punctuală a parametrilor populației;*
- *În obținerea intervalelor de încredere pentru un parametru necunoscut;*
- *Pentru verificarea ipotezelor statistice, ca o statistică-test.*

1.3. EXEMPLE DE STATISTICI

***Media de selecție**: Se numește **medie de selecție** (de volum n), statistica $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$. Valoarea mediei de selecție pentru valori ale variabilelor aleatoare X_i este **media empirică**: $\overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$.*

***Dispersia de selecție** (varianța selecției): Se numește **dispersie de selecție** (de volum n), statistica $S_X^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^2$. Valoarea dispersiei de selecție pentru valori ale variabilelor aleatoare X_i este **dispersia empirică**: $s_X^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(x_i - \overline{x}\right)^2$.*

Observație: Statistica definită mai sus se mai numește și *dispersia de selecție corectată*, atunci când dispersia de selecție este definită prin formula: $S_*^2 = \frac{1}{n}\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^2$ *. Motivul pentru care NU se lucrează cu* S_*^2 *este că* S_X^2 *estimează mai bine dispersia teoretică* $D^2\left[X\right]$ *(*S_X^2 *este un estimator nedeplasat al dispersiei teoretice, pe când* S_*^2 *este un estimator deplasat).*

Pentru selecții de volum mare, se pot folosi oricare dintre cele două formule (S_X^2 sau S_*^2) deoarece diferența dintre valorile obținute pentru dispersia de selecție este neglijabilă.

1.4. ESTIMATORI

Una dintre problemele centrale ale statisticii matematice inferențiale o reprezintă *estimarea parametrilor unei populații*. Considerăm o populație statistică Ω, de volum N (finit sau infinit) și o caracteristică a sa, reprezentată de variabila aleatoare X. Pe baza unei selecții de volum $n \ll N$ dorim să estimăm diverși parametri ai caracteristicii X (cei mai comuni parametri care se doresc a fi estimați sunt *media* și *dispersia* lui X).

Estimatorii folosiți în statistica matematică se clasifică în:

- *Estimatori punctuali* – se determină o estimare a parametrului de interes din populație, pe baza valorii parametrului respectiv din selecție;
- *Estimatori sub formă de interval* – se determină un interval de apartenență pentru parametrul de interes.

Generic, un parametru care urmează a fi estimat se notează cu θ.

Estimatorii sub formă de interval sunt cunoscuți sub denumirea de *intervale de încredere*. Aceștia sunt prezentați în continuare.

2. INTERVALE DE ÎNCREDERE

Determinarea unui interval de încredere pentru parametrul θ care apare în legea de repartiție $f\left(x,\theta\right)$ a variabilei aleatoare X (caracteristica de interes din populație), se bazează pe construirea unei statistici (funcție de selecție).

Pentru a putea determina efectiv intervalul de încredere se fac anumite ipoteze suplimentare asupra *funcției de repartiție* a statisticii construite – cea mai des folosită este ipoteza conform căreia funcția de repartiție a statisticii nu depinde de parametrul de estimat.

Considerăm spațiul de probabilitate $\left(\Omega, K, P\right)$, unde Ω reprezintă populația statistică și o caracteristică de interes reprezentată de variabila aleatoare $X : \Omega \to \mathbb{R}$. Fie θ parametrul variabilei X pe care vrem să-l estimăm pe baza unei selecții de volum n.

2.1. Interval de încredere, nivel de încredere

Presupunem că pe baza selecției putem determina două funcții de selecție (statistici) $\theta_1(X_1, X_2, ..., X_n)$ și $\theta_2(X_1, X_2, ..., X_n)$ și $\alpha \in \left(0,1\right)$ astfel încât:

$$P\left(\theta_1\left(X_1, X_2, ..., X_n\right) \le \theta \le \theta_2\left(X_1, X_2, ..., X_n\right)\right) = 1 - \alpha$$

este independentă de θ.

▪ În acest caz, spunem că intervalul $[\theta_1, \theta_2] \subset \mathbb{R}$ este **interval de încredere de nivel** $1-\alpha$ pentru parametrul θ. Valoarea α se numește *nivel de semnificație* sau *prag de semnificație*.

Observații:

- *Intervalul de încredere diferă de la o selecție la alta* – deoarece valorile de selecție, pe baza cărora se calculează valorile statisticilor, diferă.
- *Intervalul de încredere depinde de volumul selecției și de eroarea standard*:
  - cu cât volumul selecției este mai mic, cu atât intervalul de încredere este mai larg;
  - cu cât eroarea standard este mai mare, cu atât intervalul de încredere este mai larg.
- În științele inginerești (și nu numai), nivelul intervalului de încredere se specifică procentual. De exemplu, pentru un interval de încredere de nivel 0.95 se folosește specificația 95%. Această specificare este utilă pentru interpretarea intervalului de încredere(varianta corectă).

Interpretarea intervalului de încredere:

Varianta incorectă, deși foarte uzuală: "intervalul de încredere este intervalul în care, cu o probabilitate dată ($1-\alpha$, de obicei 0.95) se află valoarea adevărată a parametrului θ (media, dispersia, etc).

Varianta corectă: Considerând selecții repetate, în $100 \cdot (1-\alpha)\%$ din cazuri valoarea parametrului θ se va afla în intervalul de încredere stabilit pe baza unei singure selecții.

Cum se determină efectiv un interval de încredere?

1. Se stabilește nivelul de încredere α;
2. Se alege o funcție de selecție care să depindă și de parametrul θ, $U(X_1, X_2, ..., X_n, \theta)$, *a cărei funcție de repartiție să NU depindă de* θ;
3. Se folosește densitatea de repartiție a funcției de selecție, $f_U(x)$ și două valori particulare u_1, u_2 pentru a scrie:

$$P(u_1 \le U \le u_2) = \int_{u_1}^{u_2} f_U(x)\,dx = 1-\alpha$$

4. Există o infinitate de valori u_1, u_2 care satisfac relația $\int_{u_1}^{u_2} f_U(x)\,dx = 1-\alpha$; Prin metode specifice (de exemplu folosind multiplicatorii lui Lagrange) se determină acele valori pentru care lungimea intervalului $[u_1, u_2]$ este minimă.

2.2. Cuantile

Fie o variabilă aleatoare X cu funcția de repartiție $F(x)$. Pentru un $\alpha \in (0,1)$, definim **cuantila de ordin** α (sau α -**cuantilă**) acea valoare $c_\alpha \in \mathbb{R}$ pentru care:

$$F(c_\alpha) = P(X < c_\alpha) = \alpha$$

Întotdeauna sunt cunoscute α și repartiția variabilei X, iar valoarea lui c_α se determină din tabelele cu valorile funcției de repartiție F (pentru variabile aleatoare continue).

Observație: Pentru variabile aleatoare discrete, ecuația $F(c_\alpha)=\alpha$ nu are soluție pentru orice α. Dacă există o soluție, atunci există o infinitate de soluții, și anume intervalul ce separă două valori consecutive ale variabilei discrete.

- Notații pentru α-cuantile în funcție de repartiția F (variabile aleatoare continue):
  - z_α pentru repartiția normală standard $N(0,1)$ (Tabelul A);
  - $t_\alpha(n)$ pentru repartiția Student $t(n)$ (Tabelul B).
  - $\chi^2_\alpha(n)$ pentru repartiția Chi-pătrat $\chi^2(n)$ (Tabelul C);
- ***Pentru repartiția normală standard*** (și prin extensie și pentru repartiția Student), cuantila de ordin α (notată z_α) se definește cu ajutorul funcției lui Laplace $\Phi(x)$:

$$P(X<z_\alpha)=F_X(z_\alpha)=\Phi(z_\alpha)=\alpha$$

În Tabelul A se găsesc valorile α-cuantilelor pentru repartiția normală standard, $\Phi(x)$, pentru $\alpha\in[0.5,1)$, adică pentru $z_\alpha\geq 0$. Datorită simetriei funcției $\Phi(x)$, celelalte α-cuantile se determină folosind proprietatea:

$$\Phi(z_\alpha)+\Phi(-z_\alpha)=1$$

- ***Pentru repartiția Student***, care este simetrică, α-cuantilele verifică proprietatea: $F(t_\alpha)+F(-t_\alpha)=1$, unde F este funcția de repartiție, cu valori tabelate.
- ***Pentru repartiția Chi-pătrat*** - valorile cuantilelor se citesc direct din Tabelul C, gradele de libertate fiind trecute pe prima coloană. Deoarece repartiția $\chi^2(n)$ nu este simetrică, nu există legături între cuantile, ca la repartițiile Student sau normală standard.

Formule echivalente de calcul pentru volumul selecției $n\geq 30$:

$$\boxed{\chi^2_\alpha(n)\cong\frac{1}{2}\left(z_\alpha+\sqrt{2n-1}\right)} \text{ și } \boxed{t_\alpha(n)\cong z_\alpha\cdot\sqrt{\frac{n}{n-2}}}$$

2.3. INTERVALE DE ÎNCREDERE PENTRU PARAMETRII REPARTIȚIEI NORMALE

Fie Ω o populație statistică cu o caracteristică de interes reprezentată prin variabila aleatoare repartizată normal $X\in\mathcal{N}(m,\sigma)$. Considerăm o selecție $x_1,x_2,...,x_n$, de volum $n\geq 30$ și notăm cu $\overline{x}$ media de selecție și cu s^2 dispersia de selecție. Pentru media de selecție se folosește estimatorul nedeplasat $\overline{x}=\frac{1}{n}\sum_{i=1}^{n}x_i$ iar pentru dispersia de selecție se folosește estimatorul *absolut corect* $s^2=\frac{1}{n-1}\sum_{i=1}^{n}(x_i-\overline{x})^2$. Considerăm cunoscut (ales) nivelul de semnificație α.

2.3.1. Intervale de încredere pentru medie

2.3.1.1. Intervalul de încredere pentru parametrul m când σ este cunoscut

Se consideră statistica $U\left(x_1,x_2,...,x_n,m\right)=\dfrac{\overline{x}-m}{\sigma}\sqrt{n}$ (abaterea normată a mediei de selecție), care are repartiție normală standard $U\in\mathcal{N}\left(0,1\right)$. Pentru nivelul de semnificație α stabilit, există valorile z_1 și z_2 (notații clasice pentru repartiția normală standard) astfel încât:

$$P\left(z_1\le U\le z_2\right)=\int_{z_1}^{z_2}f_U\left(x\right)dx=1-\alpha=\phi\left(z_2\right)-\phi\left(z_1\right).$$

Ecuația $1-\alpha=\phi\left(z_2\right)-\phi\left(z_1\right)$ are o infinitate de soluții pentru un $\alpha\in\left(0,1\right)$ fixat. Se determină valorile z_1 și z_2 pentru care lungimea intervalului $\left[z_1,z_2\right]$ este minimă (este o problemă de extrem condiționat – nu intrăm în detalii). Se obține intervalul de încredere pentru m când σ este cunoscut:

$$\boxed{I=\left(\overline{x}-\frac{\sigma}{\sqrt{n}}\cdot z_{1-\frac{\alpha}{2}}\ ,\ \overline{x}+\frac{\sigma}{\sqrt{n}}\cdot z_{1-\frac{\alpha}{2}}\right)},$$

unde $z_{1-\frac{\alpha}{2}}$ este cuantila de ordin $1-\dfrac{\alpha}{2}$ a repartiței $\mathcal{N}\left(0,1\right)$ (Tabelul A).

2.3.1.2. Intervalul de încredere pentru parametrul m când σ este necunoscut

Intervalul de încredere pentru m când σ este necunoscut:

$$\boxed{I=\left(\overline{x}-\sqrt{\frac{s^2}{n}}\cdot t_{1-\frac{\alpha}{2}}\left(n-1\right)\ ,\ \overline{x}+\sqrt{\frac{s^2}{n}}\cdot t_{1-\frac{\alpha}{2}}\left(n-1\right)\right)}$$

unde $t_{1-\frac{\alpha}{2}}\left(n-1\right)$ este cuantila de ordin $1-\dfrac{\alpha}{2}$ a rep. Student, pentru $n-1$ grade de libertate (Tabelul B).

2.3.2. Intervalul de încredere pentru parametrul σ^2

Intervalul de încredere pentru σ^2 :

$$I=\left(\frac{n-1}{\chi^2_{1-\frac{\alpha}{2}}(n-1)}\cdot s^2\ ,\ \frac{n-1}{\chi^2_{\frac{\alpha}{2}}(n-1)}\cdot s^2\right)$$

Unde $\chi^2_{\frac{\alpha}{2}}\left(n-1\right)$ și $\chi^2_{1-\frac{\alpha}{2}}\left(n-1\right)$ sunt cuantilele de ordin $\dfrac{\alpha}{2}$ și respectiv $1-\dfrac{\alpha}{2}$ ale repartiței Chi-pătrat, pentru $n-1$ grade de libertate (Tabelul C).

2.4. INTERVALE DE ÎNCREDERE PENTRU PARAMETRII ALTOR REPARTIȚII

Dacă volumul selecției este mare, intervalele de încredere pentru media repartiției normale $\mathcal{N}\left(m,\sigma\right)$ *sunt valabile și pentru o variabilă aleatoare care NU urmează repartiția normală, în virtutea Teoremei Limită Centrală*.

În general, pentru alte repartiții în afara celei normale, este dificil să se stabilească o statistică potrivită și să i se determine funcția de repartiție. Dacă volumul de selecție este mare, se poate determina *repartiția asimptotică* a statisticii care conține parametrul necunoscut, folosindu-se diverse metode (printre care și metoda verosimilității maxime asociată cu Legea Numerelor Mari). Nu intrăm în detalii.

Vom prezenta în continuare intervalele de încredere pentru parametrii repartițiilor *exponențială, binomială și Poisson*, datorită aplicabilității mari a acestor repartiții în diverse domenii (și în special în științele inginerești).

Considerăm o selecție de volum n *și notăm variabilele aleatoare de selecție* $X_1, X_2, ..., X_n$*, cu valorile observate* $x_1, x_2, ..., x_n$ *și considerăm cunoscut (ales) nivelul de semnificație* α *.*

2.4.1. Intervalul de încredere pentru media repartiției exponențiale

Considerăm o caracteristică de interes reprezentată printr-o variabilă aleatoare X cu repartiţie exponenţială de parametru necunoscut $\lambda > 0$. Densitatea de repartiție a variabilei aleatoare X este: $f(x) = \begin{cases} \lambda \cdot e^{-\lambda \cdot x} & , \quad x \geq 0 \\ 0 & , \quad x < 0 \end{cases}$ iar media variabilei este $M[X] = \frac{1}{\lambda}$ (”*durata medie de funcționare*”).

Intervalul de încredere pentru medie este :

$$I = \left(\frac{2}{\chi^2_{1-\frac{\alpha}{2}}(2n)} \cdot \sum_{k=1}^{n} x_k \ , \ \frac{2}{\chi^2_{\frac{\alpha}{2}}(2n)} \cdot \sum_{k=1}^{n} x_k \right)$$

Unde $\chi^2_{\frac{\alpha}{2}}(2n)$ și $\chi^2_{1-\frac{\alpha}{2}}(2n)$ sunt cuantilele de ordin $\frac{\alpha}{2}$ și respectiv $1-\frac{\alpha}{2}$ ale repartiței Chi-pătrat, pentru $2n$ grade de libertate (Tabelul C).

2.4.2. Intervalul de încredere pentru parametrul repartiției Bernoulli

Considerăm o caracteristică de interes reprezentată printr-o variabilă aleatoare X cu repartiţie Bernoulli , *de parametru (necunoscut)* $\theta = p$ care are tabloul de repartiție:

$$X = \begin{pmatrix} 0 & 1 \\ 1-p & p \end{pmatrix}, \text{ cu } M[X] = p$$

Fie $\hat{p} = \frac{1}{n} \sum_{i=1}^{n} x_i = \frac{k}{n}$ (frecvența relativă, estimație a lui p din selecția de volum n). Atunci intervalul de încredere pentru $\theta = p$ este:

$$\boxed{I = \left(\hat{p} - z_{1-\frac{\alpha}{2}} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \ , \ \hat{p} + z_{1-\frac{\alpha}{2}} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right)}$$

unde $z_{1-\frac{\alpha}{2}}$ este cuantila de ordin $1-\frac{\alpha}{2}$ a repartiței $\mathcal{N}(0,1)$ (Tabelul A).

2.4.3. Intervalul de încredere pentru parametrul repartiției Poisson

Considerăm o caracteristică de interes reprezentată printr-o variabilă aleatoare X cu repartiţie Poisson, *de parametru (necunoscut)* $\theta = \lambda$ care are tabloul de repartiție: $X = \begin{pmatrix} k \\ e^{-\lambda}\dfrac{\lambda^k}{k!} \end{pmatrix}$, $k \in \mathbb{N}$ şi $\lambda > 0$ și $M[X] = \lambda$. Fie $\overline{x} = \dfrac{1}{n}\sum_{i=1}^{n} x_i$ media de selecție. Atunci intervalul de încredere pentru $\theta = \lambda$ este:

$$\boxed{I = \left(\overline{x} - z_{1-\frac{\alpha}{2}} \cdot \sqrt{\frac{\overline{x}}{n}} \ , \ \overline{x} + z_{1-\frac{\alpha}{2}} \cdot \sqrt{\frac{\overline{x}}{n}} \right)}$$

unde $z_{1-\frac{\alpha}{2}}$ este cuantila de ordin $1-\dfrac{\alpha}{2}$ a repartiței $\mathcal{N}(0,1)$ (Tabelul A).

3. IPOTEZE STATISTICE. TESTE PARAMETRICE

Una din problemele esenţiale ale statisticii este aceea de a decide asupra unor ipoteze care se nasc în mod natural din examinarea datelor avute la dispozitie sau a indicatorilor statistici care le caracterizează.

În statistică, orice afirmaţie este mai mult sau mai puţin plauzibilă, şi nu neapărat adevărată sau falsă.

- O **ipoteză statistică** este o supoziție cu privire la repartiția uneia sau a mai multor variabile din populația statistică studiată sau asupra valorilor unor parametri ai unei repartiții date (cunoscute).

- O ipoteză statistică se verifică pe baza unei selecții de volum n și cu ajutorul unui *test specific*, pe baza căruia se poate accepta sau respinge, *cu o anumită probabilitate*, ipoteza formulată.

- Validarea unei ipoteze statistice presupune formularea a două ipoteze ”de lucru”, numite **ipoteza de nul** (notată H_0) și **ipoteza alternativă** (notată H_1) și luarea unei decizii, pe baza unui test statistic, asupra acceptării sau respingerii ipotezei de nul.

Ipoteza de nul şi ipoteza alternativă

- Ipoteza de nul enunţă că nu există nicio diferenţă între parametrii studiați sau că nu există nicio diferență între repartițiile supuse testării (se specifică cu ”=”).

- Ipoteza alternativă enunţă că există o diferenţă sau o relaţie (specificată, în funcție de analiza teoretică a problemei, ca ”$\neq$”, ”$<$” sau ”$>$”).

Cele două ipoteze *nu sunt complementare*, în sensul că formularea lor nu acoperă în mod necesar întreg domeniul de valori al parametrului. De exemplu, dacă se face o ipoteză statistică asupra mediei unei variabile aleatoare și se formulează ipoteza de nul H_0: $m = 5$ și ipoteza alternativă H_1: $m < 5$, nu înseamnă că, pentru o anumită selecție, nu putem obține o valoare a mediei mai mare ca 5.

- Probabilitatea maximă cu care este respinsă ipoteza H_0 se numește **nivel de semnificație** și se notează, în general, cu α. Cele mai uzuale nivele de semnificație sunt $\alpha = 0.05$ și $\alpha = 0.001$, dar se mai folosesc și valori precum 0.1, 0.025 sau 0.005.

Nivelurile de semnificație sunt strâns legate de noțiunea de cuantilă, eroare statistică de tipul I și p-value.

Tipuri de eroare şi puterea unui test

Există două tipuri de erori posibile la efectuarea unei analize statistice.

- **Eroarea de tipul I**, cunoscută de asemenea ca "*fals pozitiv*", este eroarea care constă în respingerea unei ipoteze nule când este adevărată. Altfel spus, concluzionăm că există o diferenţă, când de fapt nu există nicio diferenţă.

- **Eroarea de tipul II**, cunoscută de asemenea ca "*fals negativ*", este eroarea care constă în nerespingerea unei ipoteze nule când nu este adevărată. Altfel spus, nu concluzionăm că există o diferenţă când de fapt o astfel de diferenţă există.

Erori de tipul I și de tipul II

Situația reală	Concluzia testului	Decizie	Eroare
H_0 este adevărată	Acceptăm H_0	Decizie corectă	
H_0 este adevărată	Respingem H_0	Decizie falsă	Eroare tip I
H_0 este falsă	Acceptăm H_0	Decizie falsă	Eroare tip II
H_0 este falsă	Respingem H_0	Decizie corectă	

Notații:

$$\alpha = P\left(Eroare\ de\ tip\ I\right) = P\left(resping\ H_0 \middle| H_0 = adev\right)$$

$$\beta = P\left(Eroare\ de\ tip\ II\right) = P\left(accept\ H_0 \middle| H_1 = adev\right)$$

- **Puterea unui test** este probabilitatea respingerii în mod corect a unei ipoteze nule atunci când ea este falsă. Această probabilitate este invers proporţională cu probabilitatea apariţiei unei erori de tipul II (nerespingerea ipotezei nule atunci când aceasta este falsă).

Există diferite metode matematice prin care se poate stabili puterea unui test, dar acest lucru nu este posibil pentru orice test. Nu intrăm în detalii.

Semnificaţie statistică și p-value

- **Semnificaţia statistică** a unui rezultat este *probabilitatea* cu care relaţia sau diferenţa observată între parametri sau între repartiții, pe baza unei selecții, există în populaţia din care s-a făcut selecția.

- Semnificaţia este exprimată cu ajutorul "**valorii p**" (se folosește uzual termenul din engleză, ***p-value***) care reprezintă probabilitatea de a face o eroare de tipul I. Un rezultat al unui test este considerat **semnificativ statistic** (adică există diferențe între parametri sau repartiții, care nu sunt întâmplătoare, deci se respinge ipoteza de nul) dacă $p\ value < \alpha$, unde α este nivelul de semnificație al testului folosit.

Pentru variabile continue, p-value reprezentă aria din dreapta valorii de test . Este dificil să se calculeze "cu mâna", dar majoritatea soft-urilor statistice o calculează și o afișează.

3.1. TESTE PARAMETRICE

Considerăm populația Ω și o caracteristică de interes reprezentată prin variabila aleatoare X. Presupunem că se cunoaște forma repartiției teoretice a lui X. În acest caz, ipotezele statistice care trebuie verificate (testate) se referă la *parametrii* acestei repartiții iar testele folosite în acest scop se numesc, generic, **teste parametrice**.

Fie $x_1, x_2, ..., x_n$ o selecție empirică de volum n pentru o v.a. X, o statistică $u = u(x_1, x_2, ..., x_n)$ cu repartiție cunoscută, pentru care valorile funcției de repartiție sunt tabelate sau foarte ușor de calculat și θ parametrul de interes al variabilei aleatoare X.

Testarea ipotezelor parametrice presupune parcurgerea următoarelor etape:

1) *Formularea ipotezei de nul și a celei alternative:*

- Ipoteza nulă: $H_0 : \theta = \theta_0$ (θ_0 este o valoare dată, de testare)
- Ipoteza alternativă – poate fi:
  - unilaterală: $H_1 : \theta < \theta_0$ sau $H_1 : \theta > \theta_0$
  - bilaterală: $H_1 : \theta \neq \theta_0$

2) *Stabilirea nivelului de semnificație* α ;

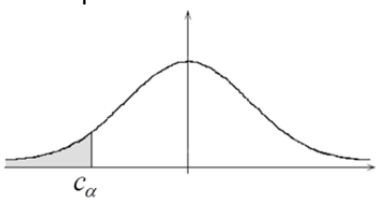
3) *Definirea statisticii* $u = u(x_1, x_2, ..., x_n)$ și precizarea repartiției sale $F(u)$;

4) *Calcularea valorilor critice (ca soluții ale ecuației* $F(c) = \alpha$), notate $c_\alpha, c_{1-\alpha}, c_{\frac{\alpha}{2}}, c_{1-\frac{\alpha}{2}}$ și care reprezintă cuantilele repartiției $F(u)$ în ipoteza H_0 :

- c_α (soluție a ecuației $F(c_\alpha) = \alpha$), pentru $H_1 : \theta < \theta_0$;
- $c_{1-\alpha}$ (soluție a ecuației $F(c_{1-\alpha}) = 1-\alpha$), pentru $H_1 : \theta > \theta_0$;
- $c_{\frac{\alpha}{2}}$ și $c_{1-\frac{\alpha}{2}}$ (soluții ale ecuațiilor $F\left(c_{\frac{\alpha}{2}}\right) = \frac{\alpha}{2}$ și respectiv $F\left(c_{1-\frac{\alpha}{2}}\right) = 1-\frac{\alpha}{2}$), pentru $H_1 : \theta \neq \theta_0$.

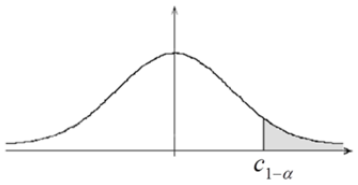
Valorile critice împart mulțimea valorilor statisticii în două regiuni: regiunea critică (de respingere a ipotezei de nul H_0 *sau altfel spus, de acceptare a ipotezei alternative* H_1*) și regiunea ne-critică (de acceptare a ipotezei de nul).*

5) În funcție de ipoteza alternativă H_1 și de valoarea critică calculată, regiunile critice (notate R_{cr}) pot fi:



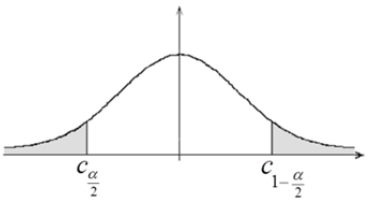
pentru un test unilateral stânga ($H_1 : \theta < \theta_0$):

$$R_{cr} = \{u \,|\, u < c_\alpha\}$$



pentru un test unilateral dreapta ($H_1 : \theta > \theta_0$):

$$R_{cr} = \{u \,|\, u > c_{1-\alpha}\}$$



pentru un test bilateral ($H_1 : \theta \neq \theta_0$):

$$R_{cr} = \left\{u \,\middle|\, u < c_{\frac{\alpha}{2}}\right\} \cup \left\{u \,\middle|\, u > c_{1-\frac{\alpha}{2}}\right\}$$

6) *Se calculează valoarea numerică a statisticii de test, folosind datele din selecție (se notează în general cu* u_{calc}*) și se compară cu valoarea corespunzătoare a cuantilei ce definește regiunea critică;*

7) Se respinge ipoteza H_0 dacă $u_{calc} \in R_{cr}$.

În continuare sunt prezentate principalele teste parametrice folosite în statistica inferențială – pentru verificarea ipotezelor statistice asupra parametrilor repartiției normale (media și dispersia) și pentru repartiția binomială (testul pentru proporții).

Pentru selecții de volum mare ($n > 100$ sau chiar mai mare), *aceste teste se pot folosi indiferent de repartiția variabilei aleatoare* care reprezintă caracteristica de interes.

3.2. TESTE PENTRU VERIFICAREA IPOTEZELOR REFERITOARE LA MEDIA ȘI DISPERSIA UNEI VARIABILE ALEATOARE NORMALE

Fie Ω o populație statistică cu o caracteristică de interes reprezentată prin variabila aleatoare repartizată normal $X \in \mathcal{N}(m,\sigma)$. Considerăm o selecție $x_1, x_2, ..., x_n$, de volum $n \geq 30$ și notăm cu $\overline{x}$ media de selecție și cu s^2 dispersia de selecție.

Pentru media de selecție se folosește estimatorul nedeplasat $\overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$ iar pentru dispersia de selecție se folosește estimatorul *absolut corect* $s^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(x_i - \overline{x}\right)^2$. Considerăm cunoscut (ales) nivelul de semnificație α.

3.2.1. Testul z pentru medie (dispersia σ^2 este cunoscută)

Ipoteza de nul $H_0: m = m_0$ (m_0 este o valoare dată, cunoscută);

Ipotezele alternative $H_1: m \neq m_0$ (bilaterală) sau $H_1: m > m_0$ sau $H_1: m < m_0$;

Se folosește statistica: $\boxed{z = \frac{\overline{x} - m_0}{\frac{\sigma}{\sqrt{n}}} \in \mathcal{N}(0,1)}$

Regiunea critică pentru ipoteza alternativă $H_1: m \neq m_0$ (bilaterală):

$$R_{cr} = \left\{ z \middle| z < z_{\frac{\alpha}{2}} \right\} \cup \left\{ z \middle| z > z_{1-\frac{\alpha}{2}} \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: m > m_0$ (unilaterală dreapta):

$$R_{cr} = \left\{ z \middle| z > z_{1-\alpha} \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: m < m_0$ (unilaterală stânga):

$$R_{cr} = \left\{ z \middle| z < z_{\alpha} \right\}$$

3.2.2. Testul t pentru medie (dispersia σ^2 este necunoscută)

Ipoteza de nul $H_0: m = m_0$ (m_0 este o valoare dată, cunoscută);

Ipotezele alternative $H_1: m \neq m_0$ (bilaterală) sau $H_1: m > m_0$ sau $H_1: m < m_0$;

Se folosește statistica: $\boxed{t = \frac{\overline{x} - m_0}{\frac{s}{\sqrt{n}}}}$ care este repartizată Student cu $n-1$ grade de libertate (repartiția Student este notată $t\left(n-1\right)$).

Regiunea critică pentru ipoteza alternativă $H_1: m \neq m_0$ (bilaterală):

$$R_{cr} = \left\{ t \middle| t < t_{\frac{\alpha}{2}}(n-1) \right\} \cup \left\{ t \middle| t > t_{1-\frac{\alpha}{2}}(n-1) \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: m > m_0$ (unilaterală dreapta):

$$R_{cr} = \left\{ t \middle| t > t_{1-\alpha}(n-1) \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: m < m_0$ (unilaterală stânga):

$$R_{cr} = \left\{ t \middle| t < t_{\alpha}(n-1) \right\}$$

3.2.3. Testul χ^2 pentru dispersie

Ipoteza de nul $H_0: \sigma^2 = \sigma_0^2$ (σ_0^2 este o valoare dată, cunoscută);

Ipotezele alternative $H_1: \sigma^2 \neq \sigma_0^2$ (bilaterală) sau $H_1: \sigma^2 > \sigma_0^2$ sau $H_1: \sigma^2 < \sigma_0^2$;

Se folosește statistica: $\boxed{v = \frac{n-1}{\sigma_0^2} s^2}$ care este repartizată χ^2 cu $n-1$ grade de libertate (repartiția Chi-pătrat este notată $\chi^2(n-1)$).

Regiunea critică pentru ipoteza alternativă $H_1: \sigma^2 \neq \sigma_0^2$ (bilaterală):

$$R_{cr} = \left\{ v \middle| v < \chi^2_{\frac{\alpha}{2}}(n-1) \right\} \cup \left\{ v \middle| v > \chi^2_{1-\frac{\alpha}{2}}(n-1) \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: \sigma^2 > \sigma_0^2$ (unilaterală dreapta):

$$R_{cr} = \left\{ v \middle| v > \chi^2_{1-\alpha}(n-1) \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: \sigma^2 < \sigma_0^2$ (unilaterală stânga):

$$R_{cr} = \left\{ v \middle| v < \chi^2_{\alpha}(n-1) \right\}$$

3.3. TESTE PENTRU VERIFICAREA IPOTEZELOR REFERITOARE LA MEDIILE ȘI DISPERSIILE A DOUĂ VARIABILE ALEATOARE NORMALE

Ipotezele statistice asupra parametrilor repartiției normale pot fi formulate și pentru *două caracteristici diferite*, repartizate normal, ale populației.

Fie Ω o populație statistică cu două caracteristici de interes, reprezentate prin variabilele aleatoare normale independente $X_1 \in \mathcal{N}(m_1, \sigma_1)$ și $X_2 \in \mathcal{N}(m_2, \sigma_2)$. Considerăm două selecții corespunzătoare celor două caracteristici, $x_{11}, x_{12}, ..., x_{1n_1}$ și $x_{21}, x_{22}, ..., x_{2n_2}$ (de volum $n_1 \geq 30$ și $n_2 \geq 30$); Notăm cu $\overline{x}_1$ și $\overline{x}_2$ mediile de selecție și cu s_1^2 și respectiv s_2^2 dispersiile de selecție. Pentru media de selecție se folosește estimatorul nedeplasat $\overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$ iar pentru dispersia de selecție se folosește estimatorul *absolut corect* $s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x})^2$. Considerăm cunoscut (ales) nivelul de semnificație α.

3.3.1. Testul z pentru medii (dispersiile σ_1, σ_2 sunt cunoscute)

Ipoteza de nul $H_0: m_1 = m_2$;

Ipotezele alternative $H_1: m_1 \neq m_2$ (bilaterală) sau $H_1: m_1 > m_2$ sau $H_1: m_1 < m_2$;

Se folosește statistica: $\boxed{z = \frac{\overline{x}_1 - \overline{x}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \in \mathcal{N}(0,1)}$

Regiunea critică pentru ipoteza alternativă $H_1: m_1 \neq m_2$ (bilaterală):

$$R_{cr} = \left\{ z \middle| z < z_{\frac{\alpha}{2}} \right\} \cup \left\{ z \middle| z > z_{1-\frac{\alpha}{2}} \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: m_1 > m_2$ (unilaterală dreapta):

$$R_{cr} = \left\{ z \middle| z > z_{1-\alpha} \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: m_1 < m_2$ (unilaterală stânga):

$$R_{cr} = \left\{ z \middle| z < z_\alpha \right\}$$

3.3.2. Testul t pentru medii (dispersiile sunt necunoscute și diferite $\sigma_1 \neq \sigma_2$)

Ipoteza de nul $H_0: m_1 = m_2$;

Ipotezele alternative $H_1: m_1 \neq m_2$ (bilaterală) sau $H_1: m_1 > m_2$ sau $H_1: m_1 < m_2$;

Se folosește statistica: $\boxed{t = \dfrac{\overline{x}_1 - \overline{x}_2}{\sqrt{\dfrac{s_1^2}{n_1} + \dfrac{s_2^2}{n_2}}}}$ care este repartizată Student cu $n-1$ grade de libertate, unde $\boxed{n = \min(n_1 - 1, n_2 - 1)}$. Repartiția Student se notează $t(n-1)$.

Regiunea critică pentru ipoteza alternativă $H_1: m_1 \neq m_2$ (bilaterală):

$$R_{cr} = \left\{ t \middle| t < t_{\frac{\alpha}{2}}(n-1) \right\} \cup \left\{ t \middle| t > t_{1-\frac{\alpha}{2}}(n-1) \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: m_1 > m_2$ (unilaterală dreapta):

$$R_{cr} = \left\{ t \middle| t > t_{1-\alpha}(n-1) \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: m_1 < m_2$ (unilaterală stânga):

$$R_{cr} = \left\{ t \middle| t < t_{\alpha}(n-1) \right\}$$

3.3.3. Testul t pentru medii (dispersiile sunt necunoscute dar egale $\sigma_1 = \sigma_2$)

Ipoteza de nul $H_0: m_1 = m_2$;

Ipotezele alternative $H_1: m_1 \neq m_2$ (bilaterală) sau $H_1: m_1 > m_2$ sau $H_1: m_1 < m_2$;

Se folosește statistica: $\boxed{t = \dfrac{\overline{x}_1 - \overline{x}_2}{\sqrt{\dfrac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1+n_2-2}\left(\dfrac{1}{n_1} + \dfrac{1}{n_2}\right)}}}$ care este repartizată Student cu $n_1 + n_2 - 2$ grade de libertate (repartiția Student este notată $t(n_1 + n_2 - 2)$).

Regiunea critică pentru ipoteza alternativă $H_1: m_1 \neq m_2$ (bilaterală):

$$R_{cr} = \left\{ t \middle| t < t_{\frac{\alpha}{2}}(n_1+n_2-2) \right\} \cup \left\{ t \middle| t > t_{1-\frac{\alpha}{2}}(n_1+n_2-2) \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: m_1 > m_2$ (unilaterală dreapta):

$$R_{cr} = \left\{ t \middle| t > t_{1-\alpha}(n_1+n_2-2) \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: m_1 < m_2$ (unilaterală stânga):

$$R_{cr} = \left\{ t \middle| t < t_{\alpha}(n_1+n_2-2) \right\}$$

3.4. TESTE PENTRU VERIFICAREA IPOTEZELOR REFERITOARE LA MEDII ȘI DISPERSII PENTRU SELECȚII DE VOLUM MIC ($n < 30$)

- Pentru selecții de volum $n < 30$ (numite și ”eșantioane mici”) , verificarea ipotezelor statistice referitoare la media caracteristicii reprezentate prin variabila aleatoare $X \in \mathcal{N}(m, \sigma)$ (sau pentru ipotezele referitoare la mediile a două variabile aleatoare repartizate normal) nu se folosesc testele z (care conțin în expresia lor valoarea dispersiei σ). Aceste teste se înlocuiesc cu corespondentele lor de tip ”test t”, *indiferent dacă se cunoaște dispersia variabilei X sau nu*.

- Pentru selecții de volum $n<30$ <u>NU se pot extinde testele parametrice pentru medie și la alte tipuri de repartiții</u>. Pentru variabile aleatoare care nu au repartiția normală este indicată folosirea altor tipuri de teste.

Fie Ω o populație statistică cu o caracteristică de interes reprezentată printr-o variabilă aleatoare X cu repartiţie Bernoulli , *de parametru* p care are tabloul de repartiție:

$$X=\begin{pmatrix} 0 & 1 \\ 1-p & p \end{pmatrix}, \text{ cu } M[X]=p \text{ și } D^2[X]=\sigma^2=p(1-p)$$

Fie $\hat{p}=\frac{1}{n}\sum_{i=1}^{n}x_i=\frac{k}{n}$ (estimație a lui p din selecția de volum n, care reprezintă *frecvența relativă* sau *proporția "succesului"*). Considerăm cunoscut (ales) nivelul de semnificație α.

3.4.1. Testul z pentru o proporție

Ipoteza de nul $H_0:\ p=p_0$ (p_0 este o valoare dată, cunoscută);

Ipotezele alternative $H_1:\ p\neq p_0$ (bilaterală) sau $H_1:\ p>p_0$ sau $H_1:\ p<p_0$;

Se folosește statistica: $\boxed{z=\frac{\hat{p}-p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}\in\mathcal{N}(0,1)}$

Regiunea critică pentru ipoteza alternativă $H_1:\ p\neq p_0$ (bilaterală):

$$R_{cr}=\left\{z\middle|z<z_{\frac{\alpha}{2}}\right\}\cup\left\{z\middle|z>z_{1-\frac{\alpha}{2}}\right\}$$

Regiunea critică pentru ipoteza alternativă $H_1:\ p>p_0$ (unilaterală dreapta):

$$R_{cr}=\left\{z\middle|z>z_{1-\alpha}\right\}$$

Regiunea critică pentru ipoteza alternativă $H_1:\ p<p_0$ (unilaterală stânga):

$$R_{cr}=\left\{z\middle|z<z_{\alpha}\right\}$$

3.4.2. Testul z pentru două proporții

Considerăm Ω o populație statistică cu două caracteristici de interes, reprezentate prin variabilele aleatoare Bernoulli independente X_1 și X_2, de parametru p_1 și respectiv p_2. Considerăm două selecții corespunzătoare celor două caracteristici, de volum n_1 și n_2; Notăm cu $\widehat{p_1}=\frac{k_1}{n_1}$ și $\widehat{p_2}=\frac{k_2}{n_2}$ estimațiile a lui p_1 și p_2 din cele două selecții (*frecvențele relative* sau *proporțiile "succesului").*

Ipoteza de nul $H_0:\ p_1=p_2$;

Ipotezele alternative $H_1:\ p_1\neq p_2$ (bilaterală) sau $H_1:\ p_1>p_2$ sau $H_1:\ p_1<p_2$;

Se folosește statistica: $\boxed{z=\frac{\widehat{p_1}-\widehat{p_2}}{\sqrt{p^*(1-p^*)\left(\frac{1}{n_1}+\frac{1}{n_2}\right)}}\in\mathcal{N}(0,1)}$,

unde $p^*=\frac{k_1+k_2}{n_1+n_2}$ reprezintă media ponderată a celor două frecvențe relative, ca estimare a valorii comune a celor două probabilități (necunoscute) p_1 și p_2, când ipoteza de nul este adevărată.

Regiunea critică pentru ipoteza alternativă $H_1: p_1 \neq p_2$ (bilaterală):

$$R_{cr} = \left\{ z \left| z < z_{\frac{\alpha}{2}} \right. \right\} \cup \left\{ z \left| z > z_{1-\frac{\alpha}{2}} \right. \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: p_1 > p_2$ (unilaterală dreapta):

$$R_{cr} = \left\{ z \left| z > z_{1-\alpha} \right. \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: p_1 < p_2$ (unilaterală stânga):

$$R_{cr} = \left\{ z \left| z < z_{\alpha} \right. \right\}$$