POPULAȚIE STATISTICĂ, SELECȚIE, ESTIMATORI

Statistica este definită ca fiind știința care se ocupă cu culegerea, înregistrarea, gruparea, analiza și interpretarea datelor referitoare la un anumit fenomen precum și cu formularea unor previziuni privind comportarea viitoare a acestuia.

Statistica matematică este o ramură a matematicii care, folosind elemente și rezultate ale teoriei probabilităților, elaborează noțiunile și metodele specifice studiului statistic.

Aceste metode sunt elaborate în scopul îndeplinirii următoarelor cerințe generale:

- descrierea cât mai fidelă și sugestivă a datelor culese, prin metode grafice sau indicatori statistici (această ramură a statisticii se numește "*statistică descriptivă*");
- Estimarea anumitor parametri ai unor caracteristici de interes ai populației, pe baza datelor culese (media populației, dispersia, asimetria, etc);
- Verificarea unor ipoteze formulate în legătură cu valorile anumitor parametri ai populației, pe baza datelor observate sau referitoare la repartiția caracteristicii populației (dacă nu este cunoscută teoretic).

Statistica inferențială este acea ramură a statisticii matematice care se ocupă cu estimarea parametrilor și testarea ipotezelor statistice, pe baza unui set de date observate.

În continuare vom prezenta noțiunile de bază și anumite aspecte teoretice fundamentale ale statisticii inferențiale.

1. DEFINIȚII, NOTAȚII

▪ Prin **populație statistică** (populație) se înțelege orice mulțime care formează obiectul unei analize statistice. Elementele unei populații statistice se numesc **indivizi sau unități statistice**.

▪ O trăsătură comună a tuturor indivizilor din populația statistică care ne interesează se numește **caracteristică**. Caracteristicile pot fi *cantitative* (înălțime, greutate, nota obținută la un examen, abscisa unui punct în plan, etc) sau *calitative* (culoarea ochilor, genul, apartenența etnică, etc). Caracteristicilor calitative li se asociază *coduri numerice* pentru a putea fi prelucrate statistic.
Datele calitative pot fi *nominale sau ordinale*. Pentru variabilele asociate acestor tipuri de date nu se pot defini caracteristici numerice (medie, dispersie, etc) dar se pot compara frecvențele relative și se pot determina proporții.

În continuare ne vom ocupa doar de caracteristici cantitative.

▪ Fie spațiul de probabilitate (Ω, K, P), unde Ω reprezintă populația statistică. Atunci caracteristica unei populații poate fi definită ca o *variabilă aleatoare* $X:\Omega\to\mathbb{R}$, discretă sau continuă (pentru caracteristici cantitative) și doar discretă (pentru caracteristici calitative).

▪ **Parametrii** sunt măsuri descriptive numerice ale caracteristicilor populației. Deoarece nu avem acces la întreaga populație, parametrii sunt necunoscuți și urmează a fi estimați pe baza datelor de selecție.
Parametrii caracteristicilor de interes pot fi: *parametri care descriu tendința centrală* (medie, momente), *parametri care descriu gradul de împrăștiere al datelor* (dispersie, abatere standard, coeficient de variație), *parametri de poziție* (cuantile), *parametri ce descriu forma* (aplatizarea sau asimetria), etc.

În majoritatea situațiilor practice, necesitatea de a obține informații relevante despre caracteristici ale unor populații mari (sau infinite) este dublată de imposibilitatea examinării fiecărui individ în parte. În aceste situații se alege o sub-populație (o submulțime a lui Ω) cu un număr finit și relativ mic de elemente și se înregistrează caracteristica dorită pentru această sub-populație (în continuare va fi numită "selecție"). Se pune problema: cât de bine este aproximată (estimată) caracterstica reală a populației de către caracteristica măsurată în sub-populație ?

Răspunsul la această întrebare depinde de modul în care este făcută selecția, de volumul acesteia și de teoria statistică folosită pentru inferență.

- *Există numeroase tehnici de selecție – numite tehnici de eșantionare – și care asigură reprezentativitatea selecției la nivelul populației, adică reproducerea într-o manieră cât mai fidelă a valorilor caracteristicilor populației.*
- *Un volum al selecției mai mare (de minim 30 de date observate) asigură o mai bună inferență decât un volum mai mic.*

2. SELECȚII, STATISTICI

▪ O mulțime de n observații independente asupra unei caracteristici X a unei populații statistice Ω, care au valorile $x_1, x_2, ..., x_n$ se numește **selecție** de volum n. Fiecărei date observate x_i i se poate asocia o variabilă aleatoare X_i, astfel încât x_i devine o posibilă valoare a variabilei X_i.

▪ Variabilele aleatoare $X_1, X_2, ..., X_n$ se numesc **variabile aleatoare de selecție** și pot fi interpretate ca fiind un set de observații independente asupra variabilei X (caracteristica populației). Toate aceste variabile de selecție sunt identic repartizate, repartiția comună fiind repartiția variabilei X.

În concluzie, X_i este o observație a variabilei X iar x_i este valoarea corespunzătoare observată.

▪ Se numește **statistică** (sau **funcție de selecție**) o funcție de variabilele aleatoare de selecție, adică o variabilă aleatoare de forma:

$$S_n(X) = u(X_1, X_2, ..., X_n)$$

unde u este o funcție (măsurabilă) $u : \mathbb{R}^n \to \mathbb{R}$.

Alte notații uzuale pentru statistici: $S(X, n)$, $S(X_1, X_2, ..., X_n)$

Observație: Denumirea de "statistică" este folosit în literatura de specialitate atât pentru variabila aleatoare e mai sus cât și *pentru valoarea ei numerică* (depinde de contextul în care este folosit termenul) definită prin:

$$S_n(x) = u(x_1, x_2, ..., x_n)$$

▪ Repartiția unei statistici se mai numește și **repartiția (distribuția) de selecție** iar valoarea numerică $S_n(x) = u(x_1, x_2, ..., x_n)$ se numește **valoarea funcției de selecție** pentru un set dat de observații $x_1, x_2, ..., x_n$.

▪ Repartiția unei statistici poate fi *exactă* (repartiția care se poate determina pentru orice volum al selecției) sau *asimptotică* (repartiția limită a lui $S_n(X)$, pentru $n \to \infty$).

Observații:

1. Dacă se lucrează cu selecții de volum redus ($n < 30$), atunci repartiția exactă trebuie să fie cunoscută apriori, dacă urmează a se lua decizii prin inferență; Utilizarea repartiției asimptotice conduce la obținerea unor rezultate inferențiale bune doar dacă volumul de selecție este mare (cel puțin $n \geq 30$).

2. Teoria probabilităților oferă posibilitatea determinării atât a repartiției exacte cât și a repartiției asimptotice a unei statistici $S_n(X)$, iar cu ajutorul acesteia putem trage concluzii despre populația din care a provenit eșantionul observat (inferența statistică).

Unde se folosesc statisticile?

- *În probleme de estimare punctuală a parametrilor populației;*
- *În obținerea intervalelor de încredere pentru un parametru necunoscut;*
- *Pentru verificarea ipotezelor statistice, ca o statistică-test.*

2.1. Exemple de statistici

1. <u>Media de selecție</u>

*Se numește **medie de selecție** (de volum n), statistica $\overline{X}=\frac{1}{n}\sum_{i=1}^{n}X_i$. Valoarea mediei de selecție pentru valori ale variabilelor aleatoare X_i este **media empirică**: $\overline{x}=\frac{1}{n}\sum_{i=1}^{n}x_i$.*

<u>Proprietăți</u>:

a) $M\left[\overline{X}\right]=M\left[X\right]$;

b) $D^2\left[\overline{X}\right]=\frac{1}{n}D^2\left[X\right]$;

c) $\overline{X}\underset{(n\to\infty)}{\overset{a.s.}{\to}}M\left[X\right]$;

d) Dacă $X_1,X_2,...,X_n$ sunt variabile aleatoare de selecție (repetată) de volum $n\geq 30$, care au o repartiție comună dată, atunci statistica $\overline{X}$ este o variabilă normală: $\overline{X}\in\mathcal{N}\left(m,\frac{\sigma}{\sqrt{n}}\right)$. În cazul în care toate variabilele de selecție X_i sunt normale, atunci proprietatea este valabilă pentru orice $n\in\mathbb{N}^*$.

***2. <u>Dispersia de selecție</u>** (varianța selecției)*

*Se numește **dispersie de selecție** (de volum n), statistica $S_X^2=\frac{1}{n-1}\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2$. Valoarea dispersiei de selecție pentru valori ale variabilelor aleatoare X_i este **dispersia empirică**: $s_X^2=\frac{1}{n-1}\sum_{i=1}^{n}\left(x_i-\overline{x}\right)^2$.*

<u>Observație</u>: Statistica definită mai sus se mai numește și *dispersia de selecție corectată*, atunci când dispersia de selecție este definită prin formula: $S_*^2=\frac{1}{n}\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2$. *Motivul pentru care NU se lucrează cu S_*^2 (și deci nu mai este necesară precizarea "corectată" pentru celalaltă variantă) este că S_X^2 estimează mai bine dispersia teoretică $D^2\left[X\right]$ (S_X^2 este un estimator nedeplasat al dispersiei teoretice, pe când S_*^2 este un estimator deplasat. Pentru definirea acestor noțiuni, a se vedea subcapitolul "Estimatori").*
Pentru selecții de volum mare, se pot folosi oricare dintre cele două formule (S_X^2 sau S_*^2) deoarece diferența dintre valorile obținute pentru dispersia de selecție este neglijabilă.

<u>Proprietăți</u>:

a) $M\left[S_X^2\right]=D^2\left[X\right]$;

b) $S_X^2\underset{(n\to\infty)}{\overset{prob.}{\to}}D^2\left[X\right]$;

c) Dacă $X_1,X_2,...,X_n$ sunt variabile aleatoare de selecție (repetată) de volum $n\geq 30$, care au o repartiție comună dată, atunci statistica S_X^2 este o variabilă repartizată χ^2, cu $n-1$ grade de libertate: $S_X^2\in\chi^2\left(n-1\right)$.

2.2. Funcția de repartiție de selecție

- Considerăm o selecție de volum n dintr-o populație statistică. **Frecvența absolută** reprezintă numărul de apariții ale unui rezultat (valoare) în cadrul selecției iar **frecvența relativă** reprezintă raportul dintre frecvența absolută și volumul selecției. Evident, suma frecvențelor relative este 1 și cu ajutorul acestora putem defini *repartiția variabilei aleatoare* X a caracteristicii de interes:

$$X = \begin{pmatrix} x_i \\ f_i \end{pmatrix}, \text{ unde } \sum_{i=1}^{n} f_i = 1 \text{ (suma frecvențelor relative)}$$

- Fie $X_1, X_2, ..., X_n$ variabile aleatoare de selecție (repetată), de volum n. Numim **funcție de repartiție de selecție** (de volum n) funcția definită prin:

$$\boxed{F_n^*(x) = \frac{n_i(x)}{n}}, \ \forall x \in \mathbb{R}$$

unde $n_i(x) = card\left\{ i \mid X_i \le x \right\}$ reprezintă numărul de variabile aleatoare din selecție care au valori mai mici sau egale cu x.

***Proprietăți**:*

a) $M\left[F_n^*(x)\right] = F(x)$, *pentru* $\forall x \in \mathbb{R}$;

b) $D^2\left[F_n^*(x)\right] = \frac{1}{n}\left[F(x)\left(1 - F(x)\right)\right]$, pentru $\forall x \in \mathbb{R}$.

Aceste două proprietăți pot fi sintetizate într-un enunț teoretic de forma:
Pentru $n \in \mathbb{N}$ suficient de mare, diferența dintre funcția empirică de repartiție și cea teoretică reprezintă o variabilă aleatoare repartizată normal:

$$\left(F_n^*(x) - F(x)\right) \in \frac{1}{\sqrt{n}} \mathcal{N}\left(0, \sqrt{F(x)\left(1 - F(x)\right)}\right)$$

Observație: Funcția de repartiție de selecție poate fi definită și cu ajutorul funcției indicatoare a unei mulțimi, χ_A: $F_n^*(x) = \frac{1}{n}\sum_{i=1}^{n} \chi_{(-\infty, x]}(X_i)$, $\forall x \in \mathbb{R}$.

- Pentru un $x \in \mathbb{R}$ fixat, $F_n^*(x)$ este o variabilă aleatoare repartizată binomial, de parametri n și $F(x)$.

Dacă avem valorile de selecție $x_1, x_2, ..., x_n$ obținem **funcția de repartiție empirică** (care are aceeași expresie ca funcția de repartiție de selecție), dar $n_i(x) = card\left\{ i \mid x_i \le x \right\}$ reprezintă numărul de valori din selecție mai mici sau egale cu x.

Observație: Dacă ordonăm crescător valorile de selecție pentru variabila aleatoare X: $x_1 \le x_2 \le ... \le x_n$, funcția empirică de repartiție poate fi definită și astfel:

$$F_n^*(x) = \begin{cases} 0, & x < x_1 \\ \sum_{j=1}^{i-1} f_j, & x_{i-1} \le x < x_i \\ 1, & x \ge x_n \end{cases}$$

unde f_j sunt frecvențele relative de selecție.

(Reamintim că funcția de repartiție a unei variabile aleatoare este definită prin $F: \mathbb{R} \to [0,1]$, $F_X(x) = P(X < x)$).

Observaţie: Dacă avem selecții diferite din aceeași populație Ω, pentru aceeași caracteristică X, funcțiile empirice de repartiție diferă, chiar dacă volumul selecțiilor este același (pentru că nu se obțin întotdeauna aceleași valori de selecție).

Pentru a putea aprecia "apropierea" funcției empirice de repartiție $F_n^*(x)$ de funcția teoretică de repartiție $F_X(x)$ au fost formulate și demonstrate câteva rezultate teoretice importante. Această "apropiere" dintre funcțiile de repartiție (empirică și teoretică) reprezintă fundamentul statisticii inferențiale. În continuare prezentăm unul dintre aceste rezultate, considerat a fi "teorema fundamentală a statisticii matematice".

Teorema lui Glivenko

Considerăm spațiul de probabilitate (Ω, K, P), unde Ω reprezintă populația statistică și o caracteristică de interes reprezentată de variabila aleatoare $X:\Omega\to\mathbb{R}$, cu funcția de repartiție teoretică $F_X(x)$. Dacă $F_n^*(x)$ este funcția de repartiție de selecție pentru o selecție de volum n, atunci:

$$P\left\{\lim_{n\to\infty}\sup\left|F_n^*(x)-F_X(x)\right|=0\right\}=1 \text{ (convergență a.s.)}$$

Acest rezultat teoretic ne asigură că putem considera în locul funcției teoretice de repartiție $F_X(x)$, funcția de repartiție empirică $F_n^*(x)$, dacă volumul selecției este suficient de mare.

Altă interpretare: Probabilitatea ca funcția empirică de repartiție $F_n^*(x)$ să dea o bună aproximare pentru funcția teoretică $F_X(x)$ este foarte apropiată de 1.

3. ESTIMATORI

Una dintre problemele centrale ale statisticii matematice inferențiale o reprezintă *estimarea parametrilor unei populații*. Considerăm o populație statistică Ω, de volum N (finit sau infinit) și o caracteristică a sa, reprezentată de variabila aleatoare X. Pe baza unei selecții de volum $n \ll N$ dorim să estimăm diverși parametri ai caracteristicii X (cei mai comuni parametri care se doresc a fi estimați sunt *media* și *dispersia* lui X).

Estimatorii folosiți în statistica matematică se clasifică în:

- *Estimatori punctuali* – se determină o estimare a parametrului de interes din populație, pe baza valorii parametrului respectiv din selecție;
- *Estimatori sub formă de interval* – se determină un interval de apartenență pentru parametrul de interes.

Estimatorii sub formă de interval sunt cunoscuți sub denumirea de *intervale de încredere*. Aceștia sunt prezentați în alt capitol.

Deoarece setul de valori observate $x_1, x_2, ..., x_n$ din selecția de volum n diferă de la un eșantion la altul, vom considera, în locul lor, variabilele aleatoare de selecție $X_1, X_2, ..., X_n$ (variabile aleatoare independente, a căror repartiție comună este repartiția lui X iar x_i este o posibilă valoare a variabilei X_i).

Generic, un parametru care urmează a fi estimat se notează cu θ.

- Se numește **estimator punctual** (sau simplu, **estimator**) al lui θ o statistică $\hat{\theta}=\hat{\theta}(X_1, X_2, ..., X_n)$, cu ajutorul căreia dorim să îl aproximăm pe θ. Dacă $\{x_1, x_2, ..., x_n\}$ sunt date observate, atunci $\hat{\theta}=\hat{\theta}(x_1, x_2, ..., x_n)$ se numește **estimație** a lui θ. Așadar, *o estimație pentru un parametru necunoscut θ este valoarea estimatorului pentru selecția observată*.

Prin abuz de notație, vom nota atât estimatorul cât și estimația cu $\hat{\theta}$. Vom evita confuziile prin precizarea variabilelor de care depind.

3.1. Estimator nedeplasat, deplasare, eroare medie pătratică, eroare standard

Deoarece estimările sunt bazate doar pe valorile unei selecții (adică o submulțime a populației), ele nu pot fi exacte – astfel, un parametru necunoscut nu poate fi *determinat*, ci doar *estimat* (aproximat) – cu o anumită eroare de aproximare.
Apare firesc întrebarea: *cât de bine aproximează un estimator parametrul necunoscut?* Pentru a răspunde la această întrebare avem nevoie de anumite mărimi care să cuantifice erorile de aproximare – și acestea sunt: *deplasarea, eroarea medie pătratică și eroarea standard*.

- Un estimator $\hat{\theta}$ se numește **estimator nedeplasat** (sau **corect**) pentru parametrul θ dacă media estimatorului este chiar valoarea parametrului estimat:

$$M\left[\hat{\theta}\right]=\theta$$

Altfel, spunem că $\hat{\theta}$ este un *estimator deplasat* pentru θ, iar **deplasarea** (distorsiunea) se definește prin:

$$b\left(\hat{\theta},\theta\right)=M\left[\hat{\theta}\right]-\theta$$

Cantitatea $b\left(\hat{\theta},\theta\right)$ este o măsură a erorii care apare la estimarea lui θ prin $\hat{\theta}$.

- Numim **eroare medie pătratică** (*notată MSE = "mean squared error"*) a unui estimator $\hat{\theta}$ pentru θ valoarea medie a pătratului diferenței dintre estimator și valoarea parametrului estimat:

$$MSE\left(\hat{\theta},\theta\right)=M\left[\left(\hat{\theta}-\theta\right)^2\right]$$

<u>Observație</u>: Pentru un estimator nedeplasat, MSE este chiar dispersia estimatorului, $D^2\left[\hat{\theta}\right]$.

- **Eroarea standard** (*en. standard error*) este indicatorul care arată cât de precis aproximează media calculată din valorile unei selecții de volum n, media populației din care a fost extras eșantionul și se definește prin:

$$Err=\frac{s}{\sqrt{n}}$$

unde s este abaterea standard a selecției (și este egală cu radicalul dispersiei de selecție). Eroarea standard se mai numește și "abaterea standard a mediei".

<u>Exemple:</u>

1. *Media de selecție* $\overline{X}=\frac{1}{n}\sum_{i=1}^{n}X_i$ *este un estimator nedeplasat pentru parametrul* $\theta=m$ *(media teoretică).*

2. *Dispersia de selecție "corectată":* $S_X^2=\frac{1}{n-1}\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2$ *este un estimator nedeplasat pentru parametrul* $\theta=\sigma^2$ *(dispersia teoretică)*

3. *Dispersia de selecție "necorectată"* $S_*^2=\frac{1}{n}\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2$ *este un estimator deplasat pentru parametrul* $\theta=\sigma^2$*, deplasarea fiind:*

$$b\left(S_*^2,\sigma^2\right)=M\left[S_*^2\right]-\sigma^2=\frac{n-1}{n}\sigma^2-\sigma^2=-\frac{\sigma^2}{n}.$$

4. *Momentele de selecție inițiale de ordin k sunt estimatori nedeplasați pentru momentele teoretice (inițiale de ordin k):* $M\left[\widehat{M_k[X]}\right]=M_k[X]$

3.2. Estimatori consistenți, absolut corecți, de dispersie minimă, eficienți

- Estimatorul $\hat{\theta}$ pentru θ este un **estimator consistent** dacă:

$$\hat{\theta}(X_1,X_2,...,X_n)\underset{(n\to\infty)}{\overset{prob.}{\to}}\theta$$

În acest caz, valoarea numerică a estimatorului, $\hat{\theta}(x_1,x_2,...,x_n)$ se numește **estimație consistentă** pentru θ.

- Estimatorul $\hat{\theta}$ pentru θ este un **estimator absolut corect** dacă:
  - **a)** este corect (adică nedeplasat): $M\left[\hat{\theta}\right]=\theta$
  - **b)** $\lim\limits_{n\to\infty}D^2\left[\hat{\theta}\right]=0$ (n este volumul selecției).

În acest caz, valoarea numerică a estimatorului, $\hat{\theta}(x_1,x_2,...,x_n)$ se numește **estimație absolut corectă** pentru θ.

Exemple:

1. *Dispersiile de selecție (și cea "corectată"* $S_X^2=\frac{1}{n-1}\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2$ *și cea "necorectată"* $S_*^2=\frac{1}{n}\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2$ *) sunt estimatori consistenți pentru dispersia teoretică.*

2. *Dispersia de selecție "corectată"* $S_X^2=\frac{1}{n-1}\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2$ *este un estimator absolut corect pentru dispersia teoretică.*

3. *Momentele de selecție inițiale de ordin k sunt estimatori absolut corecți pentru momentele teoretice (inițiale de ordin k).*

- Un estimator nedeplasat $\hat{\theta}$ pentru θ se numește **estimator nedeplasat uniform de dispersie minimă** dacă pentru orice alt estimator nedeplasat pentru θ, notat $\widehat{\theta^*}$, avem:

$$D^2\left[\hat{\theta}\right]\le D^2\left[\widehat{\theta^*}\right],$$

pentru orice valoare a parametrului θ.

Observație: Pentru un anumit parametru pot exista mai mulți estimatori nedeplasați. Dintre aceștia, cel mai bun estimator este cel care are *dispersia minimă*.

Exemplu: *Pentru parametrul $\theta=\lambda$ al repartiției Poisson există doi estimatori nedeplasați:* $\hat{\theta}=\overline{X}$ *și* $\hat{\theta}=S_X^2$ *(media și dispersia unei variabile aleatoare Poisson sunt egale între ele și egale cu parametrul repartiției, λ). Estimatorul de dispersie minimă este, în acest caz,* $\hat{\theta}=\overline{X}$.

Teorema Rao-Cramer
Considerăm o selecție de volum n dintr-o populație Ω și fie X variabila aleatoare care descrie caracteristica de interes a populației. Considerăm cunoscută densitatea de repartiție a lui X, care depinde de un parametru θ, $f(x,\theta)$. Dacă $\hat{\theta}$ este un *estimator nedeplasat* al lui θ, atunci:

$$D^2\left[\hat{\theta}\right] \geq \frac{1}{n \cdot M\left[\left(\frac{\partial \ln f(x,\theta)}{\partial \theta}\right)^2\right]}$$

- Estimatorul pentru care se obține egalitate în Teorema Rao-Cramer se numește **estimator eficient**.

Exemple:

1. *Media de selecție* $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$ *este un estimator eficient pentru parametrul* $\theta = m$ *(media teoretică) a unei variabile aleatoare repartizate normal* $\mathcal{N}(m,\sigma)$.

2. *Media de selecție* $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$ *este un estimator eficient pentru parametrul* $\theta = \lambda$ *(media teoretică sau dispersia teoretică) a unei variabile aleatoare repartizate Poisson, de parametru* λ.

- Cu ajutorul relației din Teorema Rao-Cramer se poate determina *dispersia minimă pentru un estimator nedeplasat (corect)*. (Vezi problema rezolvată 3)

În continuare sunt prezentate cele mai cunoscute metode de determinare a unor estimatori punctuali. Aceste ”metode clasice” sunt: *metoda momentelor și metoda verosimilității maxime.*

4. METODA MOMENTELOR

Metoda momentelor a fost introdusă de K. Pearson în 1928 și are la bază faptul că momentele de selecție inițiale de ordin k sunt estimatori absolut corecți pentru momentele teoretice (inițiale de ordin k), adică:
$M\left[\widehat{M_k[X]}\right] = M_k[X]$ și $D^2\left[\widehat{M_k[X]}\right] = \frac{1}{n}\left(M_{2k}[X] - M_k^2[X]\right) \overset{n\to\infty}{\to} 0$.
Astfel, pentru un volum al selecției suficient de mare, *momentele teoretice inițiale de ordin* k *vor fi înlocuite cu momentele empirice de ordin corespunzător*.
Numărul momentelor care trebuie calculate este egal cu numărul parametrilor care trebuie estimați.
Estimatorii determinați prin această metodă poartă numele de **estimatori ai momentelor**.

Exemplu*: Considerăm o caracteristică de interes* X *care are o repartiție exponențială, de parametru (necunoscut)* $\lambda > 0$. *Vrem să estimăm acest parametru prin metoda momentelor, folosind o selecție de volum* n.

Rezolvare: Considerăm o selecție de volum n *și notăm variabilele aleatoare de selecție* $X_1, X_2, ..., X_n$ *(variabile aleatoare independente, a căror repartiție comună este repartiția lui* X *- adică repartiția exponențială)*
Densitatea de repartiție a caracteristicii X*, repartizată exponențial, este:*

$$f(x,\lambda) = \begin{cases} \lambda \cdot e^{-\lambda x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

Știm că media unei variabile aleatoare repartizate exponențial (momentul de ordinul 1) este: $M[X] = \frac{1}{\lambda}$.

Momentul de selecție inițial de ordin 1 (media de selecție) este $M\left[\overline{X}\right] = \frac{X_1 + X_2 + ... + X_n}{n}$*. Pentru a*

estima parametrul necunoscut λ egalăm media teoretică cu cea de selecție (egalitatea momentelor de ordin 1) și obținem estimatorul de moment al parametrului λ : $\hat{\lambda} = \frac{n}{X_1 + X_2 + ... + X_n}$. Se poate arăta, mai departe, că $\hat{\lambda}$ este un estimator corect (adică $M\left[\hat{\lambda}\right] = \lambda$).

5. METODA VEROSIMILITĂȚII MAXIME

Această metodă a fost elaborată de R.A. Fisher în 1912.
Dacă considerăm o populație statistică Ω și o caracteristică de interes a acesteia, X, cu densitatea de repartiție specificată $f(x,\theta)$ (θ poate reprezenta un singur parametru sau poate fi considerat un vector de parametri necunoscuți, $\theta = (\theta_1, \theta_2, ...)$), atunci *prin metoda verosimilității maxime se determină un estimator de dispersie minimă pentru parametrul* θ, pe baza unei selecții de volum n. Acest estimator se numește *estimator de verosimilitate maximă* și este un estimator punctual.
Notăm cu $x_1, x_2, ..., x_n$ valorile observate ale variabilelor aleatoare de selecție $X_1, X_2, ..., X_n$ (independente, cu densitățile de repartiție $f(x_i, \theta)$).

Interpretarea metodei verosimilității maxime este aceea că *estimatorul $\hat{\theta}$ al lui θ este egal cu acea valoare care maximizează probabilitatea de apartiție a valorilor observate $x_1, x_2, ..., x_n$.*

În cele ce urmează vom considera că variabila aleatoare X are o *repartiție continuă*, cazul discret urmând a fi discutat separat.

- Se numește **funcție de verosimilitate** funcția definită prin:

$$P(x_1, x_2, ..., x_n, \theta) \overset{notatie}{=} L(x,\theta) = \prod_{i=1}^{n} f(x_i, \theta)$$

- Estimația de verosimilitate maximă $\hat{\theta}$ pentru parametrul θ este valoarea pentru care $L(x,\theta)$ devine maximă, ceea ce conduce la faptul că estimația de verosimilitate maximă $\hat{\theta}$ se obține ca soluție a ecuației: $\frac{\partial L(x,\theta)}{\partial \theta} = 0$ (cu verificare ca punct de maxim)
- Datorită formei funcției de verosimilitate (produs), calculul derivatelor parțiale se simplifică dacă logaritmăm funcția:

$$\ln L(x,\theta) = \ln\left(\prod_{i=1}^{n} f(x_i,\theta)\right) = \sum_{i=1}^{n} \ln f(x_i,\theta),$$

- Având în vedere că logaritmul este funcție crescătoare (păstrează maximul), maximizarea funcției de verosimilitate este echivalentă cu maximizarea funcției de verosimilitate logaritmată, deci *estimația de verosimilitate maximă* $\hat{\theta}$ se obține ca *soluție a ecuației* $\frac{\partial \ln L(x,\theta)}{\partial \theta} = 0$, echivalent cu:

$$\sum_{i=1}^{n} \frac{\partial \ln f(x_i,\theta)}{\partial \theta} = 0$$

și care poartă numele de **ecuația verosimilității maxime**.

<u>Observație</u>: Dacă $\theta = (\theta_1, \theta_2, ...)$ este un vector de parametri necunoscuți, atunci estimatorii punctuali $\widehat{\theta_1}, \widehat{\theta_2}, ...$ ai parametrilor $\theta_1, \theta_2, ...$ se obțin rezolvând ecuațiile provenite din logaritmarea funcției de verosimilitate:

$$\left[\frac{\partial \ln L(x,\theta)}{\partial \theta_1}\right]_{\widehat{\theta_1}} = \left[\frac{\partial \ln L(x,\theta)}{\partial \theta_2}\right]_{\widehat{\theta_2}} = ... = 0$$

(câte o ecuație pentru fiecare parametru necunoscut).

Dacă variabila aleatoare X are o *repartiție discretă*, atunci în expresia funcției de verosimilitate se înlocuiesc densitățile de repartiție $f\left(x_i,\theta\right)$ cu probabilitățile corespunzătoare $p_i = P\left(X = x_i,\theta\right)$, iar funcția de verosimilitate are forma:

$$L(x,\theta) = \prod_{i=1}^{n} P(X = x_i,\theta)$$

Prin logaritmare obținem:

$$\ln L(x,\theta) = \ln\left(\prod_{i=1}^{n} P(X = x_i,\theta)\right) = \sum_{i=1}^{n} \ln P(X = x_i,\theta)$$

iar ecuația de verosimilitate este: $\sum_{i=1}^{n} \frac{\partial \ln P(X = x_i,\theta)}{\partial\theta} = 0$.

Un rezultat teoretic important, care leagă noțiunea de estimație eficientă de cea de maximă verosimilitate este următorul:

- *Orice estimator eficient este un estimator de verosimilitate maximă.*

Exemplu *de aplicare a metodei verosimilității maxime pentru o variabilă discretă:*
Considerăm o urnă ce conține un număr necunoscut de bile albe și negre. Să se estimeze probabilitatea de a extrage o bilă albă din urnă, folosind metoda verosimilității maxime.

Rezolvare: Populația statistică Ω este finită (reprezentată de numărul total de bile din urnă) iar caracteristica de interes X este culoarea bilei extrase (albă, conform enunțului). Dacă asociem codul 0 pentru bila neagră și codul 1 pentru bila albă, variabila aleatoare X are o repartiție Bernoulli, de parametru (necunoscut) $\theta = p$ și are tabloul de repartiție:

$$X = \begin{pmatrix} 0 & 1 \\ 1-p & p \end{pmatrix}, \text{ cu } p = P\left(X = 1\right)$$

Considerăm o selecție de volum n și notăm variabilele aleatoare de selecție $X_1, X_2, ..., X_n$ (selecția este obținută prin extragerea repetată a unei bile din urnă, cu repunere) cu valorile observate $x_1, x_2, ..., x_n$. În aceste condiții putem scrie:

$$P\left(X_i = x_i\right) = p^{x_i}\left(1-p\right)^{1-x_i} = \begin{cases} p, & x_i = 1 \\ 1-p, & x_i = 0 \end{cases}$$

Funcția de verosimilitate este:

$$L(x,p) = \prod_{i=1}^{n} P\left(X = x_i\right) = \prod_{i=1}^{n} p^{x_i}\left(1-p\right)^{1-x_i} = p^{\sum_{i=1}^{n} x_i}\left(1-p\right)^{n-\sum_{i=1}^{n} x_i}$$

Logaritmăm funcția de verosimilitate și scriem ecuația de verosimilitate: $\frac{\partial \ln L\left(x,p\right)}{\partial p} = 0$ *care este echivalentă cu:* $\frac{1}{p}\sum_{i=1}^{n} x_i + \left(-\frac{1}{1-p}\right)\left(n - \sum_{i=1}^{n} x_i\right) = 0$*, de unde, prin împărțire cu n obținem:*

$\frac{1}{p}\bar{x} + \left(1-\bar{x}\right)\frac{1}{p-1} = 0$*, apoi* $p\bar{x} - \bar{x} + p - p\bar{x} = 0$*, de unde obținem:* $p = \bar{x}$.

Verificăm că este punct de maxim: $\frac{1}{n}\frac{\partial^2 \ln L\left(x,p\right)}{\partial p^2} = -\frac{\bar{x}}{p^2} - \frac{1-\bar{x}}{\left(p-1\right)^2} < 0$ pentru $p = \bar{x}$.

În concluzie, estimația de maximă verosimilitate este $\hat{p} = \bar{x} = \frac{x_1 + x_2 + ... + x_n}{n}$ *iar estimatorul de verosimilitate maximă este:* $\hat{p} = \frac{X_1 + X_2 + ... + X_n}{n}$.

PROBLEME REZOLVATE

1) *Fie* X *caracteristica unei populații statistice având* $M[X] = m$ *și* $D^2[X] = \sigma^2$. *Dacă* $x_1, x_2, ..., x_n$ *este o selecție de volum* n, *să se arate că* $\overline{\sigma^2} = \frac{1}{n}\sum_{i=1}^{n}(x_i - m)^2$ *(pentru* m *cunoscut) și* $s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$ *(pentru* m *necunoscut) sunt estimatori nedeplasați ai dispersiei.*

<u>Rezolvare</u>: Un estimator nedeplasat $\hat{\theta}$ *pentru parametrul* θ *are proprietatea că* $M[\hat{\theta}] = \theta$, *deci vom arăta că* $M[\overline{\sigma^2}] = \sigma^2$ *și respectiv* $M[s^2] = \sigma^2$.

- $M[\overline{\sigma^2}] = \frac{1}{n}\sum_{i=1}^{n} M[(x_i - m)^2] = \frac{1}{n}\sum_{i=1}^{n} D^2[X] = \frac{n\sigma^2}{n} = \sigma^2$, *deci* $\overline{\sigma^2}$ *este estimator nedeplasat al dispersiei.*
- *Pentru a calcula* $M[s^2]$ *vom face mai întâi un artificiu de calcul pentru a rescrie expresia lui* s^2, *folosind media de selecție (deoarece* m *este necunoscut):* $(x_i - m)^2 = \left[(x_i - m) + (m - \bar{x})\right]^2$. *Astfel, putem scrie:*

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left[(x_i - m) + (m - \bar{x})\right]^2 =$$

$$= \frac{1}{n-1}\sum_{i=1}^{n}\left[(x_i - m)^2 + 2(x_i - m)(m - \bar{x}) + (m - \bar{x})^2\right] =$$

$$= \frac{n}{n-1}\left[\sum_{i=1}^{n}\frac{(x_i - m)^2}{n} + 2(m - \bar{x})\left(\underbrace{\frac{1}{n}\sum_{i=1}^{n}x_i}_{\bar{x}} - m\right) + (m - \bar{x})^2\right] =$$

$$= \frac{n}{n-1}\left[\overline{\sigma^2} - (\bar{x} - m)^2\right].$$

$$M[s^2] = \frac{n}{n-1}\left[M[\overline{\sigma^2}] - M[(\bar{x} - m)^2]\right] \quad (**)$$

Dar $M[(\bar{x} - m)^2] = D^2[\bar{x}] = D^2\left[\frac{1}{n}\sum_{i=1}^{n}x_i\right]$, *variabilele* $X_1, X_2, ..., X_n$ *sunt independente (valorile lor sunt valorile selecției* $x_1, x_2, ..., x_n$*), deci :*

$D^2\left[\frac{1}{n}\sum_{i=1}^{n}x_i\right] = \frac{1}{n^2}\sum_{i=1}^{n}D^2[X_i] = \frac{1}{n^2}\cdot n \cdot D^2[X] = \frac{\sigma^2}{n}$. *Înlocuim în (**) și obținem:*

- $M[s^2] = \frac{n}{n-1}\left(\overline{\sigma^2} - \frac{\sigma^2}{n}\right) = \sigma^2$, *deci* s^2 *este estimator nedeplasat al dispersiei.*

2) *Fie Ω o populație statistică cu o caracteristică de interes $X \in \mathcal{N}(m,\sigma)$ și $x_1, x_2, ..., x_n$ o selecție de volum n. Să se verifice că $\hat{\theta} = \frac{1}{n}\sum_{i=1}^{n} x_i$ este o estimație eficientă a parametrului m, în ipoteza că σ este cunoscut.*

<u>Rezolvare</u>: $\hat{\theta} = \frac{1}{n}\sum_{i=1}^{n} x_i$ reprezintă media de selecție, care este un estimator nedeplasat al mediei m. În aceste condiții $\hat{\theta}$ este o estimație eficientă a parametrului m dacă verifică Teorema Rao-Cramer (cu egalitate):

$$D^2\left[\hat{\theta}\right] = \frac{1}{n \cdot M\left[\left(\frac{\partial \ln f(x,m)}{\partial m}\right)^2\right]}$$

Densitatea de repartiție pentru $X \in \mathcal{N}(m,\sigma)$ este $f(x,m) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-m)^2}{2\sigma^2}}$. Calculăm

$\ln f(x,m) = \ln\frac{1}{\sigma\sqrt{2\pi}} - \frac{(x-m)^2}{2\sigma^2}$, *deci* $\frac{\partial \ln f(x,m)}{\partial m} = \frac{x-m}{\sigma^2}$;

$$M\left[\left(\frac{\partial \ln f(x,m)}{\partial m}\right)^2\right] = \int_{-\infty}^{\infty} f(x,m)\cdot\left(\frac{x-m}{\sigma^2}\right)^2 dx = \frac{1}{\sigma^4}\int_{-\infty}^{\infty} f(x,m)\cdot(x-m)^2\,dx =$$

$$= \frac{1}{\sigma^4} D^2[X] = \frac{1}{\sigma^2}$$

Înlocuim în relația Teoremei Rao-Cramer și obținem: $D^2\left[\hat{\theta}\right] = \frac{\sigma^2}{n}$, deci dacă $\hat{\theta}$ este o estimație eficientă a parametrului m, dispersia lui $\hat{\theta}$ (calculată) trebuie să fie egală cu $\frac{\sigma^2}{n}$. Calculăm $D^2\left[\hat{\theta}\right] = D^2\left[\sum_{i=1}^{n} X_i\right] = \frac{1}{n^2}\sum_{i=1}^{n} D^2[X_i] = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}$, deci $\hat{\theta}$ este o estimație eficientă a parametrului m.

3) *Considerăm o populație Ω cu o caracteristică de interes X având o repartiție Poisson de parametru $\lambda > 0$ necunoscut. Să se determine dispersia minimă posibilă pentru un estimator nedeplasat (corect) al lui λ.*

<u>Rezolvare</u>: Dacă X este repartizată Poisson atunci:

$$f(k,\lambda) = P(X = k) = e^{-\lambda}\frac{\lambda^k}{k!}, \text{ cu } k \in \mathbb{N} \text{ și } \lambda > 0$$

Un estimator nedeplasat (corect) al parametrului λ verifică inegalitatea din Teorema Rao-Cramer:

$$D^2\left[\hat{\lambda}\right] \geq \frac{1}{n \cdot M\left[\left(\frac{\partial \ln f(k,\lambda)}{\partial \lambda}\right)^2\right]}$$

Calculăm $\ln f(k,\lambda) = \ln\left(e^{-\lambda}\frac{\lambda^k}{k!}\right) = -\lambda + k\ln\lambda - \ln(k!)$, deci $\frac{\partial \ln f(k,\lambda)}{\partial \lambda} = \frac{k}{\lambda} - 1$. Calculăm media

$$M\left[\left(\frac{\partial \ln f(k,\lambda)}{\partial \lambda}\right)^2\right] = \sum_{k=0}^{\infty}\left(\frac{k}{\lambda}-1\right)^2 \cdot e^{-\lambda}\frac{\lambda^k}{k!} = \frac{e^{-\lambda}}{\lambda^2}\sum_{k=0}^{\infty} k^2 \cdot \frac{\lambda^k}{k!} -$$

$-2\frac{e^{-\lambda}}{\lambda}\sum_{k=0}^{\infty}k\cdot\frac{\lambda^k}{k!}+e^{-\lambda}\sum_{k=0}^{\infty}\frac{\lambda^k}{k!}=\frac{e^{-\lambda}}{\lambda^2}\lambda e^{\lambda}(\lambda+1)-2\frac{e^{-\lambda}}{\lambda}\lambda e^{\lambda}+e^{-\lambda}e^{\lambda}=\frac{1}{\lambda}$. *(am folosit proprietăți ale seriilor de puteri – derivarea termen cu termen – pentru seria lui* e^{λ}*).*

Înlocuind în inegalitatea Teoremei Rao-Cramer, obținem: $D^2\left[\hat{\lambda}\right]\geq\frac{\lambda}{n}$, adică dispersia minimă posibilă pentru un estimator nedeplasat al lui λ este $\frac{\lambda}{n}$.

4) *Să se estimeze parametrul* b *al repartiției Gamma, care are densitatea de repartiție:*

$$f(x,b)=\begin{cases}\frac{1}{b^{a+1}\Gamma(a+1)}x^a e^{-\frac{x}{b}}, & x>0\\ 0, & x\leq 0\end{cases}$$ *, cu* $a>-1$ *cunoscut și* $b>0$*,*

prin metoda verosimilității maxime, pe baza unei selecții $x_1,x_2,...,x_n$ *de volum* n*.*

<u>Rezolvare</u>*: Funcția de verosimilitate este:* $L(x,b)=\prod_{i=1}^{n}f(x_i,b)=\frac{1}{b^{n(a+1)}}\prod_{i=1}^{n}x_i^a\cdot e^{-\frac{1}{b}\sum_{i=1}^{n}x_i}$

Logaritmăm funcția de verosimilitate: $\ln L(x,b)=-n(a+1)\ln b+\ln\left(\prod_{i=1}^{n}x_i^a\right)-\frac{1}{b}\sum_{i=1}^{n}x_i$;

Scriem ecuația de verosimilitate $\frac{\partial\ln L(x,b)}{\partial b}=0$ *care este echivalentă cu:* $-\frac{n(a+1)}{b}+\frac{1}{b^2}\sum_{i=1}^{n}x_i=0$,

soluția acestei ecuații fiind $\hat{b}=\frac{1}{n(a+1)}\sum_{i=1}^{n}x_i=\frac{\bar{x}}{a+1}$*. Verificăm că este punct de maxim:*

$\frac{\partial^2\ln L(x,b)}{\partial b^2}=-\frac{n(a+1)}{b^2}-\frac{2}{b^3}\sum_{i=1}^{n}x_i$ *, iar pentru* $b=\hat{b}=\frac{\bar{x}}{a+1}$*, avem* $\frac{\partial^2\ln L(x,b)}{\partial b^2}\left(\hat{b}\right)=-\frac{n(a+1)^3}{\bar{x}^2}<0$*, deci* $\hat{b}=\frac{\bar{x}}{a+1}$ *este punct de maxim al funcției* $L(x,b)$*.*