CURS 2+3 (PROBABILITĂȚI)
VARIABILE ALEATOARE. CARACTERISTICI ALE V.A.
REPARTIȚII CLASICE

1. VARIABILE ALEATOARE - DEFINIŢIE ŞI CLASIFICARE

Intuitiv, o *variabilă aleatoare* este o mărime care în urma realizării unei experienţe poate lua o valoare dintr-o mulţime bine definită (mulţimea valorilor posibile).

Variabila aleatoare este o funcţie reală care depinde de rezultatul unui anumit experiment:

- Fie $\{\Omega, K, P\}$ spaţiu de probabilitate. Funcţia $X:\Omega\to\mathbb{R}$ se numeşte **variabilă aleatoare** dacă:

$$\text{pentru } (\forall)a\in\mathbb{R},\ \left\{\omega\in\Omega \middle|\ X(\omega)<a\right\}\in K$$

Observaţie: Mulţimea valorilor variabilei aleatoare, $X(\Omega)$, este o submulţime a mulţimii numerelor reale ($X(\Omega)\subseteq\mathbb{R}$), adică *variabila aleatoare nu este obligatoriu o funcţie surjectivă*.

Prin variabilele aleatoare, unui fenomen supus unor circumstanţe aleatoare i se asociază un număr real, deci se stabileşte o corespondenţă între spaţiul de selecţie Ω, convenabil ales, şi $\mathbb{R}$.

În practică este dificil să găsim valorile acestor corespondenţe, dar este posibil să determinăm „cât de des" sunt luate aceste valori (cu ce probabilitate). Astfel, putem defini *funcţia de repartiţie a variabilei aleatoare* X.

- Fie $\{\Omega, K, P\}$ spaţiu de probabilitate şi $X:\Omega\to\mathbb{R}$ o variabilă aleatoare. Funcţia $F_X:\mathbb{R}\to[0,1]$ definită prin:

$$F_X(x)=P(X<x),\ \text{cu } x\in\mathbb{R}$$

se numeşte **funcţia de repartiţie** *(sau de* **distribuţie** *– en. cumulative distribution function) a variabilei aleatoare* X.

Clasificarea variabilelor aleatoare se face după proprietăţile mulţimii $X(\Omega)$:

a) **V.A. de tip discret** – dacă $X(\Omega)$ este mulţime cel mult numărabilă:
   - $X(\Omega)$ finită – *V.A. discretă simplă*
   - $X(\Omega)$ infinită dar numărabilă – *V.A. discretă cu o infinitate de valori*.

b) **V.A. de tip continuu** – dacă $X(\Omega)$ este o mulţime infinită de numere reale.

2. VARIABILE ALEATOARE DISCRETE SIMPLE

- *Variabila aleatoare discretă simplă* este o funcţie reală ale cărei valori sunt luate *cu probabilităţile corespunzătoare unui sistem complet de evenimente*.

Pentru a specifica o variabilă aleatoare discretă va trebui să enumerăm toate valorile posibile pe care aceasta le poate lua, împreună cu probabilităţile corespunzătoare. Suma tuturor acestor probabilităţi este întotdeauna egală cu 1, care este probabilitatea realizării evenimentului sigur. Când se face referire la *repartiţia* unei variabile aleatoare discrete simple, se înţelege *modul în care probabilitatea totală 1 este distribuită între toate posibilele valori ale variabilei respective*.

Pentru a specifica riguros o variabilă aleatoare discretă simplă, considerăm o experienţă şi legat de aceasta un *sistem complet de evenimente* $(A_i)_{1\le i\le n}$.

Definim funcţia X pe acest sistem complet de evenimente şi o reprezentăm prin tabelul de asociere (perechi ordonate) numit **tabloul de repartiţie** al variabilei aleatoare X:

$$X=\begin{pmatrix} x_1 & x_2 & .... & x_n \\ p_1 & p_2 & .... & p_n \end{pmatrix}, \text{ cu } p_i\ge 0 \text{ şi } \sum_{i=1}^{n} p_i = 1$$

unde numerele x_i se numesc *valorile variabilei aleatoare* iar p_i sunt probabilităţile cu care variabila aleatoare ia aceste valori:

$$p_i = P(A_i) = P\{X = x_i\} = P\left(\left\{\omega\in\Omega \,\middle|\, X(\omega)=x_i\right\}\right)$$

Convenţii:

- În tabloul de repartiţie se trec valorile *distincte* ale variabilei aleatoare;
- În tabloul de repartiţie NU se trec valorile luate cu probabilitatea 0.

2.1. Funcţia de repartiţie și funcția de probabilitate

Fie variabila aleatoare discretă simplă X, cu tabloul de repartiţie:

$$X=\begin{pmatrix} x_1 & x_2 & .... & x_n \\ p_1 & p_2 & .... & p_n \end{pmatrix}, \text{ cu } p_i\ge 0 \text{ şi } \sum_{i=1}^{n} p_i = 1$$

- **Funcția de probabilitate** (*en. probability mass function*) a unei variabile aleatoare discrete simple este *funcția care atașează fiecărei valori a variabilei probabilitatea cu care această valoare este luată*:

$$f(x_i) = p_i = P(X = x_i),\ i=\overline{1,n}$$

- **Funcția de repartiție** a unei variabile aleatoare discrete simple este funcția cumulativă:

$$F_X(x) = P(X<x) = \begin{cases} 0, & x < x_1 \\ p_1, & x_1 \le x < x_2 \\ p_1+p_2, & x_2 \le x < x_3 \\ p_1+p_2+...+p_{i-1}, & x_{i-1} \le x < x_i \\ ..... & \\ 1, & x \ge x_n \end{cases}$$

Proprietăţi:

1) Funcţie mărginită (valoarea minimă este 0, cea maximă 1).

2) F_X este o funcţie „treaptă”, *continuă la dreapta (şi discontinuă la stânga)* în punctele x_i, cu salturi egale cu p_i în aceste puncte.

3) Este nedescrescătoare ($F_X(x_1)\le F_X(x_2)$ dacă $x_1 < x_2$)

Observaţie*:* În definirea funcţiei de repartiție se pot folosi şi inegalităţile $x_{i-1} < x \le x_i$, ceea ce este corect dar duce la modificarea tipului de continuitate (în acest caz, F_X este continuă la stânga şi discontinuă la dreapta).

2.2. Reprezentare grafică

- Orice *variabilă aleatoare discretă simplă* dată prin tabloul său de repartiţie se poate reprezenta grafic prin segmente verticale (grafic de tip ”bară”): pe axa absciselor se trec valorile variabilei aleatoare, iar pe axa ordonatelor se trec probabilităţile corespunzătoare.
- Graficul *funcţiei de repartiţie (distribuție)* a unei variabile aleatoare discrete simple este o funcție de tip ”scară” (conform proprietăților sale).

2.3. Variabile aleatoare (discrete simple) independente

Fie variabilele aleatoare discrete simple X și Y cu tablourile de repartiție:

$$X=\begin{pmatrix} x_1 & x_2 & .... & x_n \\ p_1 & p_2 & .... & p_n \end{pmatrix},\ Y=\begin{pmatrix} y_1 & y_2 & .... & y_m \\ q_1 & q_2 & .... & q_m \end{pmatrix} \text{ cu } p_i, q_j \geq 0 \text{ şi } \sum_{i=1}^{n} p_i = \sum_{j=1}^{m} q_j = 1.$$

- X și Y se numesc **independente** (în totalitatea lor) dacă evenimentele $(X = x_i)$ și $(Y = y_j)$ cu $i=\overline{1,n}$ și $j=\overline{1,m}$ sunt independente, adică:

$$P\left[(X = x_i),(Y = y_j)\right] = P\left[(X = x_i)\cap(Y = y_j)\right] = p_i \cdot q_j$$

2.4. Operații cu variabile aleatoare discrete simple

Fie variabilele aleatoare discrete simple X , Y și Z cu tablourile de repartiție:

$$X=\begin{pmatrix} x_1 & x_2 & .... & x_n \\ p_1 & p_2 & .... & p_n \end{pmatrix},\ Y=\begin{pmatrix} y_1 & y_2 & .... & y_m \\ q_1 & q_2 & .... & q_m \end{pmatrix}$$

cu $p_i, q_j \geq 0$ şi $\sum_{i=1}^{n} p_i = \sum_{j=1}^{m} q_j = 1$. Putem defini următoarele operații (*care au ca rezultat tot variabile aleatoare simple*):

1. $a+X=\begin{pmatrix} a+x_i \\ p_i \end{pmatrix}_{i=\overline{1,n}}$ și $a\cdot X=\begin{pmatrix} a\cdot x_i \\ p_i \end{pmatrix}_{i=\overline{1,n}}$, cu $a\in\mathbb{R}$ constantă;

2. $X+Y=\begin{pmatrix} x_i+y_j \\ p_{ij} \end{pmatrix}_{\substack{i=\overline{1,n} \\ j=\overline{1,m}}}$, $X\cdot Y=\begin{pmatrix} x_i\cdot y_j \\ p_{ij} \end{pmatrix}_{\substack{i=\overline{1,n} \\ j=\overline{1,m}}}$ și $X^k=\begin{pmatrix} x_i^k \\ p_i \end{pmatrix}_{i=\overline{1,n}}$,

unde probabilitatea p_{ij} este probabilitatea realizării *simultane* a evenimentelor $(X = x_i)$ și $(Y = y_j)$.

Altfel spus, $p_{ij} = P\left[(X = x_i),(Y = y_j)\right] = P\left[(X = x_i)\cap(Y = y_j)\right]$.

Observații:

- Dacă variabilele aleatoare X și Y sunt *independente*, atunci $p_{ij} = p_i \cdot q_j$
- Dacă variabilele aleatoare X și Y *NU sunt independente*, atunci p_{ij} se poate determina doar din tabloul de repartiție al unui vector aleator bidimensional, discret.
- Suma și produsul se pot extinde și pentru trei sau mai multe variabile aleatoare.

Alte operații cu variabile aleatoare simple:

- **Inversa unei variabile aleatoare** X (care ia valori nenule) – este variabila $\frac{1}{X}$ care ia valoarea $\frac{1}{x_i}$ când X ia valoarea x_i (caz particular al ridicării la putere pentru $k=-1$);
- **Raportul a două variabile aleatoare** X **și** Y (unde Y nu ia valori nule) – este un caz particular al înmulțirii variabilei X cu variabila $\frac{1}{Y}$).

3. VARIABILE ALEATOARE CONTINUE

3.1. Funcţia de repartiţie și densitatea de repartiție

Reamintim că **funcţia de repartiție** a unei variabilei aleatoare X este o funcție $F_X:\mathbb{R}\to[0,1]$, definită prin: $F_X(x)=P(X<x)$, cu $x\in\mathbb{R}$.

Dacă X este o *variabilă aleatoare continuă*, funcția ei de repartiție are următoarele proprietăți:

1) Funcţie mărginită: $\lim\limits_{x\to-\infty}F(x)=0$ şi $\lim\limits_{x\to+\infty}F(x)=1$;

2) F_X este *continuă la stânga* : $F(x-0)=F(x)$ pentru $\forall x\in\mathbb{R}$, şi are un număr cel mult numărabil de puncte de discontinuitate de prima speţă;

3) Este nedescrescătoare ($F_X(x_1)\le F_X(x_2)$ dacă $x_1<x_2$, pentru $\forall x_1,x_2\in\mathbb{R}$).

▪ Fie $\{\Omega,K,P\}$ câmp de probabilitate. Considerăm o clasă de variabile aleatoare X pentru care există o funcţie $f:\mathbb{R}\to[0,+\infty)$ cu un număr finit de puncte de discontinuitate de prima speţă (deci integrabilă), ce satisface relaţia:

$$\boxed{P(X<x)\overset{def}{=}F(x)=\int_{-\infty}^{x}f(t)dt}$$

unde $F(x)$ este funcţia de repartiţie a variabilei X. Atunci funcţia f se numeşte **densitate de repartiție** a variabilei aleatoare X.

O variabilă aleatoare continuă se reprezintă cu ajutorul densității de repartiție sub forma:

$$X=\begin{pmatrix}x\\f(x)\end{pmatrix}$$

Observaţie*:* Dacă f este continuă în $x\in\mathbb{R}$, atunci F este derivabilă în x şi avem: $F'(x)=f(x)$.

Proprietăţi ale densității de repartiție:

1) Funcţie pozitivă: $f(x)\ge 0$, pentru $\forall x\in\mathbb{R}$

2) $\int_{-\infty}^{\infty}f(x)dx=1$

3) Dacă $a,b\in\mathbb{R}$ şi F continuă, atunci $P(a\le X<b)=\int_a^b f(x)dx=F(b)-F(a)$.

Observație: Fie o variabilă aleatoare continuă X cu funcția de repartiție $F_X(x)=P(X<x)$, $x\in\mathbb{R}$. Atunci pentru orice $a,b\in\mathbb{R}$, cu $a<b$, avem:

- $P(X=a)=0$;
- $P(a\le X<b)=P(a<X<b)=P(a<X\le b)=P(a\le X\le b)=\int_a^b f(x)dx=F(b)-F(a)$

3.2. Operații cu variabile aleatoare continue

Operațiile cu variabile aleatoare continue se definesc natural cu ajutorul *densității de repartiție comună* (adică cu ajutorul vectorilor aleatori bidimensionali – pe care îi vom studia într-un curs viitor).

CARACTERISTICI NUMERICE ALE VARIABILELOR ALEATOARE

În cele ce urmează, *pentru cazul discret* vom considera o variabilă aleatoare de forma:

$$X=\begin{pmatrix} x_1 & x_2 & .... & x_n \\ p_1 & p_2 & .... & p_n \end{pmatrix}, \text{ cu } p_i\ge 0 \text{ şi } \sum_{i=1}^{n} p_i=1$$

iar pentru *cazul continuu* vom considera o variabilă aleatoare $X=\begin{pmatrix} x \\ f(x) \end{pmatrix}$, cu $x\in\mathbb{R}$.

1. MEDIA

Pentru o variabilă aleatoare, **media** (*en. mean, expected value*) este o măsură a tendinței centrale a valorilor sale.

- Dacă X este variabilă aleatoare *discretă simplă*, cu funcția de probabilitate $f(x_i)=p_i$, media ei este numărul:

$$\boxed{M[X]=x_1\cdot p_1+x_2\cdot p_2+.....+x_n\cdot p_n=\sum_{i=1}^{n} x_i\cdot p_i}$$

- Dacă X este variabilă aleatoare *continuă*, cu densitatea de repartiție $f(x)$, media ei este integrala improprie:

$$\boxed{M[X]=\int_{-\infty}^{+\infty} x\cdot f(x)dx} \text{ (trebuie să fie convergentă)}$$

Observație: Dacă $g(x)$ este o funcție și X este o variabilă aleatoare, atunci *media variabilei aleatoare* $g(X)$ este $M[g(X)]=\sum_{i=1}^{n} g(x_i)\cdot p_i$ (pentru cazul discret) și respectiv $M[g(X)]=\int_{-\infty}^{+\infty} g(x)\cdot f(x)dx$ (pentru cazul continuu).

Notații uzuale pentru medie: m, $E[X]$, μ.

Observaţie: Pentru cazul discret cu o infinitate de valori numărabile, media variabilei aleatoare se definește prin *seria* $\sum_{i=1}^{\infty} x_i p_i$ care trebuie să fie *convergentă*. Dacă seria este divergentă, variabila aleatoare

NU are medie. Similar, dacă integrala improprie care definește media unei variabile continue nu este convergentă, atunci respectiva variabilă NU are medie.

Proprietăţi ale mediei

1) valoarea medie a unei constante este egală cu constanta: $M\left[c\right]=c$

2) dacă X este o variabilă aleatoare şi $a\in\mathbb{R}$ o constantă, atunci au loc relaţiile:

$$M\left[a+X\right]=a+M\left[X\right] \quad \text{şi} \quad M\left[a\cdot X\right]=a\cdot M\left[X\right]$$

3) valoarea medie a unei variabile aleatoare este cuprinsă între cea mai mică şi cea mai mare dintre valorile posibile ale variabilei aleatoare:

$$a<M\left[X\right]<A$$

(unde am notat $a=\min_i x_i$ şi $A=\max_i x_i$)

4) valoarea medie a unei sume finite de variabile aleatoare este egală cu suma valorilor medii ale variabilelor aleatoare respective:

$$M\left[X+Y+Z+...\right]=M\left[X\right]+M\left[Y\right]+M\left[Z\right]+....$$

5) valoarea medie a unui produs de variabile aleatoare <u>*independente*</u> este egală cu produsul mediilor variabilelor considerate:

$$M\left[X\cdot Y\cdot Z\cdot...\right]=M\left[X\right]\cdot M\left[Y\right]\cdot M\left[Z\right]\cdot....$$

Dacă variabilele aleatoare NU sunt independente, se calculează variabila produs şi apoi media ei, cu definiţia.

6) oricare ar fi variabila aleatoare X, are loc relaţia:

$$\left(M\left[X\right]\right)^2\le M\left[X^2\right]$$

2. MOMENT INIȚIAL DE ORDIN k

Pentru o variabilă aleatoare X, *momentul inițial de ordin* k, cu $k\in\mathbb{N}$, este *media variabilei* X^k.

Notații uzuale: m_k sau $M_k\left[X\right]$ sau $M\left[X^k\right]$.

- Dacă X este variabilă aleatoare discretă simplă:

$$\boxed{m_k=M\left[X^k\right]=\sum_{i\ge1}x_i^k\cdot p_i}$$

- Dacă X este variabilă aleatoare continuă:

$$\boxed{m_k=M\left[X^k\right]=\int_{-\infty}^{\infty}x^k\cdot f\left(x\right)dx}$$

<u>Observaţii</u>:

- Momentul iniţial de ordinul 0 al unei variabile aleatoare X este:

$$m_0=M\left[X^0\right]=M\left[1\right]=1$$

- Momentul iniţial de ordinul 1 al unei variabile aleatoare X este chiar media variabilei:

$$m_1=M\left[X^1\right]=M\left[X\right].$$

3. MOMENT CENTRAT DE ORDIN k

În raport cu variabila aleatoare X, se numeşte *moment centrat de ordin* k *raportat la constanta* a *media variabilei* $(X-a)^k$.

Pentru $a = M[X]$ (constanta este media variabilei X), obţinem **momentul centrat de ordin** k **al variabilei** X:

- Dacă X este variabilă aleatoare discretă simplă:

$$\mu_k(X) = M\left((X - M[X])^k\right) = \sum_{i\geq 1}(x_i - M[X])^k \cdot p_i$$

- Dacă X este variabilă aleatoare continuă:

$$\mu_k(X) = M\left((X - M[X])^k\right) = \int_{-\infty}^{\infty}(x-m)^k\, f(x)\,dx$$

Observaţie: Variabila aleatoare $X - M[X]$ se numeşte **abaterea de la medie** a variabilei aleatoare X.
Evident, media acestei variabile este nulă: $M[X - M[X]] = 0$.

4. DISPERSIA

Pentru o variabilă aleatoare care are medie finită, **dispersia** *(sau* **varianța**, *en. variance) este un indicator numeric al gradului de împrăștiere (dispersare) a valorilor variabilei aleatoare în jurul mediei .*

Notații uzuale: $D^2[X]$, σ^2, $Var[X]$.

Dispersia variabilei aleatoare X este *momentul centrat de ordinul 2 al variabilei*:

$$D^2[X] = M\left[(X-m)^2\right], \text{ unde } m = M[X]$$

- Dacă X este variabilă aleatoare *discretă simplă*, cu funcția de probabilitate $f(x_i) = p_i$, dispersia ei este:

$$\boxed{D^2[X] = \sum_{i=1}^{n}(x_i - m)^2 \cdot p_i}$$

- Dacă X este variabilă aleatoare *continuă*, cu densitatea de repartiție $f(x)$, dispersia ei este integrala improprie:

$$\boxed{D^2[X] = \int_{-\infty}^{\infty}(x-m)^2 \cdot f(x)\,dx}$$

Formulă de lucru utilă (indiferent de tipul variabilei aleatoare):

$$\boxed{D^2[X] = M[X^2] - (M[X])^2}$$

Proprietăţi ale dispersiei

1) dispersia unei constante este nulă: $D^2[c] = 0$

2) două variabile aleatoare care diferă printr-o constantă au dispersiile egale:

$$D^2[a + X] = D^2[X].$$

3) $D^2[aX] = a^2 D^2[X]$.

4) dispersia unei sume finite de variabile aleatoare independente (în totalitate sau două câte două) este egală cu suma dispersiilor:

$$D^2\left[X+Y+Z+...\right]=D^2\left[X\right]+D^2\left[Y\right]+D^2\left[Z\right]+...$$

5. ABATEREA STANDARD

În practică nu se foloseşte dispersia (care, din punct de vedere dimensional reprezintă pătratul variabilei în cauză) ci **abaterea standard** (*en. standard deviation*): $\sigma=\sqrt{D^2\left[X\right]}$, care are avantajul exprimării prin aceleaşi unităţi de măsură ca şi valorile variabilei aleatoare X.

Proprietăţi ale abaterii standard (rezultă din proprietăţile dispersiei):

a) $\sigma\left[c\right]=0$, unde $c\in\mathbb{R}$;

b) $\sigma\left[a+X\right]=\sigma\left[X\right]$;

c) $\sigma\left[aX\right]=\left|a\right|\cdot\sigma\left[X\right]$.

6. COVARIANȚA

Covarianța este un indicator numeric al legăturii dintre 2 variabile aleatoare și reprezintă momentul centrat mixt al celor două variabile.
Acest indicator se poate calcula dacă momentele inițiale de ordinul 1 și 2 ale celor două variabile aleatoare există și sunt finite.

Covarianța variabilelor aleatoare X şi Y se definește prin:

$$Cov\left[X,Y\right]=M\left[\left(X-M\left[X\right]\right)\left(Y-M\left[Y\right]\right)\right]$$

sau (formulă echivalentă): $\boxed{Cov\left[X,Y\right]=M\left[XY\right]-M\left[X\right]M\left[Y\right]}$

Proprietăţi ale covarianței

1) $Cov\left[X,Y\right]=Cov\left[Y,X\right]$;

2) $Cov\left[X,X\right]=D^2\left[X\right]$;

3) Pentru orice două constante $a,b\in\mathbb{R}$ avem: $Cov\left[X+a,Y+b\right]=Cov\left[X,Y\right]$;

4) Cu ajutorul covarianței se poate exprima *dispersia sumei* a două variabile aleatoare X şi Y:

$$\boxed{D^2\left[X\pm Y\right]=D^2\left[X\right]+D^2\left[Y\right]\pm 2Cov\left[X,Y\right]}$$

5) Dacă X şi Y sunt variabile aleatoare *independente*, atunci $Cov\left[X,Y\right]=0$. **RECIPROC NU ESTE ADEVĂRAT**: variabilele aleatoare X şi Y pot avea covarianța nulă și să nu fie independente (un exemplu în acest sens se poate da doar cu ajutorul vectorilor bidimensionali aleatori).

7. COEFICIENTUL DE CORELAȚIE

Coeficientul de corelație al variabilelor aleatoare X şi Y (cu abaterile standard $\sigma_X\neq 0$ şi $\sigma_Y\neq 0$) este o *măsură a <u>dependenței liniare</u> dintre cele două variabile* și este reprezentat de numărul:

$$\boxed{\rho\left[X,Y\right]=\frac{Cov\left[X,Y\right]}{\sigma_X\cdot\sigma_Y}}.$$

Valoarea pozitivă a coeficientului de corelație indică faptul că valorile celor două variabile aleatoare cresc sau descresc împreună, iar o valoare negativă a coeficientului de corelație indică faptul că valorile uneia dintre variabile cresc în timp ce valorile celeilalte descresc.

Proprietăți ale coeficientului de corelație

1) Dacă X şi Y sunt variabile aleatoare *independente*, atunci $\rho[X,Y]=0$. Reciproca NU este adevărată. (variabilele aleatoare pot fi necorelate – ceea ce este echivalent cu faptul că au covarianța nulă – fără a fi independente.

2) Pentru orice variabile aleatoare X şi Y avem: $-1\le\rho[X,Y]\le 1$;

3) Dacă pentru două constante reale a şi b, variabila aleatoare Y se poate scrie: $Y=aX+b$, atunci: $\rho[X,Y]=\begin{cases}1, & a>0\\ -1, & a<0\end{cases}$ (a se vedea în acest sens și subcapitolul 6.4.2. pentru legătura dintre coeficientul de corelație și dreapta de regresie).

***Observație*:** Corelațiile ”puternice” între două variabile au coeficientul de corelație (în modul) cât mai apropiat de 1. Cu cât valoarea coeficientului de corelație este mai aproape de 0, cu atât ipoteza conform căreia cele două variabile sunt necorelate este mai ușor de acceptat. În statistică, valori ale coeficientului de corelație de 0.12 sau -0.15 indică faptul că cele două variabile nu prezintă o asociere de tip liniar.

8. FUNCȚIA GENERATOARE DE MOMENTE

Se folosește pentru simplificarea calculelor momentelor unei variabile aleatoare.

- Se numeşte **funcţie generatoare de momente** a unei variabile aleatoare X, valoarea medie a variabilei $e^{t\cdot X}$, unde $t\in\mathbb{R}$.

Notăm funcţia generatoare de momente cu $g:\mathbb{R}\to\mathbb{R}$, dată prin: $\boxed{g_X(t)=M\left[e^{t\cdot X}\right]}$.

- Dacă X este variabilă aleatoare *discretă simplă*:

$$\boxed{g_X(t)=M\left[e^{t\cdot X}\right]=\sum_{i=1}^{n}e^{t\cdot x_i}p_i}$$

- Dacă X este variabilă aleatoare *continuă*:

$$\boxed{g_X(t)=M\left[e^{t\cdot X}\right]=\int_{-\infty}^{\infty}e^{t\cdot x}f(x)dx}$$

Proprietăți ale funcţiei generatoare de momente

Considerăm variabila aleatoare X cu funcția generatoare de momente $g_X(t)$. Atunci:

1) $g_X(0)=1$;

2) Dacă $X_1,X_2,....,X_n$ sunt variabile aleatoare *independente* atunci:

$$\boxed{g_{X_1+X_2+...+X_n}(t)=g_{X_1}(t)\cdot g_{X_2}(t)\cdot....\cdot g_{X_n}(t)}$$

3) Dacă $Y=aX+b$, cu $a,b\in\mathbb{R}$ atunci:

$$\boxed{g_Y(t)=g_X(at)\cdot e^{bt}}$$

4) Dacă X admite momente finite de orice ordin, atunci $g_X(t)=\sum_{k=0}^{\infty}\frac{t^k}{k!}\cdot m_k$.

5) Formula generării momentelor iniţiale

Funcţia generatoare de momente este de n ori derivabilă în raport cu t şi $g^{(k)}(0)=m_k$ (sau $g^{(k)}(t)\big|_{t=0}=m_k$).

6) Dacă X este variabilă aleatoare *discretă simplă*, forma derivatei de ordin k a funcţiei $g_X(t)=\sum_{i=1}^{n}e^{t\cdot x_i}p_i$ este: $g_X{}^{(k)}(t)=\sum_{i=1}^{n}x_i{}^k\cdot e^{t\cdot x_i}p_i$, deci înlocuind pe t cu 0 obţinem:

$$\boxed{g_X{}^{(k)}(0)=\sum_{i=1}^{n}x_i{}^k p_i=m_k}$$

7) Dacă X este variabilă aleatoare *continuă*, forma derivatei de ordin k a funcţiei $g_X(t)=\int_{-\infty}^{\infty}e^{t\cdot x}f(x)dx$ este: $g_X{}^{(k)}(t)=\int_{-\infty}^{\infty}x^k\cdot e^{t\cdot x}f(x)dx$, deci înlocuind pe t cu 0 obţinem:

$$\boxed{g_X{}^{(k)}(0)=\int_{-\infty}^{\infty}x^k f(x)dx=m_k}$$

9. FUNCȚIA CARACTERISTICĂ

Funcția caracteristică este foarte utilă în studiul unei variabile aleatoare deoarece cu ajutorul ei se pot determina funcția de repartiție și momentele de orice ordin ale variabilei aleatoare. Pe de altă parte, calculul cu funcții de repartiție poate fi dificil (datorită discontinuităților acestor funcții) dar calculele cu funcția caracteristică sunt mai facile (funcțiile caracteristice sunt continue).

De asemenea, faptul că produsului de convoluție a două funcții de repartiție îi corespunde produsul obișnuit al funcțiilor caracteristice constituie un avantaj în studiul diferitelor proprietăți ale variabilelor aleatoare.

Pentru introducerea noțiunii de funcție caracteristică este necesară extinderea definiției variabilei aleatoare reale și în cazul complex.

- Fie câmpul de probabilitate $\{\Omega,K,P\}$ și variabilele aleatoare $X,Y:\Omega\to\mathbb{R}$. Se numește **variabilă aleatoare complexă** variabila $Z=X+iY$ (unde $i^2=-1$). Valoarea medie a variabilei complexe este: $M[Z]=M[X]+i\cdot M[Y]$, dacă mediile $M[X]$ și $M[Y]$ există.

- Se numeşte **funcţie caracteristică** a unei variabile aleatoare X, valoarea medie a variabilei $e^{i\cdot t\cdot X}$, unde $t\in\mathbb{R}$ şi $i^2=-1$.

Notăm funcţia caracteristică cu $\varphi:\mathbb{R}\to\mathbb{C}$, dată prin: $\boxed{\varphi_X(t)=M\left[e^{i\cdot t\cdot X}\right]}$.

- Dacă X este variabilă aleatoare *discretă simplă*:

$$\boxed{\varphi_X(t)=M\left[e^{i\cdot t\cdot X}\right]=\sum_{k=1}^{n}e^{i\cdot t\cdot x_k}p_k}$$

- Dacă X este variabilă aleatoare *continuă*:

$$\boxed{\varphi_X(t)=M\left[e^{i\cdot t\cdot X}\right]=\int_{-\infty}^{\infty}e^{i\cdot t\cdot x}f(x)dx}$$

Deoarece $\left|e^{i\cdot t\cdot x}\right|=1$, funcția caracteristică *există pentru orice variabilă aleatoare* și este *unic determinată* de funcția de repartiție.

Dacă se cunoaște funcția caracteristică a unei variabile aleatoare continue, cum se poate determina funcția de repartiție?

- **Teorema de inversiune**: Fie X o variabilă aleatoare pentru care se cunoaște $\varphi_X(t)$ și a cărei funcție de repartiție este F. Dacă $x_1 < x_2$ sunt două puncte de continuitate pentru F, atunci:

$$\boxed{F(x_2) - F(x_1) = \frac{1}{2\pi} \lim_{a\to\infty} \int_{-a}^{a} \frac{e^{-itx_1} - e^{-itx_2}}{it} \varphi(t)\,dt}$$

- Dacă $\varphi_X(t)$ este absolut integrabilă pe $\mathbb{R}$, atunci funcția de repartiție F are derivata f continuă (densitatea de repartiție) și avem:

$$\boxed{f(x) = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-itx} \varphi(t)\,dt}$$

deci densitatea de repartiție a lui X este *transformata Fourier* a lui $\varphi_X(t)$.

Observație: Pentru orice $\alpha \in \mathbb{R}$ putem scrie: $e^{i\cdot\alpha} = \cos\alpha + i\sin\alpha$ şi respectiv: $e^{-i\cdot\alpha} = \cos\alpha - i\sin\alpha$.

Proprietăţi ale funcţiei caracteristice

Considerăm variabila aleatoare X cu funcția caracteristică $\varphi_X(t)$. Atunci:

1) $\varphi_X(t)$ este o funcţie uniform continuă pe $\mathbb{R}$;

2) $\varphi_X(0) = 1$ și $|\varphi_X(t)| \le 1$, pentru $\forall t \in \mathbb{R}$;

3) $\overline{\varphi_X(t)} = \varphi_X(-t)$, pentru $\forall t \in \mathbb{R}$;

4) Dacă $X_1, X_2, ..., X_n$ sunt variabile aleatoare *independente* atunci:

$$\boxed{\varphi_{X_1+X_2+...+X_n}(t) = \varphi_{X_1}(t)\cdot\varphi_{X_2}(t)\cdot....\cdot\varphi_{X_n}(t)}$$

Consecinţe:

4.1) Dacă $Y = \sum_{k=1}^{n} \lambda_k \cdot X_k$, cu $\lambda_k \in \mathbb{R}$, atunci $\boxed{\varphi_Y(t) = \prod_{k=1}^{n} \varphi_{X_k}(\lambda_k t)}$.

4.2) *Un produs de funcţii caracteristice este tot o funcţie caracteristică*.

În particular, $\left[\varphi_X(t)\right]^n$ este tot o funcţie caracteristică.

5) Dacă $Y = aX$, cu $a \in \mathbb{R}$, atunci:

$$\boxed{\varphi_Y(t) = \varphi_X(at)}$$

6) Dacă $Y = aX + b$, cu $a, b \in \mathbb{R}$ atunci:

$$\boxed{\varphi_Y(t) = \varphi_X(at)\cdot e^{ibt}}$$

7) Dacă X admite momente finite de orice ordin, atunci $\varphi_X(t) = \sum_{k=0}^{\infty} \frac{(it)^k}{k!} \cdot m_k$.

8) Formula de legătură cu momentele iniţiale. Funcţia caracteristică este de n ori derivabilă în raport cu t şi $\frac{1}{i^k}\varphi_X{}^{(k)}(0) = m_k$ (sau $\frac{1}{i^k}\varphi^{(k)}(t)\big|_{t=0} = m_k$).

9) Dacă X este variabilă aleatoare *discretă simplă*, forma derivatei de ordin k a funcţiei $\varphi_X(t)=\sum_{j=1}^{n} e^{i\cdot t\cdot x_j}p_j$ este: $\varphi_X{}^{(k)}(t)=\sum_{j=1}^{n} i^k\cdot x_j{}^k\cdot e^{i\cdot t\cdot x_j}p_j$, deci înlocuind pe t cu 0 obţinem:

$$\boxed{\varphi_X{}^{(k)}(0)=i^k\sum_{j=1}^{n} x_j{}^k p_j=i^k\cdot m_k}$$

10) Dacă X este variabilă aleatoare *continuă*, forma derivatei de ordin k a funcţiei $\varphi_X(t)=\int_{-\infty}^{\infty} e^{i\cdot t\cdot x}f(x)dx$ este: $\varphi_X{}^{(k)}(t)=\int_{-\infty}^{\infty} i^k\cdot x^k\cdot e^{i\cdot t\cdot x}f(x)dx$, deci înlocuind pe t cu 0 obţinem:

$$\boxed{\varphi_X{}^{(k)}(0)=i^k\int_{-\infty}^{\infty} x^k\cdot e^{i\cdot t\cdot x}f(x)dx=i^k\cdot m_k}$$

10. ALTE CARACTERISTICI NUMERICE *(opțional)*

10.1. Coeficientul de variație

Acest coeficient se folosește cu precădere în statistică, pentru compararea variațiilor a două sau mai multe seturi de date (selecții) corespunzătoare unei caracteristici de interes, reprezentate de o variabilă aleatoare X. Dacă dispersiile sunt egale, atunci selecția care are media mai mică prezintă o variație mai mare a valorilor.

Pentru o variabilă aleatoare X, **coeficientul de variație** este numărul real:

$$\boxed{CV=\frac{\sigma}{m}},$$

unde σ este abaterea standard iar m este media variabilei.

Uneori coeficientul de variație se poate folosi și sub formă de procente: $CV=\frac{\sigma}{m}\cdot 100\%$

10.2. Asimetria

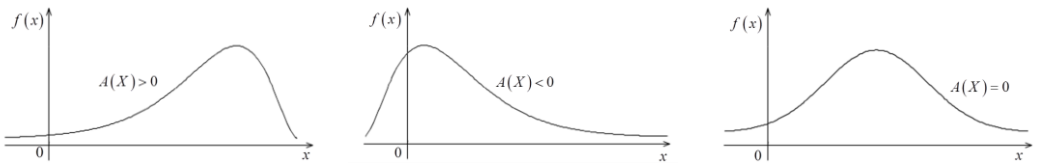
Pentru o variabilă aleatoare X, **asimetria** (coeficientul de asimetrie, *en. skewness*) este numărul real (dacă există):

$$\boxed{A(X)=\frac{\mu_3(X)}{\sigma^3}}$$

unde $\mu_3(X)=M\left(\left(X-M[X]\right)^3\right)$ este momentul centrat de ordinul 3 al variabilei aleatoare iar σ este abaterea standard.

Asimetria furnizează informații despre forma graficului repartiției variabilei aleatoare X. Dacă $f(x)$ este densitatea de repartiție a lui X, atunci:

- $A(X)>0 \Rightarrow$ graficul lui f are ”coadă” la stânga;
- $A(X)<0 \Rightarrow$ graficul lui f are ”coadă” la dreapta;
- $A(X)=0 \Rightarrow$ graficul lui f este simetric în raport cu media.



10.3. Aplatizarea

Pentru o variabilă aleatoare X , **aplatizarea** (*coeficientul de aplatizare*, *excesul sau boltirea, en. kurtosis*) este numărul real (dacă există):

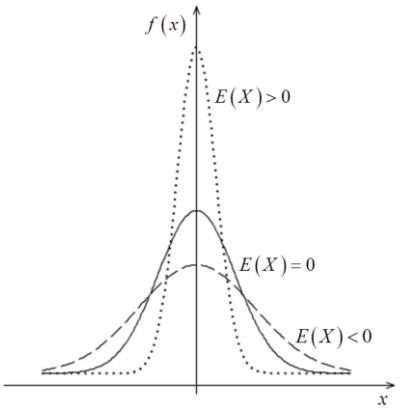
$$\boxed{E(X)=\frac{\mu_4(X)}{\sigma^4}-3}$$

unde $\mu_4(X)=M\left(\left(X-M[X]\right)^4\right)$ este momentul centrat de ordinul 4 al variabilei aleatoare iar σ este abaterea standard.

Aplatizarea se folosește pentru a compara gradul de împrăștiere al unei variabile aleatoare continue în raport cu împrăștierea variabilei aleatoare normale standard $\mathcal{N}(0,1)$ (descrisă în Capitolul 5).

Dacă $f(x)$ este densitatea de repartiție a lui X , atunci:

- $E(X)>0 \Rightarrow$ *repartiție leptocurtică* - graficul lui f are împrăștiere mai mică decât $\mathcal{N}(0,1)$ (este mai ”ascuțit”);
- $E(X)<0 \Rightarrow$ *repartiție platicurtică* - graficul lui f are împrăștiere mai mare decât $\mathcal{N}(0,1)$ (este mai ”turtit”);
- $E(X)=0 \Rightarrow$ *repartiție mezocurtică* - graficul lui f coincide cu graficul $\mathcal{N}(0,1)$.



REPARTIŢII CLASICE

Repartiții ale variabilelor aleatoare discrete simple

1. Repartiția Bernoulli

Variabila aleatoare Bernoulli este folosită pentru descrierea unei experiențe cu numai două rezultate posibile (complementare), în situația în care experiența se efectuează o singură dată (de exemplu, aruncarea unei monede care are ca rezultate posibile obținerea ”banului” sau a ”stemei”, extragerea unei bile dintr-o urnă care conține bile de 2 culori, etc).

Deseori, cele 2 rezultate posibile, complementare, descrise printr-o variabilă Bernoulli sunt numite generic ”succes” și ”insucces” (”succesul” este rezultatul care ne interesează, pe care îl contorizăm și nu are întotdeauna conotație pozitivă – de exemplu, ne interesează probabilitatea găsirii unei piese defecte într-un lot de piese, caz în care ”succesul” este atribuit extragerii unei piese defecte).

Atribuind, formal, valoarea 1 pentru ”succes” și valoarea 0 pentru ”insucces”, reprezentarea unei variabile aleatoare Bernoulli este:

$$X = \begin{pmatrix} 0 & 1 \\ q & p \end{pmatrix}$$

unde p este probabilitatea evenimentului de care suntem interesați (”succesul”) iar q este probabilitatea evenimentului contrar: $p+q=1.$

Parametrul repartiției Bernoulli: p ;

Media: $M\left[X\right]=p$; ***Dispersia:*** $D^2\left[X\right]=p\left(1-p\right).$

Funcția generatoare de momente: $g_X\left(t\right)=\left(1-p\right)+p\cdot e^t$

Funcția caracteristică: $\varphi_X\left(t\right)=\left(1-p\right)+p\cdot e^{it}$

2. Repartiția binomială

Repartiția binomială reprezintă o generalizare a repartiției Bernoulli și este folosită pentru descrierea unei experiențe cu numai două rezultate posibile (complementare), în situația în care experiența se repetă de n ori (evident, în condiții similare, fără a se modifica probabilitatea de apariție a celor două rezultate). Reprezentarea unei variabile aleatoare X cu repartiție binomială este:

$$X = \begin{pmatrix} 0 & 1 & \dots & k & \dots & n \\ C_n^0 p^0 q^n & C_n^1 p^1 q^{n-1} & \dots & C_n^k p^k q^{n-k} & \dots & C_n^k p^n q^0 \end{pmatrix} = \begin{pmatrix} k \\ C_n^k p^k q^{n-k} \end{pmatrix}$$

unde p este probabilitatea evenimentului de care suntem interesați iar q este probabilitatea evenimentului contrar: $p+q=1.$

Se notează: $X \in Bi\left(n,p\right).$

Valorile variabilei aleatoare (de la 0 la n) corespund numărului de apariții ale rezultatului (evenimentului) de care suntem interesați (denumit, generic, ”succes”, ca și în cazul variabilei aleatoare Bernoulli).

Parametrii repartiției binomiale: n și p ;

Media: $M\left[X\right]=n\cdot p$; ***Dispersia:*** $D^2\left[X\right]=n\cdot p\cdot\left(1-p\right).$

Funcția generatoare de momente: $g_X\left(t\right)=\left(p\cdot e^t+1-p\right)^n$

Funcția caracteristică: $\varphi_X\left(t\right)=\left(p\cdot e^{it}+1-p\right)^n$

3. Repartiția Poisson (legea evenimentelor rare)

Este un caz particular al repartiției binomiale, când numărul de repetiții ale experienței este foarte mare iar probabilitatea evenimentului de care suntem interesați este foarte mică (”eveniment rar”).

În repartiția binomială, dacă $n \to \infty$, $p \to 0$ dar produsul $n \cdot p = \lambda$ rămâne constant, se obține repartiția Poisson (în general, pentru $p < 0{,}1$ și $n \cdot p > 5$ se poate folosi repartiția Poisson ca o bună aproximare a repartiției binomiale).

Reprezentarea unei variabile aleatoare X cu repartiție Poisson este:

$$X = \begin{pmatrix} 0 & 1 & 2 & \dots & n & \dots \\ e^{-\lambda} & \frac{\lambda}{1!}e^{-\lambda} & \frac{\lambda^2}{2!}e^{-\lambda} & \dots & \frac{\lambda^n}{n!}e^{-\lambda} & \dots \end{pmatrix} = \begin{pmatrix} k \\ e^{-\lambda}\frac{\lambda^k}{k!} \end{pmatrix}, \text{ cu } k \in \mathbb{N} \text{ şi } \lambda > 0$$

Dacă notăm cu a numărul de apariții ale unui eveniment în unitatea de timp, atunci $\lambda = a \cdot t$ reprezintă media aparițiilor evenimentului într-un interval de timp de lungime t. Probabilitatea apariției de k ori a evenimentului în intervalul de timp de lungime t este $P(X = k) = e^{-\lambda}\frac{\lambda^k}{k!}$.

Parametrul repartiției Poisson: λ;

Media: $M[X] = \lambda$; ***Dispersia:*** $D^2[X] = \lambda$;

Funcția generatoare de momente: $g_X(t) = e^{\lambda(e^t - 1)}$;

Funcția caracteristică: $\varphi_X(t) = e^{\lambda(e^{it} - 1)}$.

4. Repartiția geometrică (a „primului succes”, repartiţia Pascal)

Variabila aleatoare geometrică reprezintă numărul de încercări efectuate într-un șir de experimente Bernoulli independente, cu același parametru p, până la apariția primului ”succes”. De exemplu, numărul de aruncări ale unui zar până la obținerea feței cu 6 puncte (”succesul”) este o variabilă aleatoare geometrică cu parametrul $p = 1/6$, fiecare aruncare a zarului fiind asociată cu un experiment de tip Bernoulli (”succesul” este fața cu 6 puncte, deci $p = 1/6$ iar ”insuccesul” este reprezentat de toate celelalte fețe, cu $q = 5/6$).

Reprezentarea unei variabile aleatoare X cu repartiție geometrică este:

$$X = \begin{pmatrix} 1 & 2 & 3 & .... & n & .... \\ p & p \cdot q & p \cdot q^2 & .... & p \cdot q^{n-1} & .... \end{pmatrix}, \text{ cu } 0 < p, q < 1 \text{ şi } p + q = 1$$

Parametrul repartiției geometrice: p;

Media: $M[X] = \frac{1}{p}$; ***Dispersia:*** $D^2[X] = \frac{1-p}{p^2}$.

Funcția generatoare de momente: $g_X(t) = \frac{p}{(1-p)\left[1-(1-p)\cdot e^t\right]}$, $t < -\ln(1-p)$;

Funcția caracteristică: $\varphi_X(t) = \frac{p}{(1-p)\left[1-(1-p)\cdot e^{it}\right]}$.

5. Repartiția binomială negativă

Variabila aleatoare binomială negativă este o generalizare a variabilei aleatoare geometrice și reprezintă numărul de încercări efectuate într-un șir de experimente Bernoulli cu parametrul p până la obținerea a $k \geq 1$ "succese".

Numele de "negativă" provine din faptul că, dacă la variabila aleatoare binomială numărul de încercări n era fixat și numărul k de succese era aleator, la variabila aleatoare binomială negativă numărul de succese k este fixat iar numărul de încercări este aleator. Variabila aleatoare binomială negativă este, într-un anumit sens, "opusa / negativa" variabilei aleatoare binomiale.

Reprezentarea unei variabile aleatoare X cu repartiție binomială negativă este:

$$X = \begin{pmatrix} k & k+1 & k+2 & k+3 & ..... \\ C_{k-1}^{k-1} p^k q^0 & C_k^{k-1} p^k q^1 & C_{k+1}^{k-1} p^k q^2 & C_{k+2}^{k-1} p^k q^3 & ..... \end{pmatrix} = \begin{pmatrix} x \\ C_{x-1}^{k-1} p^k q^{x-k} \end{pmatrix}, \text{ cu } k, x \in \mathbb{N}^* \text{ și } x \geq k$$

Parametrii repartiției binomiale negative: p și k;

Media: $M[X] = \frac{k}{p}$; ***Dispersia:*** $D^2[X] = \frac{k(1-p)}{p^2}$;

Funcția generatoare de momente: $g_X(t) = \left(\frac{p \cdot e^t}{1-(1-p) \cdot e^t} \right)^k$, $t < -\ln(1-p)$;

Funcția caracteristică: $\varphi_X(t) = \left(\frac{p \cdot e^{it}}{1-(1-p) \cdot e^{it}} \right)^k$.

6. Repartiția uniformă discretă

Variabila aleatoare uniformă (discretă) este folosită pentru descrierea unei experiențe cu n rezultate posibile echiprobabile (deci probabilitatea realizării oricăruia dintre rezultate este $p = \frac{1}{n}$)

Reprezentarea unei variabile aleatoare X cu repartiție uniformă discretă este:

$$X = \begin{pmatrix} 1 & 2 & ... & k & ... & n \\ \frac{1}{n} & \frac{1}{n} & ... & \frac{1}{n} & ... & \frac{1}{n} \end{pmatrix}$$

Parametrul repartiției uniforme discrete: n;

Media: $M[X] = \frac{n+1}{2}$; ***Dispersia:*** $D^2[X] = \frac{n^2-1}{12}$;

Funcția generatoare de momente: $g_X(t) = \frac{e^t(1-e^{nt})}{n(1-e^t)}$;

Funcția caracteristică: $\varphi_X(t) = \frac{e^{it}(1-e^{int})}{n(1-e^{it})}$.

Repartiții ale variabilelor aleatoare continue

Reamintim:

O funcţie $f : \mathbb{R} \to \mathbb{R}$ este **densitate de repartiție (probabilitate)** dacă:

- $f(x) \geq 0$ pentru $\forall x \in \mathbb{R}$

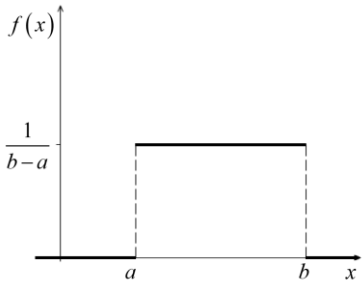
- are un număr finit de discontinuităţi (de prima speţă)
- este mărginită
- $\int_{-\infty}^{\infty} f(x)\,dx = 1$

1. Repartiția uniformă continuă

Variabila aleatoare uniformă continuă este varianta continuă a variabilei uniforme discrete, folosită pentru descrierea unei experienţe cu n rezultate posibile echiprobabile, când n tinde la infinit.
Variabila aleatoare uniformă continuă X are densitatea de repartiție :

$$f(x) = \begin{cases} \dfrac{1}{b-a}, & x \in (a,b) \\ 0, & x \notin (a,b) \end{cases}, \text{ cu } b > a \in \mathbb{R}$$

și se notează: $X \in Unif\left([a,b]\right)$.



Parametrii repartiției uniforme continue: a și b ;

Media: $M[X] = \dfrac{a+b}{2}$;

Dispersia: $D^2[X] = \dfrac{(b-a)^2}{12}$.

Funcția generatoare de momente: $g_X(t) = \begin{cases} \dfrac{e^{t\cdot b} - e^{t\cdot a}}{t(b-a)}, & t \in \mathbb{R}\setminus\{0\} \\ 1, & t = 0 \end{cases}$

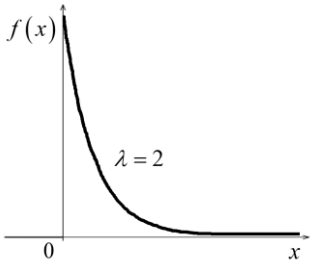
Funcția caracteristică: $\varphi_X(t) = \dfrac{e^{itb} - e^{ita}}{it(b-a)}$, $t \in \mathbb{R}\setminus\{0\}$

2. Repartiția exponențială

O variabilă aleatoare X are repartiţie exponenţială de parametru $\lambda > 0$ dacă densitatea ei de repartiție este de forma:

$$f(x) = \begin{cases} \lambda \cdot e^{-\lambda\cdot x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

și se notează: $X \in Exp(\lambda)$.



Parametrul repartiției exponențiale: λ ;

Media: $M[X] = \dfrac{1}{\lambda}$;

Dispersia: $D^2[X] = \dfrac{1}{\lambda^2}$;

Funcția generatoare de momente: $g_X(t) = \dfrac{\lambda}{\lambda - t}$ *, pentru orice* $t < \lambda$.

Funcția caracteristică: $\varphi_X(t) = \dfrac{\lambda}{\lambda - it}$

Interpretarea parametrului λ :

În multe situații practice suntem interesați de timpul scurs până la apariția unui eveniment – de exemplu timpul până la sosirea unui autobuz în stație, timpul până la primirea primului apel telefonic într-o centrală telefonică sau timpul până la sosirea primului client într-o benzinărie. În toate aceste situații putem considera că timpul scurs până la apariția evenimentului dorit este o variabilă aleatoare X cu proprietatea că probabilitatea ca X să ia valori într-un anumit interval (de timp, în exemplele de mai sus) este proporțională cu lungimea acelui interval. Parametrul repartiției exponențiale este tocmai constanta de proporționalitate.

3. Repartiția normală (Gauss)

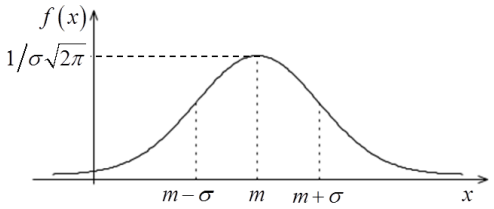
O variabilă aleatoare X are repartiţie normală (Gauss) dacă densitatea ei de repartiție este de forma:

$$f(x)=\frac{1}{\sigma\sqrt{2\pi}}e^{-\frac{(x-m)^2}{2\sigma^2}}, \text{ cu } m\in\mathbb{R} \text{ şi } \sigma>0$$

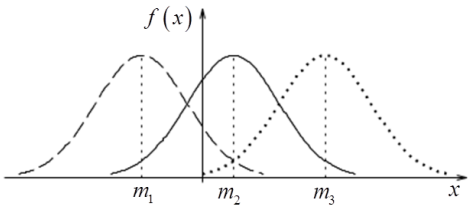
Se notează: $X\in\mathcal{N}(m,\sigma)$.

Graficul densității de repartiție pentru variabila aleatoare normală are formă de clopot (se mai numește ”Clopotul lui Gauss”) și are următoarele proprietăți:

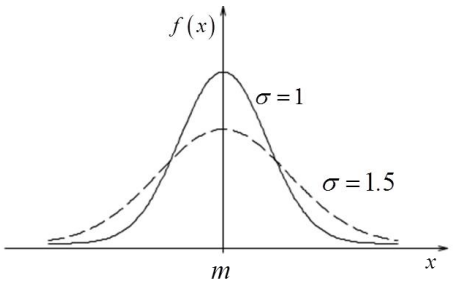
- Admite un unic punct de maxim, de coordonate $\left(m,\frac{1}{\sigma\sqrt{2\pi}}\right)$;
- Este simetric în raport cu dreapta $x=m$;
- Își modifică convexitatea în $x=m-\sigma$ și $x=m+\sigma$;



- Modificarea parametrului m (cu σ fixat) translatează graficul de-a lungul axei Ox:



- Modificarea parametrului σ (cu m fixat) modifică aplatizarea (excesul) curbei:



- ***Suma a două variabile aleatoare normale*** $X_1\in\mathcal{N}(m_1,\sigma_1)$ și $X_2\in\mathcal{N}(m_2,\sigma_2)$ este tot o variabilă aleatoare normală: $\boxed{X_1\pm X_2\in\mathcal{N}\left(m_1\pm m_2,\sqrt{\sigma_1^2+\sigma_2^2}\right)}$.

- Dacă $X_1, X_2, ..., X_n \in \mathcal{N}(m, \sigma)$ sunt variabile aleatoare independente și identic repartizate, atunci variabila aleatoare $Y = \frac{X_1 + X_2 + ... + X_n}{n}$ este repartizată normal: $Y \in \mathcal{N}\left(m, \frac{\sigma}{\sqrt{n}}\right)$.

Dacă $m = 0$ și $\sigma = 1$ spunem că X are o **repartiție normală standard** și scriem $X \in \mathcal{N}(0,1)$. Evident, în acest caz densitatea de repartiție este:

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

Funcția de repartiție (cunoscută sub numele de funcția Gauss-Laplace) este:

$$F_X(x) \overset{notatie}{=} \Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{x} e^{-\frac{t^2}{2}} dt$$

- În practică este deseori util să *transformăm o variabilă aleatoare normală* $X \in \mathcal{N}(m, \sigma)$ *într-o variabilă aleatoare normală standard* $\mathcal{N}(0,1)$. Pentru aceasta, se folosește transformarea:

$$\boxed{Z = \frac{X - m}{\sigma} \in \mathcal{N}(0,1)}$$

Parametrii repartiției normale: m și σ;
Media: $M[X] = m$; ***Dispersia:*** $D^2[X] = \sigma^2$.

Funcția generatoare de momente: $g_X(t) = e^{m \cdot t + \frac{\sigma^2 t^2}{2}}$, $t \in \mathbb{R}$

Funcția caracteristică: $\varphi_X(t) = e^{imt - \frac{\sigma^2 t^2}{2}}$

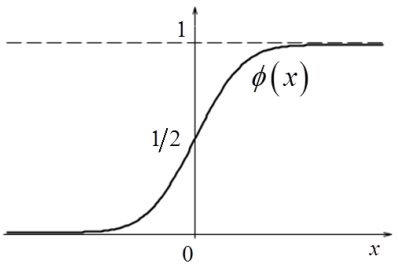
4. Funcția Gauss-Laplace

Se notează cu $\Phi(x)$ și este *<u>funcția de repartiție</u> a unei variabile aleatoare cu distribuția normală standard* $X \in \mathcal{N}(0,1)$:

$$\Phi(x) = F_X(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{x} e^{-\frac{t^2}{2}} dt$$

Proprietăți:

1) $\Phi(-\infty) = 0$
2) $\Phi(+\infty) = 1$
3) $\Phi(0) = \frac{1}{2}$
4) $\Phi(x) + \Phi(-x) = 1$ (este simetrică față de 0)



- $\Phi(x)$ se poate folosi pentru calcularea $P(a \le X \le b)$, unde $X \in \mathcal{N}(m, \sigma)$:

$$\boxed{P(a \le X \le b) = \frac{1}{\sigma\sqrt{2\pi}} \int_a^b e^{-\frac{(x-m)^2}{2\sigma^2}} dx = \Phi\left(\frac{b-m}{\sigma}\right) - \Phi\left(\frac{a-m}{\sigma}\right)}$$

(cu schimbarea de variabilă $x - m = \sigma t$)

- $\Phi(x)$ se poate folosi pentru calcularea $P\left(|X-m|<k\sigma\right)$, unde $X \in \mathcal{N}\left(m,\sigma\right)$:

$$\boxed{P\left(|X-m|<k\sigma\right)=2\Phi\left(k\right)}$$

- **Funcția de repartiție** a oricărei variabile $X \in \mathcal{N}(m,\sigma)$ se poate reprezenta cu ajutorul funcței Gauss-Laplace:

$$\boxed{P\left(X<x\right)\overset{\text{def}}{=}F(x)=\frac{1}{\sigma\sqrt{2\pi}}\int_{-\infty}^{x}e^{-\frac{(t-m)^2}{2\sigma^2}}dt=\Phi\left(\frac{x-m}{\sigma}\right)}$$

Observații:

- Valorile funcției Gauss-Laplace sunt tabelate (Anexa 3 – Tabelul A)
- Funcția Gauss-Laplace se folosește foarte mult în inginerie, deoarece în majoritatea proceselor de măsurare (unde intervin, inevitabil, erori de măsurare) se consideră că erorile urmează o distribuție normală standard.
- altă abordare în cuantificarea erorilor de măsurare presupune calcularea "**funcției erorilor**", notată $erf\left(x\right)$, care este funcția de repartiție a unei variabile aleatoare $Y \in \mathcal{N}\left(0,\frac{\sqrt{2}}{2}\right)$ care ia valori în intervalul $\left[-x,x\right]$:

$$erf\left(x\right)=\frac{1}{\sqrt{\pi}}\int_{-x}^{x}e^{-t^2}dt$$

- Valoarea funcției erorilor se poate afla cu ajutorul funcției Gauss-Laplace, legătura dintre aceste două funcții fiind dată de relația:

$$\Phi(x)=\frac{1}{2}\left[1+erf\left(\frac{x}{\sqrt{2}}\right)\right]$$

Observație: În calculele legate de variabile aleatoare continue, un rezultat des folosit este **valoarea integralei Euler-Poisson**: $\boxed{\int_{-\infty}^{\infty}e^{-\frac{x^2}{2}}dx=\sqrt{2\pi}}$. A nu se confunda cu funcția de repartiție $\Phi(x)=F(x)=\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{x}e^{-\frac{t^2}{2}}dt$. (capetele integralelor diferă !)

În definirea următoarelor repartiții intervine noțiunea de "grade de libertate". Această noțiune este specifică fizicii și statisticii matematice și, în general, în definirea ei se folosește mărimea eșantionului de date și numărul parametrilor care se vor estima.

Pentru a defini gradele de libertate strict în contextul repartițiilor de variabile aleatoare, să considerăm mai întâi un exemplu.

Considerăm o variabilă aleatoare discretă X *cu* n *valori:* $X=\begin{pmatrix}1 & 2 & 3 & \cdots & n\\ p_1 & p_2 & p_3 & \cdots & p_n\end{pmatrix}$

Pentru a determina complet repartiția lui X *este suficient să cunoaștem doar* $n-1$ *din cele* n *probabilități, a* n*-a probabilitate putând fi calculată în funcție de celelalte astfel:* $p_k=1-\sum_{\substack{i=1\\ i\neq k}}^{n}p_i$ *. Acest lucru este echivalent cu a spune că avem* $n-1$ *grade de libertate (din cei* n *parametri necesari,* $n-1$ *sunt independenți și unul este dependent – se poate determina printr-o relație cunoscută în funcție de ceilalți).*

Pe scurt, gradele de libertate ale unei variabile aleatoare reprezintă numărul de parametri independenți suficienți pentru a-i determina complet repartiția.

Repartiția "Chi pătrat"*(opțional)*

Considerăm variabilele aleatoare independente repartizate normal, cu aceeași medie și aceeași dispersie, $X_1, X_2, ..., X_n \in \mathcal{N}(m, \sigma)$. Funcția de repartiție a variabilei X definită prin:

$$X = \frac{1}{\sigma^2} \sum_{i=1}^{n} \left(X_i - m \right)^2$$

se numește repartiție χ^2 ("chi pătrat").

Deoarece putem transforma orice variabilă aleatoare normală $X \in \mathcal{N}(m, \sigma)$ într-o variabilă aleatoare normală standard $\mathcal{N}(0,1)$ cu ajutorul transformării $Z = \frac{X - m}{\sigma} \in \mathcal{N}\left(0,1\right)$, putem defini variabila aleatoare χ^2 ca fiind *suma pătratelor a* n *variabile aleatoare normale standard* $Z_1, Z_2, ..., Z_n \in \mathcal{N}(0,1)$:

$$X = \sum_{i=1}^{n} \left(\frac{X_i - m}{\sigma} \right)^2 = \sum_{i=1}^{n} Z_i^2$$

O variabilă aleatoare X cu repartiţie χ^2 și n grade de libertate (presupunem că însumăm pătratele a $n+1$ variabile aleatoare normale standard) are densitatea de repartiție de forma:

$$f\left(x\right) = \begin{cases} \dfrac{1}{2^{\frac{n}{2}} \cdot \Gamma\left(\dfrac{n}{2}\right)} \cdot e^{-\frac{x}{2}} \cdot x^{\frac{n}{2}-1}, & x > 0 \\ 0, & x \le 0 \end{cases}$$

și se notează: $X \in \chi^2$ (în definirea densității de repartiție apare funcția gamma, ale cărei valori și proprietăți se găsesc în Anexa 2)

<u>Observație</u>: Dacă am fi considerat în definirea lui $X \in \chi^2$ variabilele aleatoare independente $X_1, X_2, ..., X_n \in \mathcal{N}(m, \sigma)$, atunci densitatea de repartiție a lui X ar fi depins și de σ:

$$f\left(x\right) = \frac{1}{2^{\frac{n}{2}} \cdot \sigma^n \cdot \Gamma\left(\dfrac{n}{2}\right)} \cdot e^{-\frac{x}{2\sigma^2}} \cdot x^{\frac{n}{2}-1}, \text{ pentru } x > 0.$$

Parametrii repartiției χ^2 ***:*** n (sau n și σ);

Media: $M\left[X\right] = n$ (sau $n\sigma^2$); ***Dispersia:*** $D^2\left[X\right] = 2n$ (sau $2n\sigma^2$);

Funcția generatoare de momente: $g_X\left(t\right) = \left(1-2t\right)^{-\frac{n}{2}}$, $t < \frac{1}{2}$ (sau $\left(1-2\sigma^2 t\right)^{-\frac{n}{2}}$;

Funcția caracteristică: $\varphi_X\left(t\right) = \left(1-2it\right)^{-\frac{n}{2}}$ (sau $\left(1-2it\sigma^2\right)^{-\frac{n}{2}}$).

6. Repartiția Student *(opțional)*

Dacă variabilele aleatoare Z și Y sunt independente, cu $Z \in \mathcal{N}(0,1)$ și $Y \in \chi^2$ cu n grade de libertate, atunci variabila aleatoare:

$$X = \frac{Z}{\sqrt{\frac{Y}{n}}}$$

este repartizată după legea lui Student cu n grade de libertate și are densitatea de repartiție:

$$f(x)=\frac{1}{\sqrt{\pi n}}\frac{\Gamma\left(\frac{n+1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)}\left(1+\frac{x^2}{n}\right)^{-\frac{n+1}{2}},\ x\in\mathbb{R}\ \text{și}\ n\in\mathbb{N}$$

Parametrul repartiției Student: n;

Media: $M[X]=0$; ***Dispersia:*** $D^2[X]=\frac{n}{n-2}$, pentru $n>2$;

Funcția generatoare de momente: nu este definită;

Funcția caracteristică: are o formă foarte complicată (poate fi exprimată cu ajutorul funcțiilor Bessel de a doua speță). Nu se folosește în calcule uzuale.

7. Repartiția F (Fisher-Snedecor) (opțional)

Dacă variabilele aleatoare X_1 și X_2 sunt independente, cu $X_1\in\chi^2$ cu n_1 grade de libertate și $X_2\in\chi^2$ cu n_2 grade de libertate, atunci variabila aleatoare X definită prin:

$$X=\frac{n_2\cdot X_1}{n_1\cdot X_2}$$

are repartiția Fisher-Snedecor centrată și are funcția de densitate:

$$f(x)=\left(\frac{n_1}{n_2}\right)^{\frac{n_1}{2}}\cdot\frac{\Gamma\left(\frac{n_1+n_2}{2}\right)}{\Gamma\left(\frac{n_1}{2}\right)\cdot\Gamma\left(\frac{n_2}{2}\right)}x^{\frac{n_1}{2}-1}\cdot\left(1+\frac{n_1}{n_2}x\right)^{-\frac{n_1+n_2}{2}}\quad n_1,n_2\in\mathbb{N},\ x>0$$

Parametrii repartiției F: n_1 și n_2;

Media: $M[X]=\frac{n_2}{n_2-2}$, pentru $n_2>2$;

Dispersia: $D^2[X]=\frac{2n_2^2(n_1+n_2-2)}{n_1(n_2-2)^2(n_2-4)}$, pentru $n_2>4$;

Funcția generatoare de momente: nu este definită;

Funcția caracteristică: are o formă foarte complicată și nu se folosește în calcule uzuale.