CURS 6 (PROBABILITĂȚI)

STATISTICĂ INFERENȚIALĂ
METODA MOMENTELOR, METODA VEROSIMILITĂȚII MAXIME. INTERVALE DE ÎNCREDERE.

POPULAȚIE STATISTICĂ, SELECȚIE, ESTIMATORI

Statistica este definită ca fiind știința care se ocupă cu culegerea, înregistrarea, gruparea, analiza și interpretarea datelor referitoare la un anumit fenomen precum și cu formularea unor previziuni privind comportarea viitoare a acestuia.

Statistica matematică este o ramură a matematicii care, folosind elemente și rezultate ale teoriei probabilităților, elaborează noțiunile și metodele specifice studiului statistic.

***Statistica inferențială** este acea ramură a statisticii matematice care se ocupă cu estimarea parametrilor și testarea ipotezelor statistice, pe baza unui set de date observate.*

În continuare vor fi prezentate noțiunile de bază și anumite aspecte teoretice fundamentale ale statisticii inferențiale.

DEFINIȚII, NOTAȚII

- Prin **populație statistică** (populație) se înțelege orice mulțime care formează obiectul unei analize statistice. Elementele unei populații statistice se numesc **indivizi sau unități statistice**.

- O trăsătură comună a tuturor indivizilor din populația statistică care ne interesează se numește **caracteristică**. Caracteristicile pot fi *cantitative* (înălțime, greutate, nota obținută la un examen, abscisa unui punct în plan, etc) sau *calitative* (culoarea ochilor, genul, apartenența etnică, etc). Caracteristicilor calitative li se asociază *coduri numerice* pentru a putea fi prelucrate statistic.

În continuare ne vom ocupa doar de caracteristici cantitative.

- Fie spațiul de probabilitate (Ω, K, P), unde Ω reprezintă populația statistică. Atunci caracteristica unei populații poate fi definită ca o *variabilă aleatoare* $X : \Omega \to \mathbb{R}$, discretă sau continuă (pentru caracteristici cantitative) și doar discretă (pentru caracteristici calitative).

- **Parametrii** sunt măsuri descriptive numerice ale caracteristicilor populației. Deoarece nu avem acces la întreaga populație, parametrii sunt necunoscuți și urmează a fi estimați pe baza datelor de selecție.
Parametrii caracteristicilor de interes pot fi: *parametri care descriu tendința centrală* (medie, momente), *parametri care descriu gradul de împrăștiere al datelor* (dispersie, abatere standard, coeficient de variație), *parametri de poziție* (cuantile), *parametri ce descriu forma* (aplatizarea sau asimetria), etc.

În majoritatea situațiilor practice, necesitatea de a obține informații relevante despre caracteristici ale unor populații mari (sau infinite) este dublată de imposibilitatea examinării fiecărui individ în parte. În aceste situații se alege o sub-populație (o submulțime a lui Ω) cu un număr finit și relativ mic de elemente și se înregistrează caracteristica dorită pentru această sub-populație (în continuare va fi numită "selecție"). Se pune problema: cât de bine este aproximată (estimată) caracterstica reală a populației de către caracteristica măsurată în sub-populație ?

Răspunsul la această întrebare depinde de modul în care este făcută selecția, de volumul acesteia și de teoria statistică folosită pentru inferență.

- *Există numeroase tehnici de selecție – numite tehnici de eșantionare – și care asigură reprezentativitatea selecției la nivelul populației, adică reproducerea într-o manieră cât mai fidelă a valorilor caracteristicilor populației.*

- *Un volum al selecției mai mare (de minim 30 de date observate) asigură o mai bună inferență decât un volum mai mic.*

SELECȚII, STATISTICI

▪ O mulțime de n observații independente asupra unei caracteristici X a unei populații statistice Ω, care au valorile $x_1, x_2, ..., x_n$ se numește **selecție** de volum n. Fiecărei date observate x_i i se poate asocia o variabilă aleatoare X_i, astfel încât x_i devine o posibilă valoare a variabilei X_i.

▪ Variabilele aleatoare $X_1, X_2, ..., X_n$ se numesc **variabile aleatoare de selecție** și pot fi interpretate ca fiind un set de observații independente asupra variabilei X (caracteristica populației). Toate aceste variabile de selecție sunt identic repartizate, repartiția comună fiind repartiția variabilei X.

În concluzie, X_i este o observație a variabilei X iar x_i este valoarea corespunzătoare observată.

▪ Se numește **statistică** (sau **funcție de selecție**) o funcție de variabilele aleatoare de selecție, adică o variabilă aleatoare de forma:

$$S_n(X) = u(X_1, X_2, ..., X_n)$$

unde u este o funcție (măsurabilă) $u: \mathbb{R}^n \to \mathbb{R}$.

Alte notații uzuale pentru statistici: $S(X, n)$, $S(X_1, X_2, ..., X_n)$

▪ Repartiția unei statistici se mai numește și **repartiția (distribuția) de selecție** iar valoarea numerică $S_n(x) = u(x_1, x_2, ..., x_n)$ se numește **valoarea funcției de selecție** pentru un set dat de observații $x_1, x_2, ..., x_n$.

▪ Repartiția unei statistici poate fi *exactă* (repartiția care se poate determina pentru orice volum al selecției) sau *asimptotică* (repartiția limită a lui $S_n(X)$, pentru $n \to \infty$).

Observații:

1. Dacă se lucrează cu selecții de volum redus ($n < 30$), atunci repartiția exactă trebuie să fie cunoscută apriori, dacă urmează a se lua decizii prin inferență; Utilizarea repartiției asimptotice conduce la obținerea unor rezultate inferențiale bune doar dacă volumul de selecție este mare (cel puțin $n \geq 30$).

2. Teoria probabilităților oferă posibilitatea determinării atât a repartiției exacte cât și a repartiției asimptotice a unei statistici $S_n(X)$, iar cu ajutorul acesteia putem trage concluzii despre populația din care a provenit eșantionul observat (inferența statistică).

Unde se folosesc statisticile?

- *În probleme de estimare punctuală a parametrilor populației;*
- *În obținerea intervalelor de încredere pentru un parametru necunoscut;*
- *Pentru verificarea ipotezelor statistice, ca o statistică-test.*

EXEMPLE DE STATISTICI

***Media de selecție**: Se numește **medie de selecție** (de volum n), statistica $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$. Valoarea mediei de selecție pentru valori ale variabilelor aleatoare X_i este **media empirică**: $\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$.*

Dispersia de selecție *(varianța selecției): Se numește* ***dispersie de selecție*** *(de volum n), statistica $S_X^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^2$. Valoarea dispersiei de selecție pentru valori ale variabilelor aleatoare X_i este* ***dispersia empirică****: $s_X^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(x_i - \overline{x}\right)^2$.*

Observație: Statistica definită mai sus se mai numește și *dispersia de selecție corectată*, atunci când dispersia de selecție este definită prin formula: $S_*^2 = \frac{1}{n}\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^2$ *. Motivul pentru care NU se lucrează cu S_*^2 este că S_X^2 estimează mai bine dispersia teoretică $D^2[X]$ (S_X^2 este un estimator nedeplasat al dispersiei teoretice, pe când S_*^2 este un estimator deplasat).*

Pentru selecții de volum mare, se pot folosi oricare dintre cele două formule (S_X^2 sau S_*^2) deoarece diferența dintre valorile obținute pentru dispersia de selecție este neglijabilă.

1. ESTIMATORI

Una dintre problemele centrale ale statisticii matematice inferențiale o reprezintă *estimarea parametrilor unei populații*. Considerăm o populație statistică Ω, de volum N (finit sau infinit) și o caracteristică a sa, reprezentată de variabila aleatoare X. Pe baza unei selecții de volum $n \ll N$ dorim să estimăm diverși parametri ai caracteristicii X (cei mai comuni parametri care se doresc a fi estimați sunt *media* și *dispersia* lui X).

Estimatorii folosiți în statistica matematică se clasifică în:

- *Estimatori punctuali* – se determină o estimare a parametrului de interes din populație, pe baza valorii parametrului respectiv din selecție;
- *Estimatori sub formă de interval* – se determină un interval de apartenență pentru parametrul de interes.

Estimatorii sub formă de interval sunt cunoscuți sub denumirea de *intervale de încredere*. Aceștia au fost studiați în cursurile anterioare.

Deoarece setul de valori observate $x_1, x_2, ..., x_n$ din selecția de volum n diferă de la un eșantion la altul, vom considera, în locul lor, variabilele aleatoare de selecție $X_1, X_2, ..., X_n$ (variabile aleatoare independente, a căror repartiție comună este repartiția lui X iar x_i este o posibilă valoare a variabilei X_i).

Generic, un parametru care urmează a fi estimat se notează cu θ.

- Se numește **estimator punctual** (sau simplu, **estimator**) al lui θ o statistică $\theta = \theta\left(X_1, X_2, ..., X_n\right)$, cu ajutorul căreia dorim să îl aproximăm pe θ. Dacă $\{x_1, x_2, ..., x_n\}$ sunt date observate, atunci $\theta = \theta\left(x_1, x_2, ..., x_n\right)$ se numește **estimație** a lui θ. Așadar, *o estimație pentru un parametru necunoscut θ este valoarea estimatorului pentru selecția observată*.

Prin abuz de notație, vom nota atât estimatorul cât și estimația cu θ. Vom evita confuziile prin precizarea variabilelor de care depind.

Estimator nedeplasat, deplasare, eroare medie pătratică, eroare standard (facultativ)

Deoarece estimările sunt bazate doar pe valorile unei selecții (adică o submulțime a populației), ele nu pot fi exacte – astfel, un parametru necunoscut nu poate fi *determinat*, ci doar *estimat* (aproximat) – cu o anumită eroare de aproximare.
Apare firesc întrebarea: *cât de bine aproximează un estimator parametrul necunoscut?* Pentru a răspunde la această întrebare avem nevoie de anumite mărimi care să cuantifice erorile de aproximare – și acestea sunt: *deplasarea, eroarea medie pătratică și eroarea standard*.

- Un estimator θ se numește **estimator nedeplasat** (sau **corect**) pentru parametrul θ dacă media estimatorului este chiar valoarea parametrului estimat:

$$M\left[\theta\right]=\theta$$

Altfel, spunem că θ este un *estimator deplasat* pentru θ, iar **deplasarea** (distorsiunea) se definește prin:

$$b\left(\theta,\theta\right)=M\left[\theta\right]-\theta$$

Cantitatea $b\left(\theta,\theta\right)$ este o măsură a erorii care apare la estimarea lui θ prin θ.

- Numim **eroare medie pătratică** (*notată MSE = "mean squared error"*) a unui estimator θ pentru θ valoarea medie a pătratului diferenței dintre estimator și valoarea parametrului estimat:

$$MSE\left(\theta,\theta\right)=M\left[\left(\theta-\theta\right)^2\right]$$

<u>Observație</u>: Pentru un estimator nedeplasat, MSE este chiar dispersia estimatorului, $D^2\left[\theta\right]$.

- **Eroarea standard** (*en. standard error*) este indicatorul care arată cât de precis aproximează media calculată din valorile unei selecții de volum n, media populației din care a fost extras eșantionul și se definește prin:

$$Err=\frac{s}{\sqrt{n}}$$

unde s este abaterea standard a selecției (și este egală cu radicalul dispersiei de selecție). Eroarea standard se mai numește și "abaterea standard a mediei".

<u>Exemple:</u>

1. *Media de selecție* $\overline{X}=\frac{1}{n}\sum_{i=1}^{n}X_i$ *este un estimator nedeplasat pentru parametrul* $\theta=m$ *(media teoretică).*

2. *Dispersia de selecție "corectată":* $S_X^2=\frac{1}{n-1}\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2$ *este un estimator nedeplasat pentru parametrul* $\theta=\sigma^2$ *(dispersia teoretică)*

3. *Dispersia de selecție "necorectată"* $S_*^2=\frac{1}{n}\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2$ *este un estimator deplasat pentru parametrul* $\theta=\sigma^2$*, deplasarea fiind:*

$$b\left(S_*^2,\sigma^2\right)=M\left[S_*^2\right]-\sigma^2=\frac{n-1}{n}\sigma^2-\sigma^2=-\frac{\sigma^2}{n}.$$

4. *Momentele de selecție inițiale de ordin* k *sunt estimatori nedeplasați pentru momentele teoretice (inițiale de ordin* k*):* $M\left[M_k\left[X\right]\right]=M_k\left[X\right]$

Estimatori consistenți, absolut corecți, de dispersie minimă, eficienți (facultativ)

- Estimatorul θ pentru θ este un **estimator consistent** dacă:

$$\theta\left(X_1, X_2, ..., X_n\right) \underset{(n\to\infty)}{\overset{prob.}{\to}} \theta$$

În acest caz, valoarea numerică a estimatorului, $\theta\left(x_1, x_2, ..., x_n\right)$ se numește **estimație consistentă** pentru θ.

- Estimatorul θ pentru θ este un **estimator absolut corect** dacă:
  - **a)** este corect (adică nedeplasat): $M\left[\theta\right]=\theta$
  - **b)** $\lim\limits_{n\to\infty} D^2\left[\theta\right]=0$ (n este volumul selecției).

În acest caz, valoarea numerică a estimatorului, $\theta\left(x_1, x_2, ..., x_n\right)$ se numește **estimație absolut corectă** pentru θ.

Exemple:

1. *Dispersiile de selecție (și cea "corectată" $S_X^2=\frac{1}{n-1}\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2$ și cea "necorectată" $S_*^2=\frac{1}{n}\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2$) sunt estimatori consistenți pentru dispersia teoretică.*

2. *Dispersia de selecție "corectată" $S_X^2=\frac{1}{n-1}\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2$ este un estimator absolut corect pentru dispersia teoretică.*

3. *Momentele de selecție inițiale de ordin k sunt estimatori absolut corecți pentru momentele teoretice (inițiale de ordin k).*

- Un estimator nedeplasat θ pentru θ se numește **estimator nedeplasat uniform de dispersie minimă** dacă pentru orice alt estimator nedeplasat pentru θ, notat θ^*, avem:

$$D^2\left[\theta\right]\le D^2\left[\theta^*\right],$$

pentru orice valoare a parametrului θ.

Observație: Pentru un anumit parametru pot exista mai mulți estimatori nedeplasați. Dintre aceștia, cel mai bun estimator este cel care are *dispersia minimă*.

Exemplu: *Pentru parametrul $\theta=\lambda$ al repartiției Poisson există doi estimatori nedeplasați: $\theta=\overline{X}$ și $\theta=S_X^2$ (media și dispersia unei variabile aleatoare Poisson sunt egale între ele și egale cu parametrul repartiției, λ). Estimatorul de dispersie minimă este, în acest caz, $\theta=\overline{X}$.*

Teorema Rao-Cramer

Considerăm o selecție de volum n dintr-o populație Ω și fie X variabila aleatoare care descrie caracteristica de interes a populației. Considerăm cunoscută densitatea de repartiție a lui X, care depinde de un parametru θ, $f\left(x,\theta\right)$. Dacă θ este un *estimator nedeplasat* al lui θ, atunci:

$$D^2\left[\theta\right] \geq \frac{1}{n \cdot M\left[\left(\frac{\partial \ln f\left(x,\theta\right)}{\partial \theta}\right)^2\right]}$$

- Estimatorul pentru care se obține egalitate în Teorema Rao-Cramer se numește **estimator eficient**.

Exemple:

1. *Media de selecție* $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$ *este un estimator eficient pentru parametrul* $\theta = m$ *(media teoretică) a unei variabile aleatoare repartizate normal* $\mathcal{N}\left(m,\sigma\right)$.

2. *Media de selecție* $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$ *este un estimator eficient pentru parametrul* $\theta = \lambda$ *(media teoretică sau dispersia teoretică) a unei variabile aleatoare repartizate Poisson, de parametru* λ.

- Cu ajutorul relației din Teorema Rao-Cramer se poate determina *dispersia minimă pentru un estimator nedeplasat (corect)*.

În continuare sunt prezentate cele mai cunoscute metode de determinare a unor estimatori punctuali. Aceste "metode clasice" sunt: *metoda momentelor și metoda verosimilității maxime.*

1.2. METODA MOMENTELOR *(NU e facultativă...)*

Metoda momentelor a fost introdusă de K. Pearson în 1928 și are la bază faptul că momentele de selecție inițiale de ordin k sunt estimatori absolut corecți pentru momentele teoretice (inițiale de ordin k), adică:
$M\left[M_k\left[X\right]\right] = M_k\left[X\right]$ și $D^2\left[M_k\left[X\right]\right] = \frac{1}{n}\left(M_{2k}\left[X\right] - M_k^2\left[X\right]\right) \overset{n\to\infty}{\to} 0$.
Astfel, pentru un volum al selecției suficient de mare, *momentele teoretice inițiale de ordin* k *vor fi înlocuite cu momentele empirice de ordin corespunzător*.
Numărul momentelor care trebuie calculate este egal cu numărul parametrilor care trebuie estimați.
Estimatorii determinați prin această metodă poartă numele de **estimatori ai momentelor**.

Observație: Pentru a ușura calculele, în cazul în care trebuie să estimăm 2 parametri, se poate folosi, în locul momentului de ordin 2 (care nu are o formulă empirică echivalentă), dispersia. Astfel, sistemul din care se vor obține estimările celor 2 parametri este de forma:

$$\begin{cases} M\left[X\right] = \overline{x} \\ D^2\left[X\right] = s^2 \end{cases}$$

unde X este variabila aleatoare cu repartiția dată (ce conține cei doi parametri) și $\overline{x}$, s^2 sunt media și respectiv dispersia de selecție.

1.3. METODA VEROSIMILITĂȚII MAXIME *(NU e facultativă...)*

Această metodă a fost elaborată de R.A. Fisher în 1912.
Dacă considerăm o populație statistică Ω și o caracteristică de interes a acesteia, X, cu densitatea de repartiție specificată $f\left(x,\theta\right)$ (θ poate reprezenta un singur parametru sau poate fi considerat un vector de parametri necunoscuți, $\theta = \left(\theta_1,\theta_2,...\right)$), atunci *prin metoda verosimilității maxime se determină un estimator de dispersie minimă pentru parametrul* θ, pe baza unei selecții de volum n. Acest estimator se numește *estimator de verosimilitate maximă* și este un estimator punctual.

Notăm cu $x_1, x_2, ..., x_n$ valorile observate ale variabilelor aleatoare de selecție $X_1, X_2, ..., X_n$ (independente, cu densitățile de repartiție $f\left(x_i, \theta\right)$).

Interpretarea metodei verosimilității maxime este aceea că *estimatorul* θ *al lui* θ *este egal cu acea valoare care maximizează probabilitatea de apartiție a valorilor observate* $x_1, x_2, ..., x_n$.

În cele ce urmează vom considera că variabila aleatoare X are o *repartiție continuă*, cazul discret urmând a fi discutat separat.

- Se numește **funcție de verosimilitate** funcția definită prin:

$$P\left(x_1, x_2, ..., x_n, \theta\right) \overset{notatie}{=} L(x, \theta) = \prod_{i=1}^{n} f(x_i, \theta)$$

- Estimația de verosimilitate maximă θ pentru parametrul θ este valoarea pentru care $L\left(x, \theta\right)$ devine maximă, ceea ce conduce la faptul că estimația de verosimilitate maximă θ se obține ca soluție a ecuației: $\frac{\partial L\left(x, \theta\right)}{\partial \theta} = 0$ (cu verificare ca punct de maxim)
- Datorită formei funcției de verosimilitate (produs), calculul derivatelor parțiale se simplifică dacă logaritmăm funcția:

$$\ln L(x, \theta) = \ln\left(\prod_{i=1}^{n} f(x_i, \theta)\right) = \sum_{i=1}^{n} \ln f(x_i, \theta),$$

- Având în vedere că logaritmul este funcție crescătoare (păstrează maximul), maximizarea funcției de verosimilitate este echivalentă cu maximizarea funcției de verosimilitate logaritmată, deci *estimația de verosimilitate maximă* θ se obține ca *soluție a ecuației* $\frac{\partial \ln L\left(x, \theta\right)}{\partial \theta} = 0$, echivalent cu:

$$\sum_{i=1}^{n} \frac{\partial \ln f(x_i, \theta)}{\partial \theta} = 0$$

și care poartă numele de **ecuația verosimilității maxime**.

<u>Observație</u>: Dacă $\theta = \left(\theta_1, \theta_2, ...\right)$ este un vector de parametri necunoscuți, atunci estimatorii punctuali $\theta_1, \theta_2, ...$ ai parametrilor $\theta_1, \theta_2, ...$ se obțin rezolvând ecuațiile provenite din logaritmarea funcției de verosimilitate:

$$\left[\frac{\partial \ln L\left(x, \theta\right)}{\partial \theta_1}\right]_{\theta_1} = \left[\frac{\partial \ln L\left(x, \theta\right)}{\partial \theta_2}\right]_{\theta_2} = ... = 0$$

(câte o ecuație pentru fiecare parametru necunoscut).

Dacă variabila aleatoare X are o *repartiție discretă*, atunci în expresia funcției de verosimilitate se înlocuiesc densitățile de repartiție $f\left(x_i, \theta\right)$ cu probabilitățile corespunzătoare $p_i = P\left(X = x_i, \theta\right)$, iar funcția de verosimilitate are forma:

$$L(x, \theta) = \prod_{i=1}^{n} P(X = x_i, \theta)$$

Prin logaritmare obținem:

$$\ln L(x, \theta) = \ln\left(\prod_{i=1}^{n} P(X = x_i, \theta)\right) = \sum_{i=1}^{n} \ln P(X = x_i, \theta)$$

iar ecuația de verosimilitate este: $\sum_{i=1}^{n} \frac{\partial \ln P(X = x_i, \theta)}{\partial \theta} = 0$.

Un rezultat teoretic important, care leagă noțiunea de estimație eficientă de cea de maximă verosimilitate este următorul:

- *Orice estimator eficient este un estimator de verosimilitate maximă.*

2. INTERVALE DE ÎNCREDERE

Determinarea unui interval de încredere pentru parametrul θ care apare în legea de repartiție $f(x,\theta)$ a variabilei aleatoare X (caracteristica de interes din populație), se bazează pe construirea unei statistici (funcție de selecție).

Pentru a putea determina efectiv intervalul de încredere se fac anumite ipoteze suplimentare asupra *funcției de repartiție* a statisticii construite – cea mai des folosită este ipoteza conform căreia funcția de repartiție a statisticii nu depinde de parametrul de estimat.

Considerăm spațiul de probabilitate (Ω, K, P), unde Ω reprezintă populația statistică și o caracteristică de interes reprezentată de variabila aleatoare $X:\Omega\to\mathbb{R}$. Fie θ parametrul variabilei X pe care vrem să-l estimăm pe baza unei selecții de volum n.

2.1. Interval de încredere, nivel de încredere

Presupunem că pe baza selecției putem determina două funcții de selecție (statistici) $\theta_1(X_1, X_2, ..., X_n)$ și $\theta_2(X_1, X_2, ..., X_n)$ și $\alpha\in(0,1)$ astfel încât:

$$P\left(\theta_1(X_1, X_2, ..., X_n)\le\theta\le\theta_2(X_1, X_2, ..., X_n)\right)=1-\alpha$$

este independentă de θ.

- În acest caz, spunem că intervalul $[\theta_1,\theta_2]\subset\mathbb{R}$ este **interval de încredere de nivel** $1-\alpha$ pentru parametrul θ. Valoarea α se numește *nivel de semnificație* sau *prag de semnificație*.

Observații:

- *Intervalul de încredere diferă de la o selecție la alta* – deoarece valorile de selecție, pe baza cărora se calculează valorile statisticilor, diferă.
- *Intervalul de încredere depinde de volumul selecției și de eroarea standard*:
  - cu cât volumul selecției este mai mic, cu atât intervalul de încredere este mai larg;
  - cu cât eroarea standard este mai mare, cu atât intervalul de încredere este mai larg.
- În științele inginerești (și nu numai), nivelul intervalului de încredere se specifică procentual. De exemplu, pentru un interval de încredere de nivel 0.95 se folosește specificația 95%. Această specificare este utilă pentru interpretarea intervalului de încredere(varianta corectă).

Interpretarea intervalului de încredere:

Varianta incorectă, deși foarte uzuală: "intervalul de încredere este intervalul în care, cu o probabilitate dată ($1-\alpha$, de obicei 0.95) se află valoarea adevărată a parametrului θ (media, dispersia, etc).

***Varianta corectă*:** Considerând selecții repetate, în $100\cdot(1-\alpha)\%$ din cazuri valoarea parametrului θ se va afla în intervalul de încredere stabilit pe baza unei singure selecții.

Cum se determină efectiv un interval de încredere?

1. Se stabilește nivelul de încredere α;
2. Se alege o funcție de selecție care să depindă și de parametrul θ, $U\left(X_1, X_2, ..., X_n, \theta\right)$, *a cărei funcție de repartiție să NU depindă de* θ;
3. Se folosește densitatea de repartiție a funcției de selecție, $f_U\left(x\right)$ și două valori particulare u_1, u_2 pentru a scrie:

$$P\left(u_1 \le U \le u_2\right) = \int_{u_1}^{u_2} f_U\left(x\right) dx = 1 - \alpha$$

4. Există o infinitate de valori u_1, u_2 care satisfac relația $\int_{u_1}^{u_2} f_U\left(x\right) dx = 1 - \alpha$; Prin metode specifice (de exemplu folosind multiplicatorii lui Lagrange) se determină acele valori pentru care lungimea intervalului $\left[u_1, u_2\right]$ este minimă.

2.2. Cuantile

Fie o variabilă aleatoare X cu funcția de repartiție $F\left(x\right)$. Pentru un $\alpha \in \left(0,1\right)$, definim **cuantila de ordin** α (sau α-**cuantilă**) acea valoare $c_\alpha \in \mathbb{R}$ pentru care:

$$F\left(c_\alpha\right) = P\left(X < c_\alpha\right) = \alpha$$

Întotdeauna sunt cunoscute α și repartiția variabilei X, iar valoarea lui c_α se determină din tabelele cu valorile funcției de repartiție F (pentru variabile aleatoare continue).

Observație: Pentru variabile aleatoare discrete, ecuația $F\left(c_\alpha\right) = \alpha$ nu are soluție pentru orice α. Dacă există o soluție, atunci există o infinitate de soluții, și anume intervalul ce separă două valori consecutive ale variabilei discrete.

- Notații pentru α-cuantile în funcție de repartiția F (variabile aleatoare continue):
  - z_α pentru repartiția normală standard $N(0,1)$ (Tabelul A);
  - $t_\alpha(n)$ pentru repartiția Student $t(n)$ (Tabelul B).
  - $\chi^2_\alpha(n)$ pentru repartiția Chi-pătrat $\chi^2(n)$ (Tabelul C);
- ***Pentru repartiția normală standard*** (și prin extensie și pentru repartiția Student), cuantila de ordin α (notată z_α) se definește cu ajutorul funcției lui Laplace $\Phi\left(x\right)$:

$$P\left(X < z_\alpha\right) = F_X\left(z_\alpha\right) = \Phi\left(z_\alpha\right) = \alpha$$

În Tabelul A se găsesc valorile α-cuantilelor pentru repartiția normală standard, $\Phi\left(x\right)$, pentru $\alpha \in \left[0.5,1\right)$, adică pentru $z_\alpha \ge 0$. Datorită simetriei funcției $\Phi\left(x\right)$, celelalte α-cuantile se determină folosind proprietatea:

$$\Phi(z_\alpha)+\Phi(-z_\alpha)=1$$

- ***Pentru repartiția Student***, care este simetrică, α -cuantilele verifică proprietatea: $F(t_\alpha)+F(-t_\alpha)=1$, unde F este funcția de repartiție, cu valori tabelate.
- ***Pentru repartiția Chi-pătrat*** - valorile cuantilelor se citesc direct din Tabelul C, gradele de libertate fiind trecute pe prima coloană. Deoarece repartiția $\chi^2(n)$ nu este simetrică, nu există legături între cuantile, ca la repartițiile Student sau normală standard.

<u>*Formule echivalente de calcul*</u> pentru volumul selecției $n\geq 30$:

$$\boxed{\chi^2_\alpha(n)\cong\frac{1}{2}\left(z_\alpha+\sqrt{2n-1}\right)} \text{ și } \boxed{t_\alpha(n)\cong z_\alpha\cdot\sqrt{\frac{n}{n-2}}}$$

2.3. INTERVALE DE ÎNCREDERE PENTRU PARAMETRII REPARTIȚIEI NORMALE

Fie Ω o populație statistică cu o caracteristică de interes reprezentată prin variabila aleatoare repartizată normal $X\in\mathcal{N}(m,\sigma)$. Considerăm o selecție $x_1,x_2,...,x_n$, de volum $n\geq 30$ și notăm cu $\overline{x}$ media de selecție și cu s^2 dispersia de selecție. Pentru media de selecție se folosește estimatorul nedeplasat $\overline{x}=\frac{1}{n}\sum_{i=1}^{n}x_i$ iar pentru dispersia de selecție se folosește estimatorul *absolut corect* $s^2=\frac{1}{n-1}\sum_{i=1}^{n}(x_i-\overline{x})^2$. Considerăm cunoscut (ales) nivelul de semnificație α.

2.3.1. Intervale de încredere pentru medie

2.3.1.1. Intervalul de încredere pentru parametrul m când σ este cunoscut

Se consideră statistica $U(x_1,x_2,...,x_n,m)=\frac{\overline{x}-m}{\sigma}\sqrt{n}$ (abaterea normată a mediei de selecție), care are repartiție normală standard $U\in\mathcal{N}(0,1)$. Pentru nivelul de semnificație α stabilit, există valorile z_1 și z_2 (notații clasice pentru repartiția normală standard) astfel încât:

$$P(z_1\leq U\leq z_2)=\int_{z_1}^{z_2}f_U(x)dx=1-\alpha=\phi(z_2)-\phi(z_1).$$

Ecuația $1-\alpha=\phi(z_2)-\phi(z_1)$ are o infinitate de soluții pentru un $\alpha\in(0,1)$ fixat. Se determină valorile z_1 și z_2 pentru care lungimea intervalului $[z_1,z_2]$ este minimă (este o problemă de extrem condiționat – nu intrăm în detalii). Se obține intervalul de încredere pentru m când σ este cunoscut:

$$\boxed{I=\left(\overline{x}-\frac{\sigma}{\sqrt{n}}\cdot z_{1-\frac{\alpha}{2}}\ ,\ \overline{x}+\frac{\sigma}{\sqrt{n}}\cdot z_{1-\frac{\alpha}{2}}\right)},$$

unde $z_{1-\frac{\alpha}{2}}$ este cuantila de ordin $1-\frac{\alpha}{2}$ a repartiției $\mathcal{N}(0,1)$ (Tabelul A).

2.3.1.2. Intervalul de încredere pentru parametrul m când σ este necunoscut

Intervalul de încredere pentru m când σ este necunoscut:

$$\boxed{I=\left(\overline{x}-\sqrt{\frac{s^2}{n}}\cdot t_{1-\frac{\alpha}{2}}(n-1)\ ,\ \ \overline{x}+\sqrt{\frac{s^2}{n}}\cdot t_{1-\frac{\alpha}{2}}(n-1)\right)}$$

unde $t_{1-\frac{\alpha}{2}}(n-1)$ este cuantila de ordin $1-\frac{\alpha}{2}$ a rep. Student, pentru $n-1$ grade de libertate (Tabelul B).

2.3.2. Intervalul de încredere pentru parametrul σ^2

Intervalul de încredere pentru σ^2 :

$$I=\left(\frac{n-1}{\chi^2_{1-\frac{\alpha}{2}}(n-1)}\cdot s^2\ ,\ \frac{n-1}{\chi^2_{\frac{\alpha}{2}}(n-1)}\cdot s^2\right)$$

Unde $\chi^2_{\frac{\alpha}{2}}(n-1)$ și $\chi^2_{1-\frac{\alpha}{2}}(n-1)$ sunt cuantilele de ordin $\frac{\alpha}{2}$ și respectiv $1-\frac{\alpha}{2}$ ale repartiției Chi-pătrat, pentru $n-1$ grade de libertate (Tabelul C).

2.4. INTERVALE DE ÎNCREDERE PENTRU PARAMETRII ALTOR REPARTIȚII

Dacă volumul selecției este mare, intervalele de încredere pentru media repartiției normale $\mathcal{N}(m,\sigma)$ *sunt valabile și pentru o variabilă aleatoare care NU urmează repartiția normală, în virtutea Teoremei Limită Centrală*.

În general, pentru alte repartiții în afara celei normale, este dificil să se stabilească o statistică potrivită și să i se determine funcția de repartiție. Dacă volumul de selecție este mare, se poate determina *repartiția asimptotică* a statisticii care conține parametrul necunoscut, folosindu-se diverse metode (printre care și metoda verosimilității maxime asociată cu Legea Numerelor Mari). Nu intrăm în detalii.

Vom prezenta în continuare intervalele de încredere pentru parametrii repartițiilor *exponențială, binomială și Poisson*, datorită aplicabilității mari a acestor repartiții în diverse domenii (și în special în științele inginerești).

Considerăm o selecție de volum n și notăm variabilele aleatoare de selecție $X_1, X_2, ..., X_n$, cu valorile observate $x_1, x_2, ..., x_n$ și considerăm cunoscut (ales) nivelul de semnificație α .

2.4.1. Intervalul de încredere pentru media repartiției exponențiale

Considerăm o caracteristică de interes reprezentată printr-o variabilă aleatoare X cu repartiţie exponenţială de parametru necunoscut $\lambda>0$. Densitatea de repartiție a variabilei aleatoare X este: $f(x)=\begin{cases}\lambda\cdot e^{-\lambda\cdot x}\ , & x\geq 0\\ 0\ , & x<0\end{cases}$ iar media variabilei este $M[X]=\frac{1}{\lambda}$ (”*durata medie de funcționare*”).

Intervalul de încredere pentru medie este :

$$I=\left(\frac{2}{\chi^2_{1-\frac{\alpha}{2}}(2n)}\cdot\sum_{k=1}^{n}x_k\ ,\ \frac{2}{\chi^2_{\frac{\alpha}{2}}(2n)}\cdot\sum_{k=1}^{n}x_k\right)$$

Unde $\chi^2_{\frac{\alpha}{2}}(2n)$ și $\chi^2_{1-\frac{\alpha}{2}}(2n)$ sunt cuantilele de ordin $\frac{\alpha}{2}$ și respectiv $1-\frac{\alpha}{2}$ ale repartiției Chi-pătrat, pentru $2n$ grade de libertate (Tabelul C).

2.4.2. Intervalul de încredere pentru parametrul repartiției Bernoulli

Considerăm o caracteristică de interes reprezentată printr-o variabilă aleatoare X cu repartiţie Bernoulli , *de parametru (necunoscut)* $\theta=p$ care are tabloul de repartiție:

$$X=\begin{pmatrix}0 & 1\\ 1-p & p\end{pmatrix},\ \text{cu}\ M[X]=p$$

Fie $\hat{p}=\frac{1}{n}\sum_{i=1}^{n}x_i=\frac{k}{n}$ (frecvența relativă, estimație a lui p din selecția de volum n). Atunci intervalul de încredere pentru $\theta=p$ este:

$$\boxed{I=\left(\hat{p}-z_{1-\frac{\alpha}{2}}\cdot\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}\ ,\ \hat{p}+z_{1-\frac{\alpha}{2}}\cdot\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}\right)}$$

unde $z_{1-\frac{\alpha}{2}}$ este cuantila de ordin $1-\frac{\alpha}{2}$ a repartiței $\mathcal{N}(0,1)$ (Tabelul A).

2.4.3. Intervalul de încredere pentru parametrul repartiției Poisson

Considerăm o caracteristică de interes reprezentată printr-o variabilă aleatoare X cu repartiţie Poisson, *de parametru (necunoscut)* $\theta=\lambda$ care are tabloul de repartiție: $X=\begin{pmatrix}k\\ e^{-\lambda}\frac{\lambda^k}{k!}\end{pmatrix}$, $k\in\mathbb{N}$ şi $\lambda>0$ și $M[X]=\lambda$. Fie $\overline{x}=\frac{1}{n}\sum_{i=1}^{n}x_i$ media de selecție. Atunci intervalul de încredere pentru $\theta=\lambda$ este:

$$\boxed{I=\left(\overline{x}-z_{1-\frac{\alpha}{2}}\cdot\sqrt{\frac{\overline{x}}{n}}\ ,\ \overline{x}+z_{1-\frac{\alpha}{2}}\cdot\sqrt{\frac{\overline{x}}{n}}\right)}$$

unde $z_{1-\frac{\alpha}{2}}$ este cuantila de ordin $1-\frac{\alpha}{2}$ a repartiței $\mathcal{N}(0,1)$ (Tabelul A).