CURS 7 (PROBABILITĂȚI)

STATISTICA INFERENȚIALĂ

TESTE PARAMETRICE

IPOTEZE STATISTICE. TESTE PARAMETRICE

Una din problemele esenţiale ale statisticii este aceea de a decide asupra unor ipoteze care se nasc în mod natural din examinarea datelor avute la dispozitie sau a indicatorilor statistici care le caracterizează.

În statistică, orice afirmaţie este mai mult sau mai puţin plauzibilă, şi nu neapărat adevărată sau falsă.

- O **ipoteză statistică** este o supoziție cu privire la repartiția uneia sau a mai multor variabile din populația statistică studiată sau asupra valorilor unor parametri ai unei repartiții date (cunoscute).

- O ipoteză statistică se verifică pe baza unei selecții de volum n și cu ajutorul unui *test specific*, pe baza căruia se poate accepta sau respinge, *cu o anumită probabilitate*, ipoteza formulată.

- Validarea unei ipoteze statistice presupune formularea a două ipoteze ”de lucru”, numite **ipoteza de nul** (notată H_0) și **ipoteza alternativă** (notată H_1) și luarea unei decizii, pe baza unui test statistic, asupra acceptării sau respingerii ipotezei de nul.

Ipoteza de nul şi ipoteza alternativă

- Ipoteza de nul enunţă că nu există nicio diferenţă între parametrii studiați sau că nu există nicio diferență între repartițiile supuse testării (se specifică cu ”=”).

- Ipoteza alternativă enunţă că există o diferenţă sau o relaţie (specificată, în funcție de analiza teoretică a problemei, ca ”$\neq$”, ”$<$” sau ”$>$”).

Cele două ipoteze <u>*nu sunt complementare*</u>, în sensul că formularea lor nu acoperă în mod necesar întreg domeniul de valori al parametrului.

De exemplu, dacă se face o ipoteză statistică asupra mediei unei variabile aleatoare și se formulează ipoteza de nul $H_0: m=5$ și ipoteza alternativă $H_1: m<5$, nu înseamnă că, pentru o anumită selecție, nu putem obține o valoare a mediei mai mare ca 5.

- Probabilitatea maximă cu care este respinsă ipoteza H_0 se numește **nivel de semnificație** și se notează, în general, cu α. Cele mai uzuale nivele de semnificație sunt $\alpha=0.05$ și $\alpha=0.001$, dar se mai folosesc și valori precum 0.1, 0.025 sau 0.005.

Nivelul de semnificație este strâns legat de noțiunea de cuantilă, eroare statistică de tipul I și p-value.

Tipuri de eroare şi puterea unui test

Există două tipuri de erori posibile la efectuarea unei analize statistice.

- **Eroarea de tipul I**, cunoscută de asemenea ca ”*fals pozitiv*”, este eroarea care constă în respingerea unei ipoteze nule când este adevărată. Altfel spus, concluzionăm că există o diferenţă, când de fapt nu există nicio diferenţă.

- **Eroarea de tipul II**, cunoscută de asemenea ca ”*fals negativ*”, este eroarea care constă în nerespingerea unei ipoteze nule când nu este adevărată. Altfel spus, nu concluzionăm că există o diferenţă când de fapt o astfel de diferenţă există.

Erori de tipul I și de tipul II

Situația reală	Concluzia testului	Decizie	Eroare
H_0 este adevărată	Acceptăm H_0	Decizie corectă	
H_0 este adevărată	Respingem H_0	Decizie falsă	Eroare tip I
H_0 este falsă	Acceptăm H_0	Decizie falsă	Eroare tip II
H_0 este falsă	Respingem H_0	Decizie corectă	

Notații:

$$\alpha = P\left(Eroare\ de\ tip\ I\right) = P\left(resping\ H_0 \middle| H_0 = adev\right)$$

$$\beta = P\left(Eroare\ de\ tip\ II\right) = P\left(accept\ H_0 \middle| H_1 = adev\right)$$

- **Puterea unui test** este probabilitatea respingerii în mod corect a unei ipoteze nule atunci când ea este falsă. Această probabilitate este invers proporţională cu probabilitatea apariţiei unei erori de tipul II (nerespingerea ipotezei nule atunci când aceasta este falsă).

Există diferite metode matematice prin care se poate stabili puterea unui test, dar acest lucru nu este posibil pentru orice test. Nu intrăm în detalii.

Semnificaţie statistică și p-value

- **Semnificaţia statistică** a unui rezultat este *probabilitatea* cu care relaţia sau diferenţa observată între parametri sau între repartiții, pe baza unei selecții, există în populaţia din care s-a făcut selecția.

- Semnificaţia este exprimată cu ajutorul "**valorii p**" (se folosește uzual termenul din engleză, ***p-value***) care reprezintă probabilitatea de a face o eroare de tipul I. Un rezultat al unui test este considerat **semnificativ statistic** (adică există diferențe între parametri sau repartiții, care nu sunt întâmplătoare, deci se respinge ipoteza de nul) dacă $p\ value < \alpha$, unde α este nivelul de semnificație al testului folosit.

Pentru variabile continue, p-value reprezentă aria din dreapta valorii de test. Este dificil să se calculeze "cu mâna", dar majoritatea soft-urilor statistice o calculează și o afișează.

1. TESTE PARAMETRICE

Considerăm populația Ω și o caracteristică de interes reprezentată prin variabila aleatoare X. Presupunem că se cunoaște forma repartiției teoretice a lui X. În acest caz, ipotezele statistice care trebuie verificate (testate) se referă la *parametrii* acestei repartiții iar testele folosite în acest scop se numesc, generic, **teste parametrice**.

Fie $x_1, x_2, ..., x_n$ o selecție empirică de volum n pentru o v.a. X, o statistică $u = u(x_1, x_2, ..., x_n)$ cu repartiție cunoscută, pentru care valorile funcției de repartiție sunt tabelate sau foarte ușor de calculat și θ parametrul de interes al variabilei aleatoare X.

Testarea ipotezelor parametrice presupune parcurgerea următoarelor etape:

1) *Formularea ipotezei de nul și a celei alternative:*

- Ipoteza nulă: $H_0 : \theta = \theta_0$ (θ_0 este o valoare dată, de testare)
- Ipoteza alternativă – poate fi:
  - unilaterală: $H_1 : \theta < \theta_0$ sau $H_1 : \theta > \theta_0$

- bilaterală: $H_1 : \theta \neq \theta_0$

2) *Stabilirea nivelului de semnificație* α ;

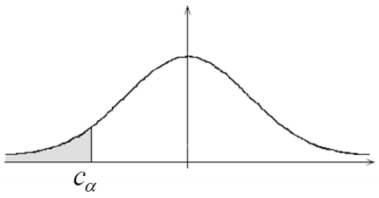
3) *Definirea statisticii* $u = u(x_1, x_2, ..., x_n)$ și precizarea repartiției sale $F(u)$;

4) *Calcularea valorilor critice (ca soluții ale ecuației* $F(c) = \alpha$), notate $c_\alpha, c_{1-\alpha}, c_{\frac{\alpha}{2}}, c_{1-\frac{\alpha}{2}}$ și care reprezintă cuantilele repartiției $F(u)$ în ipoteza H_0 :

- c_α (soluție a ecuației $F(c_\alpha) = \alpha$), pentru $H_1 : \theta < \theta_0$;
- $c_{1-\alpha}$ (soluție a ecuației $F(c_{1-\alpha}) = 1-\alpha$), pentru $H_1 : \theta > \theta_0$;
- $c_{\frac{\alpha}{2}}$ și $c_{1-\frac{\alpha}{2}}$ (soluții ale ecuațiilor $F\left(c_{\frac{\alpha}{2}}\right) = \frac{\alpha}{2}$ și respectiv $F\left(c_{1-\frac{\alpha}{2}}\right) = 1-\frac{\alpha}{2}$), pentru $H_1 : \theta \neq \theta_0$.

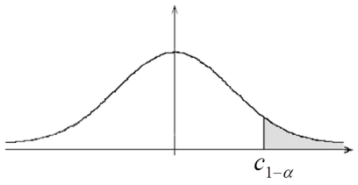
Valorile critice împart mulțimea valorilor statisticii în două regiuni: regiunea critică (de respingere a ipotezei de nul H_0 *sau altfel spus, de acceptare a ipotezei alternative* H_1*) și regiunea ne-critică (de acceptare a ipotezei de nul).*

5) În funcție de ipoteza alternativă H_1 și de valoarea critică calculată, regiunile critice (notate R_{cr}) pot fi:



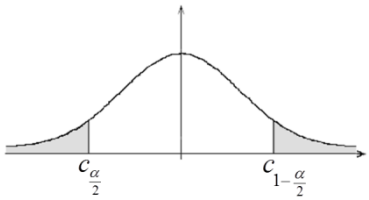
pentru un test unilateral stânga ($H_1 : \theta < \theta_0$):

$$R_{cr} = \{u \,|\, u < c_\alpha\}$$



pentru un test unilateral dreapta ($H_1 : \theta > \theta_0$):

$$R_{cr} = \{u \,|\, u > c_{1-\alpha}\}$$



pentru un test bilateral ($H_1 : \theta \neq \theta_0$):

$$R_{cr} = \left\{u \,\middle|\, u < c_{\frac{\alpha}{2}}\right\} \cup \left\{u \,\middle|\, u > c_{1-\frac{\alpha}{2}}\right\}$$

6) *Se calculează valoarea numerică a statisticii de test, folosind datele din selecție (se notează în general cu* u_{calc}*) și se compară cu valoarea corespunzătoare a cuantilei ce definește regiunea critică;*

7) Se respinge ipoteza H_0 dacă $u_{calc} \in R_{cr}$.

În continuare sunt prezentate principalele teste parametrice folosite în statistica inferențială – **pentru verificarea ipotezelor statistice asupra parametrilor repartiției normale (media și dispersia) și pentru repartiția binomială (testul pentru proporții).**

Pentru selecții de volum mare ($n > 100$ **sau chiar mai mare), *aceste teste se pot folosi indiferent de repartiția variabilei aleatoare* care reprezintă caracteristica de interes.**

2. TESTE PENTRU VERIFICAREA IPOTEZELOR REFERITOARE LA MEDIA ȘI DISPERSIA UNEI VARIABILE ALEATOARE NORMALE

Fie Ω o populație statistică cu o caracteristică de interes reprezentată prin variabila aleatoare repartizată normal $X \in \mathcal{N}(m, \sigma)$. Considerăm o selecție $x_1, x_2, ..., x_n$, de volum $n \geq 30$ și notăm cu $\overline{x}$ media de selecție și cu s^2 dispersia de selecție.

Pentru media de selecție se folosește estimatorul nedeplasat $\overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$ iar pentru dispersia de selecție se folosește estimatorul *absolut corect* $s^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(x_i - \overline{x}\right)^2$. Considerăm cunoscut (ales) nivelul de semnificație α.

2.1. Testul z pentru medie (dispersia σ^2 este cunoscută)

Ipoteza de nul $H_0: m = m_0$ (m_0 este o valoare dată, cunoscută);

Ipotezele alternative $H_1: m \neq m_0$ (bilaterală) sau $H_1: m > m_0$ sau $H_1: m < m_0$;

Se folosește statistica: $\boxed{z = \frac{\overline{x} - m_0}{\frac{\sigma}{\sqrt{n}}} \in \mathcal{N}(0,1)}$

Regiunea critică pentru ipoteza alternativă $H_1: m \neq m_0$ (bilaterală):

$$R_{cr} = \left\{ z \middle| z < z_{\frac{\alpha}{2}} \right\} \cup \left\{ z \middle| z > z_{1-\frac{\alpha}{2}} \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: m > m_0$ (unilaterală dreapta):

$$R_{cr} = \left\{ z \middle| z > z_{1-\alpha} \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: m < m_0$ (unilaterală stânga):

$$R_{cr} = \left\{ z \middle| z < z_{\alpha} \right\}$$

2.2. Testul t pentru medie (dispersia σ^2 este necunoscută)

Ipoteza de nul $H_0: m = m_0$ (m_0 este o valoare dată, cunoscută);

Ipotezele alternative $H_1: m \neq m_0$ (bilaterală) sau $H_1: m > m_0$ sau $H_1: m < m_0$;

Se folosește statistica: $\boxed{t = \frac{\overline{x} - m_0}{\frac{s}{\sqrt{n}}}}$ care este repartizată Student cu $n-1$ grade de libertate (repartiția Student este notată $t\left(n-1\right)$).

Regiunea critică pentru ipoteza alternativă $H_1: m \neq m_0$ (bilaterală):

$$R_{cr} = \left\{ t \middle| t < t_{\frac{\alpha}{2}}(n-1) \right\} \cup \left\{ t \middle| t > t_{1-\frac{\alpha}{2}}(n-1) \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: m > m_0$ (unilaterală dreapta):

$$R_{cr} = \left\{ t \middle| t > t_{1-\alpha}(n-1) \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: m < m_0$ (unilaterală stânga):

$$R_{cr} = \left\{ t \middle| t < t_{\alpha}(n-1) \right\}$$

2.3. Testul χ^2 pentru dispersie

Ipoteza de nul $H_0: \sigma^2 = \sigma_0^2$ (σ_0^2 este o valoare dată, cunoscută);

Ipotezele alternative $H_1: \sigma^2 \neq \sigma_0^2$ (bilaterală) sau $H_1: \sigma^2 > \sigma_0^2$ sau $H_1: \sigma^2 < \sigma_0^2$;

Se folosește statistica: $\boxed{v=\frac{n-1}{\sigma_0^2}s^2}$ care este repartizată χ^2 cu $n-1$ grade de libertate (repartiția Chi-pătrat este notată $\chi^2(n-1)$).

Regiunea critică pentru ipoteza alternativă $H_1:\ \sigma^2\neq\sigma_0^2$ (bilaterală):

$$R_{cr}=\left\{v\middle|v<\chi^2_{\frac{\alpha}{2}}(n-1)\right\}\cup\left\{v\middle|v>\chi^2_{1-\frac{\alpha}{2}}(n-1)\right\}$$

Regiunea critică pentru ipoteza alternativă $H_1:\ \sigma^2>\sigma_0^2$ (unilaterală dreapta):

$$R_{cr}=\left\{v\middle|v>\chi^2_{1-\alpha}(n-1)\right\}$$

Regiunea critică pentru ipoteza alternativă $H_1:\ \sigma^2<\sigma_0^2$ (unilaterală stânga):

$$R_{cr}=\left\{v\middle|v<\chi^2_{\alpha}(n-1)\right\}$$

3. TESTE PENTRU VERIFICAREA IPOTEZELOR REFERITOARE LA MEDIILE ȘI DISPERSIILE A DOUĂ VARIABILE ALEATOARE NORMALE

Ipotezele statistice asupra parametrilor repartiției normale pot fi formulate și pentru *două caracteristici diferite*, repartizate normal, ale populației.

Fie Ω o populație statistică cu două caracteristici de interes, reprezentate prin variabilele aleatoare normale independente $X_1\in\mathcal{N}(m_1,\sigma_1)$ și $X_2\in\mathcal{N}(m_2,\sigma_2)$. Considerăm două selecții corespunzătoare celor două caracteristici, $x_{11},x_{12},...,x_{1n_1}$ și $x_{21},x_{22},...,x_{2n_2}$ (de volum $n_1\geq 30$ și $n_2\geq 30$); Notăm cu $\overline{x}_1$ și $\overline{x}_2$ mediile de selecție și cu s_1^2 și respectiv s_2^2 dispersiile de selecție. Pentru media de selecție se folosește estimatorul nedeplasat $\overline{x}=\frac{1}{n}\sum_{i=1}^{n}x_i$ iar pentru dispersia de selecție se folosește estimatorul *absolut corect* $s^2=\frac{1}{n-1}\sum_{i=1}^{n}(x_i-\overline{x})^2$. Considerăm cunoscut (ales) nivelul de semnificație α.

3.1. Testul z pentru medii (dispersiile σ_1,σ_2 sunt cunoscute)

Ipoteza de nul $H_0:\ m_1=m_2$;

Ipotezele alternative $H_1:\ m_1\neq m_2$ (bilaterală) sau $H_1:\ m_1>m_2$ sau $H_1:\ m_1<m_2$;

Se folosește statistica: $\boxed{z=\frac{\overline{x}_1-\overline{x}_2}{\sqrt{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}}}\in\mathcal{N}(0,1)}$

Regiunea critică pentru ipoteza alternativă $H_1:\ m_1\neq m_2$ (bilaterală):

$$R_{cr}=\left\{z\middle|z<z_{\frac{\alpha}{2}}\right\}\cup\left\{z\middle|z>z_{1-\frac{\alpha}{2}}\right\}$$

Regiunea critică pentru ipoteza alternativă $H_1:\ m_1>m_2$ (unilaterală dreapta):

$$R_{cr}=\left\{z\middle|z>z_{1-\alpha}\right\}$$

Regiunea critică pentru ipoteza alternativă $H_1:\ m_1<m_2$ (unilaterală stânga):

$$R_{cr}=\left\{z\middle|z<z_{\alpha}\right\}$$

3.2. Testul t pentru medii (dispersiile sunt necunoscute și diferite $\sigma_1 \neq \sigma_2$)

Ipoteza de nul $H_0: m_1 = m_2$;

Ipotezele alternative $H_1: m_1 \neq m_2$ (bilaterală) sau $H_1: m_1 > m_2$ sau $H_1: m_1 < m_2$;

Se folosește statistica: $\boxed{t = \dfrac{\overline{x}_1 - \overline{x}_2}{\sqrt{\dfrac{s_1^2}{n_1} + \dfrac{s_2^2}{n_2}}}}$ care este repartizată Student cu $n-1$ grade de libertate, unde $\boxed{n = \min(n_1 - 1, n_2 - 1)}$. Repartiția Student se notează $t(n-1)$.

Regiunea critică pentru ipoteza alternativă $H_1: m_1 \neq m_2$ (bilaterală):

$$R_{cr} = \left\{ t \,\middle|\, t < t_{\frac{\alpha}{2}}(n-1) \right\} \cup \left\{ t \,\middle|\, t > t_{1-\frac{\alpha}{2}}(n-1) \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: m_1 > m_2$ (unilaterală dreapta):

$$R_{cr} = \left\{ t \,|\, t > t_{1-\alpha}(n-1) \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: m_1 < m_2$ (unilaterală stânga):

$$R_{cr} = \left\{ t \,|\, t < t_{\alpha}(n-1) \right\}$$

3.3. Testul t pentru medii (dispersiile sunt necunoscute dar egale $\sigma_1 = \sigma_2$)

Ipoteza de nul $H_0: m_1 = m_2$;

Ipotezele alternative $H_1: m_1 \neq m_2$ (bilaterală) sau $H_1: m_1 > m_2$ sau $H_1: m_1 < m_2$;

Se folosește statistica: $\boxed{t = \dfrac{\overline{x}_1 - \overline{x}_2}{\sqrt{\dfrac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1+n_2-2}\left(\dfrac{1}{n_1} + \dfrac{1}{n_2}\right)}}}$ care este repartizată Student cu $n_1 + n_2 - 2$ grade de libertate (repartiția Student este notată $t(n_1 + n_2 - 2)$).

Regiunea critică pentru ipoteza alternativă $H_1: m_1 \neq m_2$ (bilaterală):

$$R_{cr} = \left\{ t \,\middle|\, t < t_{\frac{\alpha}{2}}(n_1+n_2-2) \right\} \cup \left\{ t \,\middle|\, t > t_{1-\frac{\alpha}{2}}(n_1+n_2-2) \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: m_1 > m_2$ (unilaterală dreapta):

$$R_{cr} = \left\{ t \,|\, t > t_{1-\alpha}(n_1+n_2-2) \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: m_1 < m_2$ (unilaterală stânga):

$$R_{cr} = \left\{ t \,|\, t < t_{\alpha}(n_1+n_2-2) \right\}$$

4. TESTE PENTRU VERIFICAREA IPOTEZELOR REFERITOARE LA MEDII ȘI DISPERSII PENTRU SELECȚII DE VOLUM MIC ($n < 30$)

- Pentru selecții de volum $n < 30$ (numite și "eșantioane mici") , verificarea ipotezelor statistice referitoare la media caracteristicii reprezentate prin variabila aleatoare $X \in \mathcal{N}(m, \sigma)$ (sau pentru ipotezele referitoare la mediile a două variabile aleatoare repartizate normal) **NU se folosesc testele z** (care conțin în expresia lor valoarea dispersiei σ). Aceste teste se înlocuiesc cu corespondentele lor de tip "test t", *indiferent dacă se cunoaște dispersia variabilei X sau nu*.
- Pentru selecții de volum $n < 30$ *NU se pot extinde testele parametrice pentru medie și la alte tipuri de repartiții*. Pentru variabile aleatoare care nu au repartiția normală este indicată folosirea altor tipuri de teste (nu intrăm în detalii).

Fie Ω o populație statistică cu o caracteristică de interes reprezentată printr-o variabilă aleatoare X cu repartiție Bernoulli , *de parametru* p care are tabloul de repartiție:

$$X = \begin{pmatrix} 0 & 1 \\ 1-p & p \end{pmatrix}, \text{ cu } M[X] = p \text{ și } D^2[X] = \sigma^2 = p(1-p)$$

Fie $\hat{p} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{k}{n}$ (estimație a lui p din selecția de volum n, care reprezintă *frecvența relativă* sau *proporția "succesului"*). Considerăm cunoscut (ales) nivelul de semnificație α .

4.1. Testul z pentru o proporție

Ipoteza de nul $H_0: p = p_0$ (p_0 este o valoare dată, cunoscută);

Ipotezele alternative $H_1: p \neq p_0$ (bilaterală) sau $H_1: p > p_0$ sau $H_1: p < p_0$;

Se folosește statistica: $\boxed{z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} \in \mathcal{N}(0,1)}$

Regiunea critică pentru ipoteza alternativă $H_1: p \neq p_0$ (bilaterală):

$$R_{cr} = \left\{ z \middle| z < z_{\frac{\alpha}{2}} \right\} \cup \left\{ z \middle| z > z_{1-\frac{\alpha}{2}} \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: p > p_0$ (unilaterală dreapta):

$$R_{cr} = \left\{ z \middle| z > z_{1-\alpha} \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: p < p_0$ (unilaterală stânga):

$$R_{cr} = \left\{ z \middle| z < z_{\alpha} \right\}$$

4.2. Testul z pentru două proporții

Considerăm Ω o populație statistică cu două caracteristici de interes, reprezentate prin variabilele aleatoare Bernoulli independente X_1 și X_2, de parametru p_1 și respectiv p_2. Considerăm două selecții corespunzătoare celor două caracteristici, de volum n_1 și n_2; Notăm cu $\hat{p}_1 = \frac{k_1}{n_1}$ și $\hat{p}_2 = \frac{k_2}{n_2}$ estimațiile a lui p_1 și p_2 din cele două selecții (*frecvențele relative* sau *proporțiile "succesului").*

Ipoteza de nul $H_0: p_1 = p_2$;

Ipotezele alternative $H_1: p_1 \neq p_2$ (bilaterală) sau $H_1: p_1 > p_2$ sau $H_1: p_1 < p_2$;

Se folosește statistica: $\boxed{z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{p^*(1-p^*)\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} \in \mathcal{N}(0,1)}$,

unde $p^* = \frac{k_1 + k_2}{n_1 + n_2}$ reprezintă media ponderată a celor două frecvențe relative, ca estimare a valorii comune a celor două probabilități (necunoscute) p_1 și p_2, când ipoteza de nul este adevărată.

Regiunea critică pentru ipoteza alternativă $H_1: p_1 \neq p_2$ (bilaterală):

$$R_{cr} = \left\{ z \left| z < z_{\frac{\alpha}{2}} \right. \right\} \cup \left\{ z \left| z > z_{1-\frac{\alpha}{2}} \right. \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: \ p_1 > p_2$ (unilaterală dreapta):

$$R_{cr} = \left\{ z \left| z > z_{1-\alpha} \right. \right\}$$

Regiunea critică pentru ipoteza alternativă $H_1: \ p_1 < p_2$ (unilaterală stânga):

$$R_{cr} = \left\{ z \left| z < z_{\alpha} \right. \right\}$$